同濟大學

TONGJI UNIVERSITY

人工智能原理（论文）

课题名称 从奖励驱动到智能涌现

副 标 题 强化学习的技术脉络、前沿演进与应用图景

学　　院 国豪书院

专　　业 数据科学与大数据技术

学生姓名 费凡

学　　号 2454259

指导教师 苗夺谦、张奇

日　　期 2026.4.23

从奖励驱动到智能涌现

——强化学习的技术脉络、前沿演进与应用图景

装 订 线

摘 要

强化学习（Reinforcement Learning, RL）作为机器学习三大范式之一，凭借其在序贯决策中“试错学习”的独特机制，已成为人工智能从模式识别迈向自主决策的关键技术路径。本文系统梳理了强化学习的理论基础，包括马尔可夫决策过程的形式化框架和蒙特卡洛法、时间差分法、Q-learning、策略梯度等核心算法，并接着重分析了深度强化学习中 DQN、PPO 等重要方法。在此基础上，文章从 NeurIPS 2025 的最新研究动态出发，剖析了多模态 RL、绿色 RL 和社会协作 RL 三大前沿方向，进而从 LLM 推理增强、具身智能、金融量化交易三个维度展开应用场景分析。最后，本文对样本效率、泛化能力、安全性与可解释性等核心挑战进行了讨论，并对强化学习的未来发展做出展望。全文旨在呈现强化学习从理论基础到技术前沿再到产业应用的全景图，揭示其从“奖励驱动”走向“智能涌现”的内在逻辑。

关键词：强化学习；深度强化学习；马尔可夫决策过程；LLM 推理；具身智能

目 录

1 引 言 1
2 理论基础 2
2.1 马尔可夫决策过程 2
2.2 核心算法谱系 2
2.3 深度强化学习 3
3 前沿方向与技术演进 5
3.1 研究格局透视 5
3.2 方向一：多模态强化学习 5
3.3 方向二：绿色 RL 与高效学习 6
3.4 方向三：社会协作 RL 与价值对齐 6
4 应用场景 8
4.1 LLM 推理增强 8
4.2 具身智能 8
4.3 金融交易 9
5 挑战与展望 10
5.1 样本效率 10
5.2 泛化能力 10
5.3 安全性与可解释性 10
5.4 未来展望 11
参考文献 12

装 订 线

1 引言

2025 年 3 月 5 日，ACM 将图灵奖授予安德鲁·巴托（Andrew Barto）和理查德·萨顿（Richard Sutton），以表彰他们在强化学习理论方面的奠基性贡献。这一荣誉不仅是对两位学者数十年研究的肯定，更标志着强化学习在人工智能发展史上获得了公认的核心地位[1]。

然而，强化学习走向聚光灯下的道路并非坦途。2016 年，AlphaGo 以 4:1 战胜围棋世界冠军李世石，其“神之一手”令全球震撼，而 RL 正是 AlphaGo 训练的理论基石。RL 研究者们坚信，机器的学习可以类比人类——正如多巴胺激励神经元，机器通过与环境的反馈互动不断改进能力。但 2020 年后，大语言模型（LLM）的崛起和“缩放法则”（scaling law）的压倒性优势将 RL 相对边缘化了。在一些讨论中，从业者明确感到 RL 的“市场关注份额”流失，有人抱怨“找不到 RL 工作”，甚至出现“RL 是否走进死胡同”的论战。

峰回路转的转折点出现在 2024 至 2025 年间。当大语言模型的缩放法则开始碰壁，RL 被重新发现为解决 LLM 推理能力瓶颈的关键拼图。2024 年下半年，OpenAI 发布了用 RL 实现“深度思考”的 o1 模型[4]；2025 年初，DeepSeek 完全开源的 R1 模型在 LLM 中引入“纯 RL”，使其推理能力比肩甚至超越 o1[5]。RL 作为帮助通往通用人工智能（AGI）的关键路径，共识迅速凝聚。

正是在这一历史节点上，重新审视强化学习的技术全景具有特殊意义。本文将从理论基础出发，沿核心算法—前沿方向—应用场景—挑战与展望这条逻辑主线，对强化学习展开系统的技术调研与思考。

2 理论基础

2.1 马尔可夫决策过程

强化学习的所有理论架构，都建立在马尔可夫决策过程（Markov Decision Process, MDP）这一形式化框架之上。MDP 用一个五元组<S,A,P,R,γ>来刻画智能体与环境的交互：S为状态空间，A为动作空间，$P(s' \mid s,a)$为状态转移概率，$R(s,a)$为即时奖励函数，$\gamma \in [0,1]$为折扣因子[1]。

在 MDP 框架下，智能体的目标是学习一个策略 $\pi(a \mid s)$，使得从任意起始状态出发的累积折扣奖励期望——即价值函数 $V^{\pi}(s) = E_{\pi}[\sum_{t=0}^{\infty} \gamma^{t} R_t \mid S_0 = s]$ 达到最大。这一简洁的数学表述容纳了极为丰富的决策场景：从围棋对弈到机器人操控，从投资组合管理到临床治疗决策，皆可纳入其中。MDP 的“马尔可夫性”,即下一状态仅依赖于当前状态和动作、与历史无关，虽然在真实环境中往往不完全成立，但它为理论分析提供了坚实的起点[1]。

当环境状态不能完全观测时，MDP 的框架被推广为部分可观测马尔可夫决策过程（POMDP）。这一扩展近期在 LLM 智能体研究中获得了新的生命力：智能体的“状态”不再是一个固定的环境快照，而是包含历史观测、推理记忆和工具调用记录的复杂上下文，这使得 POMDP 成为形式化 Agentic RL 的自然选择[7]。

2.2 核心算法谱系

强化学习的算法谱系可以沿两条主线展开：基于价值的方法与基于策略的方法。这两类方法的融合则催生了现代深度强化学习中最为强大的 Actor-Critic 架构。

1. 蒙特卡洛法与时间差分法。蒙特卡洛法（Monte Carlo, MC）通过完整采样一条轨迹、以实际累积回报来估计价值，其思想直观但依赖于回合的完整完成。时间差分法（Temporal Difference, TD）则向前迈出了关键一步：它无需等待回合结束，而是在每一步都利用当前估计来“自举”（bootstrap）更新——这就是 TD 学习的核心思想，也是 RL 区别于其他学习范式的标志性特征[1]。

2. Q-learning 与 SARSA。Q-learning 是最具代表性的无模型（model-free）离策略（off-policy）算法，它直接学习最优动作价值函数 $Q^{*}(s,a)$，更新规则为 $Q(s,a) \leftarrow$

$Q(s,a)+\alpha[r+\gamma\max_{a'}Q(s',a')-Q(s,a)]$[1]。与之相比，SARSA 则采用同策略方式，在更新时使用实际采取的动作而非最优动作。两相比较：Q-learning 更为激进地追求最优，而 SARSA 在探索中的行为更为保守，这一差异在安全性敏感的应用场景中有着实质性影响。

3. 策略梯度与 Actor-Critic。基于价值的方法在高维或连续动作空间中面临“维度灾难”。策略梯度方法直接对策略进行参数化，沿期望回报上升最快的梯度方向更新参数：$\nabla_\theta J(\theta)=\mathrm{E}[\nabla_\theta \log \pi_\theta(a\mid s)\cdot\hat{A}(s,a)]$，其中$\hat{A}(s,a)$为优势函数，衡量某个动作相对于平均水平的优劣。Actor-Critic 架构将这一思想进一步系统化：Actor（执行者）负责输出动作概率，Critic（评论家）负责估计价值以提供梯度方向，两者协同训练，兼顾了策略直接优化的灵活性和价值估计的稳定性[6]。

2.3 深度强化学习

当深度学习与强化学习相遇，深度强化学习（Deep RL）使智能体能够直接从高维原始输入（如图像像素）中学习策略。

1. 深度 Q 网络（DQN）。2015 年，DeepMind 提出的 DQN 在 49 款 Atari 游戏中达到了人类专业玩家的水平，成为深度 RL 的里程碑[2]。DQN 引入了两项关键创新：经验回放（experience replay）打破数据间的时序相关性以提高样本效率；目标网络（target network）则通过固定一个周期性更新的目标 Q 值来缓解训练的不稳定性。

2. 近端策略优化（PPO）。PPO 是当前工业界使用最广泛的深度 RL 算法之一。其核心思想是限制每次策略更新的幅度，防止过大的策略改变导致训练崩溃。PPO 通过一个截断的目标函数，以简洁而高效的方式实现了“信任区域”的约束：$L^{CLIP}(\theta)=\mathrm{E}_t[\min(r_t(\theta)\hat{A}_t,\mathrm{clip}(r_t(\theta),1-\epsilon,1+\epsilon)\hat{A}_t)]$[3]。这一设计使 PPO 在保持良好样本效率的同时具有出色的稳定性，这也是为何在 RLHF（基于人类反馈的强化学习）中，PPO 长期占据首选优化器的地位。

3. 从 PPO 到 GRPO。值得注意的是，DeepSeek-R1 的成功引入了一个新的策略优化选择——群体相对策略优化（Group Relative Policy Optimization, GRPO）。与 PPO 不同，GRPO 省去了单独的价值网络，转而通过组内采样对奖励进行标准化来获得优势估计，从而降低了计算开销[5]。这一设计使得 GRPO 在大规模 LLM 训练中展现出与 PPO 不同的效率-稳定性权衡曲线。研究者指出，尽管 GRPO 在样本标准化层面具

有优势，但在高方差环境中其优势估计的可靠性可能不及传统的价值网络方法，因此算法选择仍需综合考虑任务特性和计算资源约束。[5]

装 订 线

3 前沿方向与技术演进

3.1 研究格局透视

近年来，强化学习的研究格局正在发生深刻的结构性变化。据 2025 年的一项综述统计，NeurIPS 2025 上强化学习领域投稿量达 1217 篇，较 2024 年增长约 23%，但接收率降至 18.7%，创历史新低[7]。这一“量增率降”现象既反映了 RL 研究队伍的持续扩大，也标志着领域评审标准的显著提升。更深层的信号在于：传统 RL 在以 Atari 为代表的封闭游戏环境中的性能指标增幅已明显放缓，研究重心正加速向开放环境、跨领域融合、多模态感知等更复杂的场景转移[7]。

在这一轮范式转换中，三个前沿方向尤为值得关注：多模态强化学习旨在打破传统 RL 对单一感官输入的依赖；高效学习（绿色 RL）以降低能耗和提高样本效率为核心目标；社会协作 RL 则致力于解决多智能体系统中的价值对齐与安全约束问题。

3.2 方向一：多模态强化学习

传统 RL 长期依赖单一模态输入（如图像像素或低维状态向量），但真实世界的决策天然涉及视觉、触觉、语言、力觉等多模态信号的融合。多模态 RL 正是为了打破这一单向度的限制，使智能体能够像人类一样协同处理多种感官信息。

从技术路线来看，多模态 RL 的核心挑战在于不同模态之间的对齐与融合。近期研究主要沿两条路径展开：一是表征对齐路径，通过对比学习等自监督方法将不同模态嵌入到统一的表征空间中，降低模态间的语义鸿沟；二是语言引导路径，利用大语言模型（LLM）的语义理解能力将人类指令自动转化为可执行的多模态奖励函数或任务分解方案，尤其在家用机器人等复杂场景中展现出显著效果[8]。

一个值得注意的趋势是，多模态 RL 的相关论文占比在近两年迅速上升，跻身成为最活跃的子领域之一。与此同时，随着预训练多模态基础模型（如 CLIP、GPT-4V 等）的成熟，训练多模态 RL 系统所需的数据集规模和计算成本不升反降。这表明，多模态 RL 不仅在学术研究上保持着持续的热度，在工程落地的可行性上也正从“定制化研发”走向“基于基础模型的迁移学习”阶段。

我认为，多模态 RL 的真正意义不仅在于感官维度的扩展，更在于它为具身智能

提供了一种“感知—理解—规划”一体化的架构可能性。当机器人能同时“看”、“听”、“感受”并基于语言指令综合推理时，它距离真正的自主操作将更近一步。

3.3 方向二：绿色 RL 与高效学习

AlphaGo Zero 式的暴力计算固然令人印象深刻，但其能耗代价却日益引发关注——据报道，训练一个大规模 RL 系统的计算成本可达数百万美元量级。在此背景下，如何在保持性能的同时大幅降低 RL 的能源消耗和样本需求，已成为关乎技术可持续性的核心议题。“绿色 RL”（Green RL）的理念应运而生。

高效 RL 的技术路径可归纳为三个层面。一是模型压缩与轻量化，通过知识蒸馏、网络剪枝和量化等技术，将庞大臃肿的策略网络压缩为可在边缘设备上高效运行的轻量模型，同时将性能损失控制在可接受范围内。二是样本效率提升，已有方法包括基于模型（model-based）的 RL 先学习环境动力学以降低真实交互次数，以及利用元学习或预训练策略来加速在新任务上的适配[13]。三是跨任务迁移，通过能量模型或扩散模型将已有策略的知识迁移到新场景，避免从零开始训练[10][11]。

在工业应用层面，Google DeepMind 已将 RL 驱动的节能算法应用于数据中心冷却系统，取得了实质性的节能成效。这为绿色 RL 从学术概念走向真实工业部署提供了有力的背书。这些进展共同揭示了一个趋势：RL 的发展方向不再是算力无限制扩张的军备竞赛，而是走向“以更少的资源做更多的事”的精益化路线[6]。

3.4 方向三：社会协作 RL 与价值对齐

多智能体系统中，个体的最优策略与群体整体福祉之间并非天然一致，甚至经常出现冲突——这正是社会协作 RL（Social RL / Multi-Agent RL）需要解决的核心理论问题。2025 年前后，这一方向的研究呈现出鲜明的特征：技术探索与伦理治理的深度融合。

从技术层面看，社会协作 RL 的关键挑战包括激励机制的合理设计、均衡策略的高效求解以及约束条件下的安全探索。已有研究探索通过动态机制设计来实现纳什均衡与帕累托最优的同步收敛，也有工作在尝试以可解释的“宪法式”约束条款来限制智能体策略空间，确保其在追求自身目标时至少不损害人类的基本规范[7]。

从治理层面看，这些讨论已超越了纯技术领域。欧盟《AI 法案》的推进意味着

多智能体系统的社会影响评估正在从学术倡议上升为制度性要求。我认为，RL 研究的“伦理嵌入”将成为下一个十年的重要主题——智能体的“价值观对齐”不是附加于性能之上的可选功能，而应内化于算法设计的底层逻辑之中。

装 订 线

4 应用场景

4.1 LLM 推理增强

如果说 2016 年的 AlphaGo 标志着 RL 在游戏领域的巅峰，那么 2024-2025 年的 o1 和 R1 则标志着 RL 在语言推理领域的突破性应用。传统上，LLM 的训练依赖于“下一个 token 预测”的监督学习范式，这使模型擅长模仿训练数据的统计模式，却缺乏真正的“推理”——即在多步逻辑链条上进行审慎思考的能力。

RL 之所以能够填补这一空白，深层原因在于它与推理问题的结构高度契合。推理本质上是一个序贯决策过程：从问题出发，经多步中间推导，最终得出结论。将这一过程建模为 MDP——状态为已有的推理上下文，动作为下一个推理步骤，奖励为最终答案的正确性——RL 便可系统性地优化推理策略。清华大学 KEG 团队提出的 ReST-RL 方法进一步推进了这一思路：它将改进的 GRPO 算法与价值模型辅助的蒙特卡洛树搜索相结合，在 APPS、BigCodeBench 和 HumanEval 等不同级别的编程基准上，其性能显著优于原始 GRPO 和 ReST-DPO 等基线方法[9]。

从 RLHF 到 RLVR（可验证奖励强化学习），LLM 对齐范式也在经历深刻转变。RLHF 依赖人类标注训练奖励模型，成本高昂且难以扩展；RLVR 则利用数学答案、代码执行结果等可自动验证的确定性指标作为奖励信号，使对齐过程的可扩展性大幅提升[5][9]。DeepSeek-R1 所采用的两阶段“SFT→GRPO”流程，正是 RLVR 范式的典型实践。我认为，这一从“靠人教”到“靠验证”的转变，恰如神经科学中从“模仿学习”到“试错学习”的认知进化——它赋予了模型在推理空间中自主探索、自我纠正的能力，这是通向更高层次智能的关键一步。

4.2 具身智能

具身智能（Embodied AI）是 RL 从数字世界迈向物理世界的前沿阵地。与游戏环境不同，物理世界的高维感官输入、复杂动力学、稀疏奖励和安全性约束，使得机器人 RL 成为一个极具挑战性的问题域。

近年的一个重要趋势是生成式模型与 RL 的深度融合。一篇 2025 年的综述梳理了 245 篇将 Transformer 和扩散模型架构融入 RL 管线的论文，揭示了二者之间的“对

偶关系”：生成式 AI 作为 RL 的多模态先验，提供强大的表征能力；RL 则为生成式策略提供训练与精调机制，使之适应具体的控制任务[8]。在具身智能场景中，这种融合催生了一系列令人瞩目的成果：视觉-语言-动作（VLA）模型将 LLM 的语义理解与 RL 的动作优化相结合，使机器人能够根据自然语言指令完成复杂的操作任务[8]。

然而，从仿真环境到真实世界的迁移——即“Sim-to-Real Gap”——依然是具身 RL 面临的核心瓶颈。模拟器中习得的策略在真实世界中常常失效，原因包括物理参数的不匹配、传感器噪声的差异以及不可预见的环境变化。域随机化与渐进迁移是当前的主流对策，但距离真正的鲁棒部署仍有相当距离。我认为，解决这一问题的关键或许不在于更逼真的仿真，而在于赋予智能体以“元学习”能力——即不仅学会完成特定任务，更学会在面临新环境时快速适应。

4.3 金融交易

金融市场是 RL 最理想的试验场之一，原因在于三方面的高度契合：金融决策本质上是序贯的（每笔交易影响未来持仓和市场状态）；环境提供的反馈是明确但延迟的（盈亏数字）；以及策略优化的目标是累积收益的最大化。三者叠加，恰好吻合 RL 的核心设计原则。

2025 年的研究展现出从“通用 RL 到金融 RL”转向“金融特有 RL”的深化趋势。例如，ChronosRL 框架利用 Transformer 生成的预训练嵌入来捕捉加密货币交易中复杂的时间依赖关系，以化解传统手工特征方法难以表征非线性市场模式的困境[14]。另一项针对印度 NIFTY 50 指数的研究则构建了一套完整的 DRL 交易框架，并在 2024 年 5 月至 2025 年 4 月的未见过数据上验证了泛化性能[15]。

不过，金融 RL 的特殊性也不容忽视。市场数据的高度非平稳性意味着历史模式频繁失效；过拟合的危险远超其他 RL 领域；而探索-利用的平衡——是冒险押注未知机会还是守住已知策略——更直接关乎真金白银的得失。这些挑战使得金融 RL 不仅是对算法的考验，更是对研究者在风险与回报之间判断力的检验。

5 挑战与展望

5.1 样本效率

尽管深度 RL 取得了诸多突破，但其“数据饥渴”的本性仍是最根本的制约之一。典型深度RL算法往往需要与环境交互数百万乃至数十亿步才能收敛到一个有效的策略，这对于成本高昂或时间敏感的物理系统而言是不可接受的。

值得关注的是，“预训练-微调”这一在 NLP 和 CV 中取得巨大成功的范式，正被引入 RL 领域。伯克利团队提出的 InFOM（Intention-Conditioned Flow Occupancy Models）方法，通过流匹配技术构建对意图敏感的占据模型，在不依赖奖励信号的情况下对 RL 智能体进行预训练。其预训练模型在下游任务中的样本效率可提升高达 20 倍，并能执行更精细的意图推理[12]。这一方向如果持续发展，有望从根本上改变 RL 的研发模式：像今天下载一个预训练语言模型一样，未来 RL 从业者或许也能直接调用一个“通用决策基础模型”，仅需少量环境交互即可适配到特定任务。

5.2 泛化能力

RL 策略对训练环境的“过拟合”同样令人担忧。一个在固定地图上训练出的导航策略，换到新地图可能完全失效；一个针对特定机器人型号优化的操控策略，换到尺寸略有差异的新型号上可能无法正常工作。

这指向 RL 领域的一个深层问题：当前的训练范式倾向于让智能体“记住”特定的环境模式，而非“理解”任务背后的抽象结构。构建能够跨任务泛化的 RL 模型，既需要在架构层面引入更强的归纳偏置（如因果关系建模和目标条件的策略表示），也需要在训练层面设计多样化的环境分布以覆盖更多的可能情景[13]。

5.3 安全性与可解释性

当 RL 被部署到医疗决策、自动驾驶、金融交易等高风险场景时，“安全”与“可解释”便从可选特性变为刚性约束。

在安全性方面，Safe RL 已成为一个活跃的子领域。代表性工作 SafeRPlan 为脊柱手术中的椎弓根螺钉放置设计了安全性感知的 DRL 规划方法，在路径规划的全过

程中持续监测安全约束[16]；在可解释性方面，RL 模型的“黑箱”特性使得其决策理由难以向人类用户传达——当 AI 推荐系统解释“为什么推荐这个商品”或“为什么执行这个交易”时，人类期望获得的远不止“这是策略网络的输出”这样的回答。如何在性能与可解释性之间找到平衡，是强化学习从实验室走向社会的必修课。

5.4 未来展望

面向未来，我认为 RL 的发展将沿三条主线展开。其一，与 LLM 的深度融合将持续深化，Agentic RL 这个将 LLM 从被动的文本生成器重新定义为嵌入于复杂、动态世界中的自主决策主体，将在自动化办公、科学研究、智能客服等场景中催生新一代 AI 智能体[7]。其二，多模态与世界模型将成为 RL 智能体理解物理世界的“想象力引擎”，使它们不仅能在已知环境中反应，还能在未见环境中预演[8]。其三，RL 将越来越密切地与社会治理和伦理机制互动，智能体的“价值观对齐”将不再是附加功能，而是设计中的内在约束。

强化学习曾被比喻为“AI 蛋糕上的樱桃”——虽精巧但体量有限。然而今天，这颗“樱桃”正在成长为整个蛋糕中最具活力的组成部分。从驱动 AlphaGo 下出“神之一手”，到赋能 LLM 展现“深度思考”，再到指挥机器人在现实世界灵活操作，RL 所承载的不仅是算法的进步，更是人类对“智能何以可能”这一根本命题的持续追问。

装 订 线

参考文献

[1] Barto A G, Sutton R S. Reinforcement Learning: An Introduction (2nd Edition)[M]. Cambridge: MIT Press, 2018.

[2] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[3] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. arXiv preprint, 2017, arXiv:1707.06347.

[4] OpenAI. Learning to Reason with LLMs (o1 System Card)[R]. OpenAI Technical Report, 2024.

[5] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning[J]. arXiv preprint, 2025, arXiv:2501.12948.

[6] 李升波. Reinforcement Learning for Sequential Decision and Optimal Control[M]. Singapore: Springer, 2023.

[7] Zhang G, Geng H, Yu X, et al. The Landscape of Agentic Reinforcement Learning for LLMs: A Survey[J]. arXiv preprint, 2025.

[8] Moro C, et al. The duality of generative AI and reinforcement learning in robotics: A review[J]. Information Fusion, 2025.

[9] 清华大学知识工程研究室（KEG）团队. ReST-RL: 统一 LLM 强化学习新范式[J]. arXiv preprint, 2025, arXiv:2508.19576.

[10] Ding S, Hu K, Zhong S, et al. GenPO: Generative Diffusion Models Meet On-Policy Reinforcement Learning[C]//NeurIPS, 2025.

[11] Celik O, Li Z, Blessing D, et al. DIME: Diffusion-Based Maximum Entropy Reinforcement Learning[C]//ICML, 2025.

[12] Zheng C, Eysenbach B, Levine S, et al. InFOM: Intention-Conditioned Flow Occupancy Models for Reinforcement Learning Pretraining[J]. arXiv preprint, 2025, arXiv:2506.08902.

[13] Soni S. Exploring Reinforcement Learning: Theory, Applications, and Advances[J]. TechRxiv, 2025.

[14] Oliveira A L I, Zanchettin C. ChronosRL: embeddings-based reinforcement learning agent for financial trading[J]. ScienceDirect, 2025, 264.

[15] MDPI. A Deep Reinforcement Learning Framework for Strategic Indian NIFTY 50 Index Trading[J]. MDPI, 2025.

[16] Ao Y, Esfandiari H, Carrillo F, et al. SafeRPlan: Safe deep reinforcement learning for intraoperative planning of pedicle screw placement[J]. Medical Image Analysis, 2025, 99: 103507.

装

订

线