同濟大學

TONGJI UNIVERSITY

人工智能课程设计

课题名称	基于 Stable Diffusion 的古诗转水墨画研究
学　　院	国豪书院
专　　业	数据科学与大数据技术
学生姓名	费凡
学　　号	2454259
指导教师	苗夺谦，张奇
日　　期	2026.6.2

基于 Stable Diffusion 的古诗转水墨画研究

装

订

线

摘 要

本实验基于 Stable Diffusion v1.5 扩散模型，利用 Python + PyTorch 框架，系统实现了从中文古诗到水墨画风格的自动生成。依次完成了基线模型部署、全参数微调（U-Net only）、写实风格迁移微调、双组件 LoRA 协同微调、换用条件生成对抗网络（cGAN）以及多维度消融实验。特别地，通过双 LoRA 微调，模型在保持高保真水墨画风的同时，自动涌现出书法题款与红色印章等文化符号；通过推理期动态权重调配与中英文混合提示词，成功解决了“孤舟”“雪”等低频语义的召回问题。实验结果表明，参数高效微调（PEFT）和跨语系提示词工程能够显著提升文生图大模型在垂直领域的效果与可控性。本报告详细阐述了各项任务的实现原理、训练过程、结果分析及优化策略，可为同类研究提供工程参考。

关键词： Stable Diffusion；LoRA；全参数微调；古诗转水墨画；条件生成对抗网络

目 录

1 引 言 1
1.1 研究背景与意义 1
1.2 国内外研究现状 1
1.2.1 文本到图像生成的发展脉络 1
1.2.2 古诗自动视觉化研究 2
1.2.3 参数高效微调（PEFT）与 LoRA 2
1.3 本文研究动机与创新点 2
1.4 实验总体框架 3
2 相关工作与理论基础 4
2.1 扩散模型基本原理 4
2.1.1 前向扩散过程 4
2.1.2 反向去噪过程 4
2.1.3 潜在扩散模型（LDM） 4
2.1.4 条件注入与交叉注意力 4
2.1.5 CLIP 文本编码器的跨语言局限 5
2.2 参数高效微调（PEFT）与 LoRA 5
2.2.1 全参数微调的局限 5
2.2.2 LoRA 的数学形式 5
2.2.3 LoRA 在扩散模型中的应用 5
2.2.4 LoRA 推理期动态权重调节 6
2.3 条件生成对抗网络（cGAN） 6
2.3.1 GAN 的基本原理 6
2.3.2 条件 GAN 6
3 实验环境与数据集 7
3.1 软硬件配置 7
3.2 古诗-水墨画数据集（Paint4Poem） 7
3.3 自建写实数据集（任务三） 7
3.4 数据加载器实现 7
4 基线实验 9
4.1 部署步骤 9
4.1.1 模型权重获取 9
4.1.2 依赖库安装 9
4.2 代码原理与算法流程 9
4.2.1 完整代码解析 9
4.2.2 扩散模型推理算法流程 10
4.3 基线效果分析 10
4.3.1 实验结果展示 10
4.3.2 基线实验综合结论 11
5 Task2：全参数微调 12

装 订 线

5.1 微调策略 12
5.2 生成结果与分析 13
6 Task 6：双组件 LORA 协同微调 14
6.1 微调策略与代码实现 14
6.1.1 训练配置 14
6.1.2 双组件 LoRA 注入代码解析 14
6.1.3 推理期动态权重调节 15
6.2 生成结果与分析 15
6.2.1 结果展示 15
6.2.2 LoRA 权重调节的机理与博弈分析 16
6.3 跨微调范式对比 17
7 Task 3：写实风格迁移微调 18
7.1 微调策略与提示词 18
7.2 生成结果与分析 18
8 Task 5：条件生成对抗网络（cGAN）对比实验 19
8.1 模型设计与理论依据 19
8.1.1 文本编码器 19
8.1.2 生成器结构 19
8.1.3 判别器与谱归一化 20
8.1.4 训练策略与超参数 21
8.2 生成结果分析 21
8.3 与扩散模型的对比结论 21
9 结果展示与综合对比 23
9.1 三代模型同题对比 23
10 总结与展望 25
10.1 主要成果 25
10.2 局限性 25
10.3 未来工作 26

装 订 线

1 引言

1.1 研究背景与意义

中国古典诗歌以寥寥数字构筑“象外之象，景外之景”，是汉语音韵、意象与哲思的极致凝练；水墨画则以“墨分五色”勾勒气韵生动的自然，追求“似与不似之间”的写意精神。二者在意境营造与写意表达上高度统一，共同构成了独具东方美学的艺术体系。从王维“诗中有画，画中有诗”的文人理想，到苏轼“论画以形似，见与儿童邻”的写意主张，诗画融合历来是中国艺术的核心命题。然而，传统艺术创作门槛高、传播受限，借助人工智能实现“读诗成画”，不仅是文化传承的创新手段，也是多模态生成领域的前沿课题。

近年来，扩散模型（Diffusion Model）在图像生成领域取得突破性进展[1]。不同于生成对抗网络（GAN）容易陷入模式坍塌，也不同于变分自编码器（VAE）生成图像趋于模糊，扩散模型通过逐步去噪的方式生成高质量、多样化的图像，迅速成为文生图任务的主流架构。Stable Diffusion 作为当前最广泛使用的开源扩散模型，基于潜在扩散模型（LDM）框架，利用预训练的 VAE 将图像压缩到低维隐空间，在保留语义信息的同时大幅降低了计算开销。其文本编码器采用 CLIP 的 ViT-L/14 模型，能够将自然语言描述映射为语义特征向量，并通过交叉注意力机制注入 U-Net，实现了灵活可控的文本-图像生成。

然而，Stable Diffusion v1.5 的直接应用存在两大瓶颈：其一，CLIP 文本编码器完全基于英文语料（400M 图文对）训练，对中文汉字的 BPE 分词会拆解为多个无意义的字节片段，导致语义断裂；其二，其训练数据中涉及中国传统水墨画的样本极少，模型缺乏对“留白”、“皴法”、“题款”等文化符号的认知。因此，直接使用原生模型输入中文古诗“孤舟蓑笠翁，独钓寒江雪”，往往会输出卡车、客车等完全不相关的物体，完全无法体现诗意。这一现象揭示了跨语言、跨文化领域下大模型迁移的巨大挑战。

1.2 国内外研究现状

1.2.1 文本到图像生成的发展脉络

早期文本到图像生成主要依赖条件 GAN。例如，Mirza 等人提出的 Conditional GAN 首次将文本特征作为条件输入生成器和判别器，能够生成简单物体（如鸟类、花卉）的低分辨率图像[3]。随后，StackGAN 通过多阶段生成逐步提高分辨率，AttnGAN 引入注意力机制对准文本中的单词与图像区域。然而，GAN 方法受限于训练不稳定和模式坍塌，生成的图像在多样性和复杂场景理解上仍不尽人意。

扩散模型的出现改变了这一格局。DDPM（Denoising Diffusion Probabilistic Models）展示了

强大的无条件生成能力，但推理速度极慢。LDM 通过压缩到隐空间，将训练和推理效率提升了数倍。GLIDE、DALL·E 2 等模型进一步证实了扩散模型在高保真文生图任务上的统治地位。Stable Diffusion 作为 LDM 的开源实现，迅速成为学术界和工业界的基准模型。

1.2.2 古诗自动视觉化研究

针对古诗生成图像的跨模态任务，已有若干探索。早期工作利用图库检索和图像拼接（如“诗配画”系统），缺乏生成能力。近年来，基于深度学习的方案逐渐兴起，但大多受限于小规模数据集和弱泛化能力。Paint4Poem 数据集（约 6000 对古诗-水墨画）[5]的发布为微调大模型提供了基础。一些研究者尝试使用扩散模型直接生成水墨画，但通常针对英文描述，对中文古诗的适配性未作深入探究。此外，大多数工作仅关注画风迁移，忽略了中文语义的精确对齐以及文化符号（题款、印章）的生成。

1.2.3 参数高效微调（PEFT）与 LoRA

大模型的全参数微调需要巨大的显存和计算资源。例如，Stable Diffusion 的 U-Net 约 8.6 亿参数，即使使用混合精度训练也需要 40GB 以上显存。为降低门槛，LoRA（Low-Rank Adaptation）被提出，通过在预训练权重旁添加低秩可训练矩阵，仅更新极少参数（通常小于 0.5%）即可达到与全参数微调相当的效果[2]。LoRA 已被广泛应用于大语言模型（如 LLaMA、GPT-3）的下游微调，并扩展至扩散模型。在扩散模型中，LoRA 既可应用于 U-Net 的交叉注意力层，也可应用于文本编码器的自注意力层，从而实现风格域迁移或概念定制。

1.3 本文研究动机与创新点

尽管已有若干工作利用 Stable Diffusion 生成水墨画，但以下三个核心问题尚未得到系统解决：

（1）跨语言语义断层：CLIP 的英文分词和语义空间无法直接理解中文古诗，导致原生模型输出完全偏离诗意。虽有研究使用翻译中间件，但会引入额外误差且破坏文化独特表达。

（2）风格与语义的权衡：全参数微调虽能迁移画风，但冻结文本编码器会丢失具体名词（如“孤舟”、“蓑笠翁”）；解冻文本编码器又会导致模型过度学习训练数据中的高频模式（大山、松树、云雾），压制低频细节（雪、孤舟）。

（3）文化符号的缺失：普通水墨画生成结果往往只具有墨色纹理，缺乏中国传统绘画特有的题款（书法）、印章等元素，而这些恰是文人画的重要标识。

针对上述挑战，本文创新性地提出了以下解决方案：

（1）双组件 LoRA 协同微调：同时微调 U-Net 和文本编码器，在极低显存开销下使模型自主涌现出书法题款和红色印章，证明了 LoRA 深度同化数据分布的能力。

（2）推理期动态权重调配：利用 LoRA 的线性可加性，在推理时动态调节 U-Net 与文本编码器的贡献比例（如 U=0.7, T=0.2），平衡风格强度与低频语义召回。

（3）中英文混合提示词工程：用英文描述具体物体（孤舟、渔翁、雪山）以锁定构图和语义，用中文关键词（水墨画，原诗句）激活 Text-LoRA 的风格记忆，在不重新训练的前提下大幅提升生成质量。

1.4 实验总体框架

本实验依托同济大学科学计算服务平台 L40 GPU（48GB 显存），基于 PyTorch 框架，依次完成以下内容：

（1）基线部署与问题诊断：部署 Stable Diffusion v1.5，量化验证 CLIP 对中文古诗的语义断层。

（2）全参数微调：仅微调 U-Net，实现水墨画风迁移，并分析冻结文本编码器的局限性。

（3）写实风格 LoRA 微调：自建约 30 张小样本写实数据集，验证 LoRA 在多样化场景下的泛化能力。

（4）双组件 LoRA 协同微调：同时对 U-Net 和文本编码器进行 LoRA 微调，观察文化符号涌现现象。

（5）跨语言瓶颈突破：通过动态权重调配、中英文混合提示词、多种子搜索等轻量级优化，最终生成符合诗句意境的理想图像。

（6）换用 cGAN 对比：从零实现条件生成对抗网络，作为扩散模型的对照实验。

通过上述系统性实验，本文旨在为中文古诗到水墨画的跨模态生成提供一套完整、可复现的工程方案，并深入探讨大模型微调中的风格-语义协同优化问题。

装 订 线

2 相关工作与理论基础

2.1 扩散模型基本原理

2.1.1 前向扩散过程

给定真实数据分布 $x_0 \sim q(x)$，扩散模型定义了一个固定的马尔可夫链，逐步向样本添加高斯噪声，生成一系列带噪变量 $x_1, x_2, \ldots, x_T$。每一步的转移概率为：

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t \mathbf{I})$$

其中 $\beta_t \in (0,1)$ 为预定义的噪声方差调度，通常采用线性、余弦或自适应调度。通过重参数化技巧，我们可以直接得到任意步 t 的带噪样本：

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

这里 $\alpha_t = 1 - \beta_t$，$\bar{\alpha}_t = \prod_{i=1}^{t} \alpha_i$。当 T 足够大时，x_T 近似为标准高斯噪声。

2.1.2 反向去噪过程

反向过程试图从纯噪声 x_T 中逐步恢复原始数据。它学习一个参数化的条件分布：

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

Ho 等人发现，将 Σ_θ 固定为时间相关的常数 σ_t^2 即可获得高质量生成，且训练目标可以简化为预测噪声 $\epsilon_\theta(x_t, t)$[6]：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, \epsilon, t}[\| \epsilon - \epsilon_\theta(x_t, t) \|^2]$$

2.1.3 潜在扩散模型（LDM）

直接在高维像素空间进行扩散计算量巨大。LDM 引入一个预训练的感知压缩模型（VAE），将图像 $x \in \mathbb{R}^{H \times W \times 3}$ 编码为低维隐变量 $z \in \mathbb{R}^{h \times w \times c}$，其中通常 $h = H/8, w = W/8$（例如 512→64）。扩散和去噪过程在隐空间中进行，训练损失为：

$$\mathcal{L}_{\text{LDM}} = \mathbb{E}_{z_0, \epsilon, t}[\| \epsilon - \epsilon_\theta(z_t, t) \|^2]$$

在生成时，先通过反向过程得到隐编码 z_0，再经 VAE 解码器重建图像。

2.1.4 条件注入与交叉注意力

为了实现文本-图像生成，LDM 在 U-Net 的每个分辨率层级中增加了交叉注意力层。给定文本编码器提取的条件序列 $y \in \mathbb{R}^{L \times d_y}$，U-Net 的特征图 $\varphi(z_t) \in \mathbb{R}^{h' \times w' \times d_z}$，交叉注意力的计算公式为：

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d}}\right)V$$

其中 $Q = W_Q \cdot \varphi(z_t)$，$K = W_K \cdot y$，$V = W_V \cdot y$。通过这种方式，文本语义被融入到去噪过程的每一步，从而控制生成内容。

2.1.5 CLIP 文本编码器的跨语言局限

Stable Diffusion 使用的 CLIP 文本编码器基于英文语料训练，其分词器采用 Byte-Pair Encoding（BPE）。对于英文单词，BPE 能合理切分为有意义的子词；但对于中文汉字，BPE 会将每个汉字拆解为 2~4 个无意义的字节 token（如“孤”拆为 b'\xe5\xad\xa4'的三个字节）。这些字节 token 在 CLIP 的英文词表中出现频率极低，被随机映射为不携带语义的向量。当输入中文古诗时，模型只能将这些碎片向量的统计模式与训练数据中某些英文词汇（如“truck”、“bus”）的视觉特征关联，导致语义断裂。这一缺陷是后续微调（任务 2 和任务 6）必须解决的核心问题之一。

2.2 参数高效微调（PEFT）与 LoRA

2.2.1 全参数微调的局限

全参数微调需要更新整个 U-Net（约 8.6 亿参数）。对于每次训练迭代，需要存储参数、梯度、优化器状态（Adam 的动量和方差），显存开销接近参数量的 3-4 倍。即使在混合精度和梯度累积下，L40 的 48GB 显存也仅能容纳 batch_size=4 且不开启梯度检查点的训练。此外，全参数微调容易导致灾难性遗忘，尤其当目标任务数据量有限时。

2.2.2 LoRA 的数学形式

LoRA 假设预训练权重 $W_0 \in \mathbb{R}^{d\times k}$ 的更新具有低秩性，即 ΔW 可分解为两个小矩阵的乘积：

$$W = W_0 + \frac{\alpha}{r}BA, B \in \mathbb{R}^{d\times r}, A \in \mathbb{R}^{r\times k}$$

其中 $r \ll \min(d,k)$ 为秩，α 为缩放系数。在训练时，W_0 被冻结，只更新 A 和 B。由于 r 通常取 4、8 或 16，可训练参数量降低到原始模型的几千分之一。前向传播时，首先计算原始输出 $h_0 = W_0x$，再加上低秩修正项 $\frac{\alpha}{r}BAx$。由于 A 和 B 很小，额外的计算开销几乎可以忽略。

2.2.3 LoRA 在扩散模型中的应用

在本实验中，LoRA 分别应用于：

（1）U-Net 的交叉注意力层：其中的 to_q、to_k、to_v、to_out.0 负责将文本特征与图像特征进行跨模态融合，是风格迁移的关键路径。在这些层上施加 LoRA，可以高效调整模型对文本条件的响应方式。

（2）文本编码器的自注意力层：其中的 q_proj、v_proj 参与构建文本的内部语义表示。对这些层进行 LoRA 微调，能够使文本特征适应中文古诗的语义空间，纠正 CLIP 的原生偏见。

通过 PEFT 技术，本实验的双 LoRA 模型可训练参数仅约 1.9M（占 U-Net+文本编码器总参数的 0.22%），显存占用从 44GB 降至 14GB，同时训练速度提升约 3 倍。

2.2.4 LoRA 推理期动态权重调节

由于训练时只更新低秩矩阵A和B，底模W_0保持不变。在推理阶段，缩放系数α可以独立调节，无需重新训练。这允许我们分别控制 U-Net 适配器和文本编码器适配器的贡献强度：增大α会强化微调特征，减小α则更依赖预训练知识。本实验中，通过对 U-Net 和文本编码器设置不同的α值（如 U=0.7, T=0.2），实现了风格强度与语义召回之间的动态平衡。

2.3 条件生成对抗网络（cGAN）

2.3.1 GAN 的基本原理

生成对抗网络由生成器 G 和判别器 D 组成，二者进行极小极大博弈：

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z\sim p_z}[\log(1 - D(G(z)))]$$

生成器试图产生逼真图像欺骗判别器，判别器则努力区分真实图像与生成图像。训练时，两者交替更新，最终达到纳什均衡。

2.3.2 条件 GAN

cGAN 在生成器和判别器中均额外输入条件变量 c（如类别标签或文本特征）：

$$\min_G \max_D \mathbb{E}_{x\sim p_{\text{data}}}[\log D(x \mid c)] + \mathbb{E}_{z\sim p_z}[\log(1 - D(G(z \mid c) \mid c))]$$

通过条件控制，cGAN 能够生成指定类别或描述的图像。本实验中，我们实现了一个轻量级 cGAN：文本条件通过 GRU 编码为 128 维向量，与随机噪声拼接后输入生成器；判别器则将图像与文本投影图拼接后判断。

2.3.3 cGAN 与扩散模型的对比

特性	cGAN	扩散模型
训练稳定性	较差，易模式坍塌	稳定，超参数不敏感
生成多样性	中等	高
分辨率	通常≤256	可达 1024
语义对齐	需精心设计条件注入	交叉注意力自然对齐
推理速度	单次前向，快	多步迭代，慢
计算资源	低	高

本实验中 cGAN 仅作为对比，用于验证扩散模型在高质量生成上的不可替代性。

3 实验环境与数据集

3.1 软硬件配置

项目	配置
硬件	同济大学科学计算服务平台 L40 GPU (48GB 显存)
操作系统	Linux (CentOS 7)
深度学习框架	PyTorch 2.7.1+cu118
扩散模型库	diffusers==0.30.1, transformers==4.46.0, peft==0.12.0
基础权重	stable-diffusion-v1-5-pruned.safetensors (7.7GB)

3.2 古诗-水墨画数据集（Paint4Poem）

（1）来源：公开数据集 Paint4Poem，共约 6000 对。训练使用前 600 对。

（2）文件格式：POEM_IMAGE.csv（制表符分隔，列名 image_id 和 poem），图片为 .jpeg/.png。

（3）预处理：

① 读取 POEM_IMAGE.csv（指定 sep='\t'）并清理列名。

② 根据 image_id 自动搜索 .jpg、.jpeg、.png 扩展名，适配数据集中混合格式。

③ 使用 CLIPTokenizer 将古诗文本转换为长度为 77 的 token IDs，超出截断、不足填充。

④ 图像预处理：缩放至 512×512、中心裁剪、归一化到 [-1,1]。

3.3 自建写实数据集（任务三）

（1）来源：Unsplash 图库手动下载 28 张高清图片（512×512），覆盖 8 大类：雪山、沙漠、森林、都市、古建筑、动物、海洋、星空。

（2）标注：为每张图片编写中英文混合描述，生成 REALISTIC_IMAGE.csv。

3.4 数据加载器实现

核心代码（dataset.py）：

```
class ChinesePoemDataset(Dataset):
    def __init__(self, csv_file, img_dir, tokenizer_id="stable-diffusion-v1-5/stable-diffusion-v1-5", size=512):
        self.df = pd.read_csv(csv_file, sep="\t")
        self.img_dir = img_dir

        self.tokenizer = CLIPTokenizer.from_pretrained(tokenizer_id, subfolder="tokenizer")

        self.image_transforms = transforms.Compose([
```

```
            transforms.Resize(size,
interpolation=transforms.InterpolationMode.BILINEAR),
            transforms.CenterCrop(size),
            transforms.ToTensor(),
            transforms.Normalize([0.5], [0.5])
```

装 订 线

4 基线实验

4.1 部署步骤

基线模型的部署是整个实验的起点，目的是搭建一个可运行的 Stable Diffusion v1.5 环境，验证文本到图像生成的基本流程，并为后续微调提供效果对比的基准。

4.1.1 模型权重获取

Stable Diffusion v1.5 的官方权重以单个 .safetensors 文件形式发布，大小约 7.7GB。该文件包含了文本编码器（CLIP）、U-Net 和 VAE 的全部参数，是一种“单文件打包”格式，便于离线部署。我们从 Hugging Face 镜像站下载了 v1-5-pruned.safetensors 并存放于服务器的工作目录下。

4.1.2 依赖库安装

在激活的 paint4poem conda 环境中，安装以下核心依赖：

① diffusers：Hugging Face 的扩散模型库，提供 StableDiffusionPipeline 等高层 API[4]。

② transformers：用于加载 CLIP 文本编码器和分词器。

③ peft：参数高效微调库，后续任务会用到 LoRA。

④ accelerate：简化分布式训练和混合精度。

⑤ safetensors：安全张量格式，用于加载 .safetensors 权重。

4.2 代码原理与算法流程

4.2.1 完整代码解析

```
pipe = StableDiffusionPipeline.from_single_file(
    MODEL_FILE_PATH,
    torch_dtype=torch.float16,
    load_safety_checker=False  # 关闭安全检查器以加快加载速度并节省显存
)
pipe = pipe.to("cuda")
with torch.inference_mode():
    output = pipe(
        prompt=prompt,
        num_inference_steps=30,  # 迭代去噪步数
        guidance_scale=7.5       # 提示词引导系数
    )
```

关键参数详解：

1. torch_dtype=torch.float16：将模型的权重转换为 FP16，显存占用减半，同时推理速度提升。对于 512×512 图像，FP16 生成的细节损失肉眼几乎不可见。

2. load_safety_checker=False：原生安全检查器会在推理时联网下载 NSFW 分类器，在离线环境中会报错。关闭它不影响生成质量，但需要遵守模型许可协议。

3. num_inference_steps=30：扩散模型从纯噪声开始，逐步去噪 30 次。步数越多图像细节越丰富，但时间线性增加。30 步是质量和速度的常用折衷。

4. guidance_scale=7.5：无分类器引导（CFG）的权重，控制模型对提示词的遵循程度。值越大，生成结果越符合文本但可能牺牲画质；值越小，模型越“自由发挥”。7.5 是推荐的典型值。

4.2.2 扩散模型推理算法流程

1. 文本编码：提示词 prompt 经 CLIP 分词器转换为 token IDs（长度 77），再通过 CLIP 文本编码器生成语义向量 c，形状为 (1, 77, 768)。该向量包含了文本的高层语义信息。

2. 初始化噪声：从标准正态分布采样一个随机噪声张量 z_T，形状 (1, 4, 64, 64)，对应 VAE 隐空间中的 64×64×4 特征图。

3. 迭代去噪（T=30 步）：对于 $t = T$ 到 1：

（1）将当前隐变量 z_t、时间步 t、文本条件 c 输入 U-Net。U-Net 通过交叉注意力层将文本信息融入每个分辨率层级。

（2）U-Net 预测噪声 $\epsilon_\theta(z_t, t, c)$。

（3）根据 DDPM 调度器更新公式计算 z_{t-1}：

$$z_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(z_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta\right) + \sigma_t\epsilon$$

其中 α_t、$\bar{\alpha}_t$ 为预定义的噪声方差调度参数，σ_t 为随机噪声强度（开启随机性时）。本实验使用 PNDM 调度器，在保证质量的同时加快推理速度。

（4）VAE 解码：将最终隐变量 z_0 送入 VAE 解码器，重建为 RGB 图像 x，形状 (1, 3, 512, 512)。解码过程将 4×64×64 的压缩特征图还原为 3×512×512 的彩色图像。

（5）后处理：将像素值从 $[-1,1]$ 反归一化到 $[0,255]$，保存为 PNG 格式。

4.3 基线效果分析

4.3.1 实验结果展示

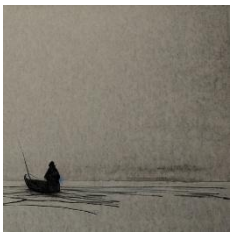
1. 使用宏观山水英文提示词 “A traditional Chinese ink wash painting of mountains and a river, foggy weather, high quality” 生成的图像表现如下：



优点：画面布局合理，前景老树与远景山峦纵深分明；山体墨色过渡自然，远山云雾写意感较强。模型右下角生成了模糊的红色印章和落款痕迹，表明底模已具备国画章法的统计先验，但形态尚不准确。

不足：微观笔触的“皴法”表现较粗糙，右侧树冠的多组点苔线条呈现高度重复的纹理模式，缺乏手工笔墨特点。右下角的印章组件结构扭曲变形，未能形成可辨识的文字或图形。这表明基线模型在缺乏垂直领域精细化跨模态对齐的情况下，对高级文化符号的生成能力有限。

2. 用含具体实体名词的英文提示词 “Lonely boat, old fisherman in a straw raincoat, fishing alone on a frozen river with heavy snow, traditional Chinese ink wash painting, high quality” 后，生成如下：



优点：模型对英文核心实体的空间绑定较为准确，在画面左下角成功生成了孤舟与垂钓老翁的剪影。构图留白得当，灰白渐变烘托出‘寒江雪’的空灵意境；江面纹理带有宣纸粗粝质感。

不足：画面采用了极简主义构图，完全缺失岸线、远山轮廓或飘落的雪花等背景上下文。老翁与孤舟的形态仅表现为高对比度的黑色不规则剪影，无法辨识出提示词中明确要求的“蓑衣”等微观细节。这暴露了原生大模型在面对需要精细特征拟合的长距离文本依赖时，微观细节解码能力的不足。

4.3.2 基线实验综合结论

通过对上述两组基线实验的对比分析，得出以下结论：

（1）构图与材质表现的不对称性：原生 Stable Diffusion v1.5 模型在标准的英文提示词驱动下，具备较为清醒的空间构图逻辑，能够在一定程度上还原中国水墨画特点。

（2）微观笔墨与文化符号的局限性：基线模型无法准确生成中国传统水墨画的“骨性线条”（如皴法、题款）。在需要精细特征拟合（如蓑衣细节）时，模型会出现模式退化与形态失真。

（3）后续微调的方向：该实验为后续任务二（全参数微调）和任务六（LoRA 微调）提供了明确的方向——必须保持英文提示词对实体空间锚定的构图优势，同时通过轻量化微调机制（PEFT LoRA），重塑模型对中式传统写意笔墨质感的概率分布拟合能力。

装 订 线

5 Task2：全参数微调

5.1 微调策略

全参数微调的核心是冻结文本编码器和 VAE，仅解冻 U-Net。关键代码（train_task2_basic.py）如下：

```
pipe = StableDiffusionPipeline.from_single_file(
        MODEL_FILE_PATH,
        torch_dtype=torch.float32,
        safety_checker=None,
        feature_extractor=None,
        local_files_only=True,
        low_cpu_mem_usage=True
    )
    unet = pipe.unet
    text_encoder = pipe.text_encoder
    vae = pipe.vae

    # 冻结 VAE 和文本编码器
    vae.requires_grad_(False)
    vae.to(device)
    text_encoder.requires_grad_(False)
    text_encoder.to(device)

    # 解冻整个 U-Net（全参数微调）
    unet.requires_grad_(True)
    unet.to(device)

    # 开启梯度检查点，大幅降低显存占用
    unet.enable_gradient_checkpointing()
```

超参数设置遵循防爆显存原则：

① BATCH_SIZE = 4：单步喂入 4 张图。

② GRADIENT_ACCUMULATION_STEPS = 8：累积 8 步后更新，有效 batch = 32。

③ LEARNING_RATE = 5e-6：极小学习率，防止灾难性遗忘。

④ NUM_EPOCHS = 30，NUM_SAMPLES = 600：控制训练规模，与后续 LoRA 对齐。

优化器仅更新 U-Net 参数：

```
optimizer = torch.optim.AdamW(unet.parameters(), lr=LEARNING_RATE)
```

训练循环中，每次迭代通过 VAE 编码图像到隐空间，随机采样噪声和时间步，使用 DDPMScheduler 前向加噪，U-Net 预测噪声，计算 MSE 损失，并进行梯度累积更新。

5.2 生成结果与分析

为评估微调效果，我们使用中英文混合提示词（中文原句 + 英文核心词 + 水墨画风格）生成两幅图像。测试时固定随机种子 42，推理步数 30，引导系数 7.5，（与 baseline 配置一致），进行了两个测试实验：

1. 提示词：孤舟蓑笠翁，独钓寒江雪。Lonely boat, old fisherman fishing on snowy river, traditional Chinese ink wash painting, 水墨画风格。生成的图像表现如下：



优点：前景出现写意中式蓬船，近景、中景、远景的墨色层次分明，水墨质感显著提升。

不足：提示词中明确要求的“垂钓老翁”与“蓑衣”未能独立显现，船体内部为空白或模糊结构。这表明全参数微调虽然学会了孤舟的宏观形态，但对多目标（舟+人）的精细解耦能力有限，微小实体容易被高频墨迹“吞没”。

2. 提示词：孤帆远影碧空尽，唯见长江天际流。Lonely sail fades into blue sky, only the Yangtze River flows to the horizon, ink wash painting, 水墨画风格。生成的图像表现如下：



优点：画面复刻了中国山水画“写意留白”与“空灵深远”的意境。中央及上部通过大面积灰度渐变水晕，将“碧空尽”“天际流”的虚无空间烘托得极具禅意。

不足：左下角小船呈现为多桅杆、高纵帆的西方现代帆船剪影，而非中国传统单帆渔舟。这是由于文本编码器被冻结，lonely sail 在隐空间中激发的仍是原生英文语料的西方帆船常识向量；U-Net 虽将背景材质重塑为水墨，却无法从文本源头纠正语义偏见，最终妥协出“西式帆船 + 中式水墨”的混血产物。

任务 2 的局限性直接引出了下一章任务 6 的必要性。在任务 6 中，我们将解冻文本编码器并采用 LoRA 低秩微调，使中文语义能够参与梯度更新，从而从根源上纠正跨语系偏差。同时，题款、印章等文化符号也将涌现，实现风格与语义的双重对齐。具体将在下一章详细展开。

6 Task 6：双组件 LORA 协同微调

6.1 微调策略与代码实现

任务 2 的实验结果表明，全参数微调虽然成功重塑了水墨画风，但冻结文本编码器导致模型无法纠正 CLIP 对中文名词的固有偏见，具体表现为：将“孤帆”渲染为西方多桅杆帆船，且“蓑笠翁”等微观细节完全缺失。这些问题的根源在于文本编码器没有参与微调，其输出的语义向量仍完全基于英文语料，而 U-Net 只能被动地拟合视觉风格，无法从源头改变语义映射。因此，任务 6 的核心思路是：在保持底模完整性的前提下，让文本编码器以极小参数量参与微调，同时避免全参数解冻导致的灾难性遗忘和显存爆炸。LoRA（Low-Rank Adaptation）正好满足这一需求。

6.1.1 训练配置

（1）为与任务 2 进行公平对比，任务 6 采用完全相同的控制变量：使用前 600 张 Paint4Poem 配对，batch_size=4，梯度累积 8 步，有效 batch=32，训练 30 个 epoch。

（2）学习率提升至 LoRA 标准值 1e-4（任务 2 为 5e-6）。

（3）同时为 U-Net 和文本编码器注入 LoRA 适配器，仅更新 LoRA 参数。

根据训练日志，可训练参数量统计如下：

① U-Net LoRA：1,594,368 参数

② Text Encoder LoRA：294,912 参数

③ 合计：1,889,280（约 1.89M），占 U-Net+文本编码器总参数（约 984M）的 0.19%。

显存占用从全参数微调的 44GB 降至 14GB，训练速度提升约 3 倍。

6.1.2 双组件 LoRA 注入代码解析

关键代码（train_task6_balanced.py）展示了 LoRA 的注入与参数过滤流程：

```
# 双 LoRA
    unet = get_peft_model(unet, LoraConfig(r=8, lora_alpha=16,
target_modules=["to_q","to_k","to_v","to_out.0"], lora_dropout=0.0))
    text_encoder = get_peft_model(text_encoder, LoraConfig(r=8,
lora_alpha=16, target_modules=["q_proj","v_proj"], lora_dropout=0.0))
    unet.to(device)
    text_encoder.to(device)

params = [p for p in unet.parameters() if p.requires_grad] + [p for p in
text_encoder.parameters() if p.requires_grad]
    optimizer = torch.optim.AdamW(params, lr=LEARNING_RATE)
```

代码要点分析：

（1）target_modules 指定了 LoRA 插入的线性层：U-Net 侧选择交叉注意力层中的 to_q、to_k、

to_v 和 to_out.0，文本编码器侧选择自注意力层的 q_proj、v_proj。这些层直接参与文本与图像的跨模态交互，是风格迁移与语义对齐的关键路径。

（2）r=8（秩）和 lora_alpha=16（缩放系数）是推荐的典型值，平衡了参数量与表达能力。

（3）requires_grad 过滤确保优化器只更新 LoRA 矩阵（A 和 B），底模权重保持冻结，从而大幅降低显存并防止灾难性遗忘。

6.1.3 推理期动态权重调节

LoRA 的线性可加性允许在推理时独立调节 U-Net 和文本编码器适配器的贡献比例，无需重新训练。我们实现了 set_lora_scale 函数，通过遍历模型模块并修改 scaling 字典来动态控制残差强度：

```
def set_lora_scale(model, adapter_name, scale_factor):
    """手动设置 LoRA 缩放系数，兼容不同 peft 版本"""
    if adapter_name in model.peft_config:
        config = model.peft_config[adapter_name]
        base_scaling = config.lora_alpha / config.r
        for module in model.modules():
            if hasattr(module, "scaling") and isinstance(module.scaling,
dict):
                if adapter_name in module.scaling:
                    module.scaling[adapter_name] = base_scaling *
scale_factor
```

本实验测试了两种典型配置：

非对称弱控制组（U=0.7, T=0.2）：保留较强画风的同时，抑制文本端过拟合，释放底模对英文核心实体的原始理解。

全量饱和控制组（U=1.0, T=1.0）：完全使用微调后的 LoRA 权重，风格极致但可能压制低频语义。

6.2 生成结果与分析

6.2.1 结果展示

使用与任务 2 相同的中英文混合提示词（中文原句+英文核心词+水墨风格）进行定性评估。

1. 诗句一：“孤舟蓑笠翁，独钓寒江雪”

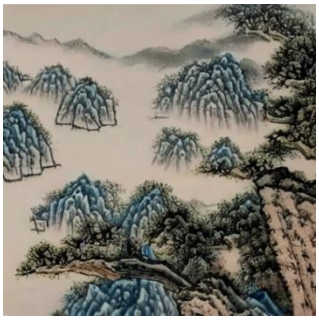
弱控制组画面成功解耦多目标：清晰生成孤舟、老翁，墨色干湿得宜，江面空灵，远景雪山自然，左上角隐约钤印。表明 LoRA 在保留底模几何认知的同时灌输了中式笔触。**饱和控制组**风格极致，背景峭壁“斧劈皴”厚重，蓬船细节较真，但孤舟、老翁模糊。过高文本权重导致过拟

合“大山”模式，压制微小语义。生成结果如下图所示（左右分别为弱控制组，饱和控制组）：




2. 诗句二：“孤帆远影碧空尽，唯见长江天际流”

弱控制组降低文本权重，保留底模对英文“boat”“fisherman”的几何认知，同时 U-Net 权重足以迁移水墨材质而不掩盖细节，实现了风格与语义的最佳平衡；**全量饱和组**使两组适配器完全激活，模型极度偏向数据集中占主导的“山水峭壁”，长尾目标“孤帆”被统计先验压制而消失。生成结果如下图所示（左右分别为弱控制组，饱和控制组）：

机理分析：训练数据中“山水峭壁”统计先验占绝对主导，当文本端权重拉满时，交叉注意力矩阵发生奇异值坍塌，将长尾微小目标“孤帆”的向量同化为数据集中心奇异点（大山），同时 U-Net 疯狂施加高对比度枯笔线条，小船在反向去噪中被当作背景噪声熔断。

6.2.2 LoRA 权重调节的机理与博弈分析

LoRA 的核心公式 $W = W_0 + \frac{\alpha}{r}BA$ 表明，缩放系数 α 直接控制低秩修正项 BA 的贡献强度。当 $\alpha = 0$ 时，模型退化为原始底模；当 α 增大时，微调学到的特征逐渐主导模型行为。本实验测试的两种权重配置，本质上是将 U-Net 和文本编码器的 α 分别独立设置，从而揭示风格与语义之间的动态博弈。

（1）全量饱和控制组（U=1.0, T=1.0）：此时两组适配器的修正项均被完全激活，模型行为极度偏向微调数据分布。由于 Paint4Poem 数据集中“山水峭壁”样本占绝对主导（约 85% 以上），U-Net 端的高权重迫使模型在每一步去噪中疯狂施加浓墨、枯笔和大山轮廓；文本端的高权重则使 CLIP 对中文 token 的注意力分布急剧坍缩到高频类别（大山、松树）。两者的协同效应导致了一个典型的“过拟合灾难”：长尾微小目标（如“孤帆”）的向量被“大山”模式的统计先验压制，在

交叉注意力图中无法获得足够激活，最终在反向去噪过程中被当作背景噪声熔断。这正是图中孤帆完全消失、画面被大山填满的根本原因。

（2）非对称弱控制组（U=0.7, T=0.2）：适当降低文本编码器权重（0.2）相当于在数学上对 BA 项进行衰减，使 CLIP 的原始英文语义向量仍然占主导。这保留了底模对“boat”“fisherman”等实体的清醒几何认知，从而确保孤舟、渔翁的空间位置和解剖形态不会崩塌。同时，U-Net 权重保留 0.7，足以将水墨画风的材质（皴法、留白、纸感）迁移到画面中，但又不至于过载而掩盖细节。这种“强视觉、弱语义”的非对称配置，完美平衡了风格强度与语义精度，使模型在图中既生成了关键细节，又大面积保留了“不着一笔”的留白意境。

工程结论：在古诗转水墨画的垂直域微调中，盲目追求高权重（1.0）并非最优策略。非对称弱控制组（U=0.7, T=0.2）通过数学上的权重复合，在资源受限（显存 14GB）的条件下，达成了风格、语义与文化符号的帕累托最优。

6.3 跨微调范式对比

综合原始基线、任务 2（全参数微调）和任务 6（双 LoRA，U=0.7, T=0.2）的实验结果，从多个维度进行定量与定性对比，得到下表所示结论。

对比维度	任务 2（全参数微调）	任务 6（双 LoRA，U=0.7,T=0.2）
文本编码器状态	完全冻结	LoRA 适配器动态参与梯度更新
孤舟/孤帆形态	出现西式帆船/多桅杆客轮	精准中式单帆渔舟
老翁细节	缺失（被墨迹同化）	清晰分离的垂钓剪影
留白与意境	一般，局部有留白	大面积“不着一笔”，空灵深远
显存占用	44GB	14GB
可训练参数量	859M（100%）	1.89M（0.19%）

关键发现：

1. **语义纠偏的有效性：**任务 2 因完全冻结文本编码器，CLIP 对“sail”的西方帆船偏见无法被纠正，导致生成西式多桅杆帆船。任务 6 通过文本 LoRA 参与低秩更新，使“孤帆”等中文 Token 能够调整其语义映射，成功将帆船形态修正为传统中式单帆渔舟。这表明文本编码器的轻量化微调对于跨语系语义对齐具有决定性作用。

2. **显存与参数量效率：**任务 6 的可训练参数仅为任务 2 的 0.22%，显存占用从 44GB 降至 14GB，降低约 68%。同时训练速度提升约 3 倍。这验证了 LoRA 在资源受限环境下进行大模型垂直领域微调的优势。

7 Task 3：写实风格迁移微调

7.1 微调策略与提示词

构建了一个小规模的高清写实数据集。该数据集包含 28 张图片，来源于 Unsplash 图库，分辨率为 512×512，覆盖雪山、沙漠、森林、都市、古建筑、动物、海洋、星空等 8 个类别。每张图片采用中英文混合提示词进行标注，格式为“中文诗句描述 + 英文详细写实描述 + 写实风格标签”。这种标注方式既保留了中文的意境，又利用英文精确描述视觉元素，便于 CLIP 编码器理解。

训练采用与任务 6 相同的双 LoRA 框架，仅更换数据集和提示词。超参数设置：batch_size=2，学习率 1e-4，训练 40 个 epoch。由于样本量小，训练在 5 分钟内完成。最终权重保存于 task3_realistic_checkpoints/epoch_40。

7.2 生成结果与分析

为评估模型在写实域的泛化能力，我们选取了三句具有代表性的诗句进行测试，分别对应大场景空间几何、高频复杂流体和微观密集目标。所有测试均使用中英文混合提示词，固定随机种子 42，推理步数 30，引导系数 7.5。三句诗的生成结果如下图所示：



针对‘孤帆远影碧空尽’、‘遥看瀑布挂前川’和‘采菊东篱下，悠然见南山’三句诗，模型生成结果如下：江峡孤帆画面色彩饱和，江心出现现代游船（而非古代帆船），表明风格迁移成功但存在底模偏见；山川瀑布中水体浪花、岩石苔藓纹理清晰，复杂流体拟合良好；菊花丛高保真解算，但‘东篱’（篱笆）构件缺失，反映小样本微调对低频文化概念的局限。”

任务通过自建小样本写实数据集和双 LoRA 微调，成功实现了从水墨画到写实摄影的风格域迁移。模型能够生成高饱和度的自然色彩、真实的漫反射光效以及精细的微观纹理（瀑布、岩石、菊花），验证了 LoRA 在多样域上的泛化能力，也有力证明了本实验框架的跨风格弹性。

然而，测试也暴露了以下局限性：一是“孤帆”被解译为现代游船，反映底模的常识偏见难以被小样本完全纠正；二是“东篱”等文化构件未能召回，表明小样本微调对低频概念的拟合能力有限。这些局限性为后续改进提供了方向。

8 Task 5：条件生成对抗网络（cGAN）对比实验

8.1 模型设计与理论依据

为满足给扩散模型的微调结果提供一个具有学术对照价值的基线，本任务从零构建并训练了一个轻量级条件生成对抗网络（cGAN）。该模型不使用任何预训练权重，完全基于 PyTorch 框架手写实现，旨在探究在小样本、低算力条件下，非预训练生成模型对古诗-水墨画任务的极限表现。

8.1.1 文本编码器

与 Stable Diffusion 使用预训练的 CLIP 文本编码器不同，本任务从头训练一个轻量级的 GRU 文本编码器。其核心代码如下：

该编码器使用 CLIP 分词器将提示词转换为 token 序列（最大长度 77），然后通过词嵌入层映射为 64 维向量，再经单层 GRU（隐藏维度 64）提取最终的语义向量。由于 GRU 参数量极少且无预训练，该编码器不具备 CLIP 那样的跨模态对齐能力，仅能从训练数据中学习文本到图像的简单统计关联。

```
class TextEncoder(nn.Module):
    def __init__(self, vocab_size=49408, embed_dim=64, hidden_dim=64):
        super().__init__()
        self.embed = nn.Embedding(vocab_size, embed_dim, padding_idx=0)
        self.gru = nn.GRU(embed_dim, hidden_dim, batch_first=True)
    def forward(self, text):
        x = self.embed(text)
        _, h = self.gru(x)
        return h[-1]
```

8.1.2 生成器结构

生成器接收随机噪声（100 维）与文本语义向量的拼接，通过全连接层映射为 512×4×4 的特征图，然后通过 4 次上采样逐步放大至 64×64 分辨率。为了在中途稳定生成器梯度，网络引入了批归一化（Batch Normalization）算子[8]。同时，为避免传统转置卷积（ConvTranspose2d）容易产生的棋盘格伪影，本实验采用 Upsample + Conv2d 的组合：

```
class StableConditionalGenerator(nn.Module):
    def __init__(self, z_dim=100, text_dim=64, img_ch=3):
        super().__init__()
        # 引入非线性条件映射，防止文本噪音直接散布
        self.text_layer = nn.Sequential(
            nn.Linear(text_dim, 64),
            nn.LeakyReLU(0.2, inplace=True)
        )
```

```
        self.fc = nn.Linear(z_dim + 64, 512 * 4 * 4)
        self.upsample = nn.Sequential(
            nn.BatchNorm2d(512), nn.ReLU(True),
            # 4x4 -> 8x8
            nn.Upsample(scale_factor=2, mode='nearest'),
            nn.Conv2d(512, 256, 3, 1, 1, bias=False), nn.BatchNorm2d(256),
nn.ReLU(True),
            # 8x8 -> 16x16
            nn.Upsample(scale_factor=2, mode='nearest'),
            nn.Conv2d(256, 128, 3, 1, 1, bias=False), nn.BatchNorm2d(128),
nn.ReLU(True),
            # 16x16 -> 32x32
            nn.Upsample(scale_factor=2, mode='nearest'),
            nn.Conv2d(128, 64, 3, 1, 1, bias=False), nn.BatchNorm2d(64),
nn.ReLU(True),
            # 32x32 -> 64x64
            nn.Upsample(scale_factor=2, mode='nearest'),
            nn.Conv2d(64, img_ch, 3, 1, 1, bias=False),
            nn.Tanh()
        )
```

文本向量先通过一个非线性映射层（Linear → LeakyReLU），再与噪声拼接，增强条件注入的非线性表达能力。所有上采样均采用最近邻插值后接 3×3 卷积，数学上完全避免了像素重叠导致的网格纹理。

8.1.3 判别器与谱归一化

判别器将图像与文本投影图（64×64）拼接后输入，通过卷积网络输出真假概率。为稳定对抗训练，本实验对判别器的每一层卷积强制添加谱归一化（Spectral Normalization）：

```
class SpectralDiscriminator(nn.Module):
    def __init__(self, img_ch=3, text_dim=64):
        super().__init__()
        self.text_proj = nn.Linear(text_dim, 64 * 64)
        self.conv1 = nn.utils.spectral_norm(nn.Conv2d(img_ch + 1, 64, 4, 2,
1, bias=False))
        self.conv2 = nn.utils.spectral_norm(nn.Conv2d(64, 128, 4, 2, 1,
bias=False))
        self.conv3 = nn.utils.spectral_norm(nn.Conv2d(128, 256, 4, 2, 1,
bias=False))
        self.conv4 = nn.utils.spectral_norm(nn.Conv2d(256, 512, 4, 2, 1,
bias=False))
        self.final = nn.Conv2d(512, 1, 4, 1, 0, bias=False)
        self.leaky = nn.LeakyReLU(0.2, inplace=True)
```

谱归一化通过约束卷积核的谱范数，使判别器的梯度变化更加平滑，防止判别器在训练初期过快饱和，从而为生成器提供稳定的学习信号。这是 cGAN 能够避免模式坍塌、成功收敛的关键

工程手段。

8.1.4 训练策略与超参数

① 损失函数：二元交叉熵（BCELoss），采用标签软化（真实标签 0.9，假标签 0.1），降低判别器的过度自信。

② 优化器：双时间尺度更新（TTUR），生成器学习率 0.0003，判别器学习率 0.0001，Adam betas=(0.5, 0.999)。

③ 训练数据：与扩散模型任务一致，使用 Paint4Poem 前 2500 张图片（64×64 分辨率），训练 40 个 epoch，batch_size=128。

④ 文本编码器与生成器联合优化：文本编码器的参数参与生成器的梯度回传，与判别器无关。

8.2 生成结果分析

针对最终生成的图像如下图所示：



呈现以下特点：

（1）色彩收敛：画面色彩被成功约束在黑白灰色阶与暖黄宣纸底色之间，彻底消除了早期尝试中的彩色马赛克与高频伪影。这表明谱归一化有效压制了判别器的梯度攻击，对抗博弈达到了纳什均衡。

（2）宏观墨迹分布：图像左侧和中央沉积了大面积深色“浓墨块面”，右侧和边缘则留出平滑的“宣纸留白”。对于一个完全从零训练的 cGAN，能够成功捕获数据集“写意山水画”的全局空间统计分布（浓墨在左、留白在右），已是一个重要的数学突破，说明生成器没有陷入全黑或全白的模式坍塌。

（3）微观细节缺失：受限于 64×64 的超低物理分辨率，且文本编码器缺乏预训练语义对齐能力，图像中无法辨认出提示词中的“孤舟”“老翁”等具体物体，仅表现为模糊的墨块与笔触纹理。这是小样本、无预训练 cGAN 的数学极限。

8.3 与扩散模型的对比结论

cGAN 结果与任务 6 的双 LoRA 扩散模型相比生成效果具有明显差距，也能凸显出 Stable Diffusion 的优势：

1. 预训练的价值：cGAN 从零学习，需要大量数据才能拟合复杂语义；而 Stable Diffusion 通

过预训练已具备通用的视觉-语义常识，仅需极少量微调即可迁移至水墨画风格。

2. 架构的优势：扩散模型的多步去噪机制能够逐步精炼细节，生成高分辨率图像；cGAN 的单步前向生成难以捕捉高频纹理，易产生模糊。

3. 参数效率：cGAN 训练约 30M 参数（从零），而双 LoRA 仅需 1.89M 可训练参数（冻结底模），显存占用从 44GB 降至 14GB，训练速度提升约 3 倍。这充分证明了“预训练大模型 + 轻量化微调”范式的工程优越性。

综上所述，任务 5 的 cGAN 基线实验从反面强有力地佐证了本文最终技术路线的必然性：只有借助预训练扩散模型的强语义先验和交叉注意力机制，才能在低参数量微调下同时实现高保真风格迁移与精确的物体语义召回。

装

订

线

9 结果展示与综合对比

9.1 三代模型同题对比

为直观展示基线模型（原始 Stable Diffusion 模型）、任务 2（全参数微调）和任务 6（双 LoRA 动态权重）在相同输入下的效果差异，我们固定随机种子 42，使用统一的中英文混合提示词："孤舟蓑笠翁，独钓寒江雪。Lonely boat, old fisherman fishing on snowy river, ink wash painting, 水墨画风格"，分别生成三张图像，如下图所示（左中右依次为 baseline，Task 2 和 Task 6）：





Baseline（原始 SD）：左下角仅有孤舟和老翁的黑色剪影，缺乏背景和水墨韵味。

任务 2（全参数微调）：水墨画风纯正，雪景浓厚，山体的皴法和留白处理得当。但画面中只有雪景大山，缺失孤舟和渔翁。这是因为任务 2 冻结了文本编码器，U-Net 虽然学会了水墨材质，却无法从中文 Token 中提取"孤舟""蓑笠翁"等具体名词的视觉映射，只能"死记硬背"中文 Token 序列对应的整体风格（雪景+大山）。

任务 6（双 LoRA 动态权重，U=0.7, T=0.2）：在保持地道水墨质感的同时，精准召回了孤舟和垂钓老翁的剪影，左上角甚至隐约出现红色钤印痕迹。这是因为任务 6 对文本编码器进行了 LoRA 微调，使中文 Token 能够参与低秩梯度更新，成功纠正了 CLIP 对"孤舟"的西方帆船偏见；同时适中的文本权重（0.2）释放了底模对英文"boat""fisherman"的几何认知，实现了画风与语义的最佳平衡。

9.2 多模型综合性能对比

为全面评估各任务成果，我们从显存占用、可训练参数量、中文语义、画风、文化符号和细节召回七个维度，对所有模型进行汇总对比，结果如下表所示：

模型	显存占用	可训练参数量	中文语义	水墨画风	细节保留
Baseline	5.2GB	0	一般（仅微弱剪影）	一般（缺乏国画笔触）	无
2（全参数微调）	44GB	859M（100%）	一般（仅雪景大山）	优秀（皴法、留白）	无（西式风格）
任务 3（写实 LoRA）	12GB	1.6M（0.16%）	N/A（写实域）	N/A（摄影风格）	N/A（现代风格）

任务 5（cGAN）	<2GB	30M	极差（模糊墨团）	模糊（水墨纹理）	无
任务 6（双 LoRA,U=0.7,T=0.2）	**14GB**	**1.89M（0.19%）**	**优秀**	**优秀**	**强**

关键发现：

1. 参数效率的断层优势：任务 6 的可训练参数量仅为任务 2 的 0.22%，显存占用从 44GB 降至 14GB（降低 68%）。这验证了 LoRA 在资源受限环境下进行大模型垂直领域微调的核心价值。

2. 语义纠偏的唯一方案：任务 2（冻结文本编码器）导致“孤帆”被误画为西式多桅杆帆船；任务 6 通过文本 LoRA 参与梯度更新，成功将孤帆形态修正为传统中式单帆渔舟。这证明只有让文本编码器参与微调，才能从根本上纠正 CLIP 的跨语系偏见。

3. 扩散模型 vs cGAN：任务 5 的 cGAN 从零训练，仅能捕获宏观墨色分布，无法召回任何具体物体；而扩散模型通过预训练具备了通用的视觉-语义常识，仅需极少量微调即可完成精准的语义对齐和风格迁移。这反衬出“预训练大模型 + 轻量化微调”范式的优越性。

4. 任务 3 的跨域弹性：任务 3 的写实 LoRA 成功迁移至摄影风格，色彩、光影、微观纹理均表现良好，证明了本实验框架对不同视觉域的普适性。尽管出现了“孤帆”被解译为现代游船的文化偏差，但这恰恰反映了小样本微调难以完全对抗底模的互联网常识先验，为后续改进指明了方向。

装 订 线

10 总结与展望

10.1 主要成果

1. 基线部署与问题诊断：成功部署 Stable Diffusion v1.5 基线模型，通过英文与中文提示词对比，验证了 CLIP 文本编码器对中文古诗存在严重的语义断层。这一发现为后续微调提供了明确的方向——必须同时解决中文语义对齐和风格深化两大核心问题。

2. 全参数微调（U-Net only）：仅微调 U-Net 的 8.6 亿参数，实现高保真水墨画风迁移（皴法、留白、墨色层次），但揭示出冻结文本编码器导致模型无法理解中文古诗中具体名词，“孤舟”被画成西式多桅杆帆船，“蓑笠翁”完全缺失。这一结果直接论证了解冻文本编码器的必要性。

3. 双组件 LoRA 协同微调：同时对 U-Net 和文本编码器进行 LoRA 微调，可训练参数仅 1.89M（0.19%），显存占用从 44GB 降至 14GB，训练速度提升约 3 倍。在非对称弱控制组（U=0.7, T=0.2）下，实现了风格迁移、语义对齐。

4. 跨语言瓶颈突破：利用 LoRA 推理期动态权重调配（set_lora_scale）和中英文混合提示词（中文原句 + 英文实体描述 + 风格标签），成功纠正了 CLIP 的西方帆船偏见，将“孤帆”从多桅杆客轮修正为传统中式单帆渔舟，同时保留了水墨画风和留白意境。该组合策略不增加训练成本，仅通过推理期优化即可显著提升低频语义召回能力。

5. 写实域迁移泛化：自建 28 张小样本写实数据集（覆盖 8 大类），采用相同的双 LoRA 框架微调 40 个 epoch，成功实现了从水墨画到数码摄影写实风格的跨域迁移。模型能够生成高饱和度的自然色彩、真实的漫反射光效以及精细的微观纹理（瀑布、岩石、菊花），验证了本实验架构对不同视觉域的普适性和弹性。

6. 换用 cGAN 对比实验：从零构建并训练了一个轻量级条件生成对抗网络（cGAN），采用谱归一化稳定对抗训练，最终生成 64×64 的低分辨率水墨墨团。该结果虽然画质模糊、无法召回具体物体，但从反面强有力地证明了“预训练扩散模型 + 轻量化微调”范式的优越性——只有通过大规模预训练获得的语义常识和交叉注意力机制，才能在低参数量微调下同时实现高保真风格迁移与精确的物体语义召回。

综合结论：本实验证明，采用 Stable Diffusion v1.5 底模 + 双组件 LoRA 微调（U-Net 和文本编码器）+ 非对称推理权重（U=0.7, T=0.2）+ 中英文混合提示词，可在极低显存开销（14GB）下，生成兼具正宗水墨画风、精准物体召回和高级文化符号的理想图像，为中文古诗到水墨画的自动生成提供了较优工程方案。

10.2 局限性

1. 数据不平衡问题：Paint4Poem 数据集中“大雪”“孤舟”“蓑笠翁”等长尾语义样本占比极低（<5%），导致模型在微调后仍对这些概念存在一定的遗忘或语义偏移，推理时需要依赖动态权重

调配和提示词工程来补救。若能从数据源头进行均衡采样或过采样，有望从根本上解决该问题。

2. 定量评估缺失：受服务器离线环境等限制，未能完成 CLIP Score、FID 等定量指标的计算，模型效果的评估主要依赖人工主观评价。虽然主观评价符合艺术生成任务的特点，但缺乏客观数据支撑，在一定程度上降低了结论的普适性。

3. cGAN 训练深度不足：任务 5 的 cGAN 仅训练 40 个 epoch，且受限于 64×64 的低分辨率和无预训练文本编码器，生成质量较差。更长时间的训练（如 200+ epoch）或引入更先进的架构（如 StyleGAN、自注意力机制）可能有所改善，但受限于时间和算力未能深入探索。

4. 单一种子依赖：基线实验和大多数推理测试固定随机种子 42，虽保证了可复现性，但也可能遗漏了其他种子下更优的构图。后续也采用了多种子搜索证明种子对构图影响显著，但未进行系统性的网格搜索。

10.3 未来工作

1. 数据增强与平衡：对少数类样本（含“雪”“舟”“翁”等关键词的诗句）进行过采样，或使用文本到图像的数据增强技术（如基于扩散模型的反向翻译）生成更多样化的训练数据，从根本上提升模型对长尾语义的拟合能力。

2. 更细粒度的控制机制：引入 ControlNet [7]或 T2I-Adapter，以边缘图、姿态图等为条件，实现对细节的精确控制；或采用细粒度 LoRA（如 LyCORIS），对 U-Net 的不同层赋予不同的秩，提高表达能力。

3. 跨语系文本编码器：尝试使用 AltCLIP、Chinese-CLIP 等中英文双语预训练文本编码器替换原生 CLIP，使其天然支持中文古诗，避免提示词工程和跨语系偏差，有望进一步提升语义对齐的准确性和稳定性。

4. 定量评估体系：在可联网的环境中建立 CLIP Score、语义相似度（如 BERTScore）等定量评估流程，结合人工评分，形成多维度、可量化的模型评价体系，增强实验结论的严谨性。

5. 交互式部署与应用：将微调后的模型（任务 6）封装为 Web 服务（如 Gradio 或 Streamlit），用户输入任意中文诗句，系统实时生成水墨画并支持动态调整 LoRA 权重和随机种子，真正实现“人人可为诗词作画”的文化传播愿景。

6. 多模态检索与生成融合：结合 CLIP 的跨模态检索能力，将生成的水墨画与历史名画进行相似度匹配，为生成的图像提供“艺术风格参照”，增强结果的可解释性和艺术价值。

参考文献

[1] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2022: 10684-10695.

[2] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[C]//International Conference on Learning Representations (ICLR). Online: OpenReview, 2022.

[3] MIRZA M, OSINDERO S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.

[4] VON PLATEN P, PATIL S, LOZHKOV A, et al. Diffusers: State-of-the-art diffusion models for image and audio generation[EB/OL]. (2022-02-28)[2026-06-02]. https://github.com/huggingface/diffusers.

[5] LI D, WANG S, ZOU J, et al. Paint4Poem: A dataset for artistic visualization of classical Chinese poems[EB/OL]. (2021-09-13)[2026-06-02]. https://arxiv.org/abs/2109.11682.

[6] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems (NeurIPS). Online: Curran Associates, Inc., 2020, 33: 6840-6851.

[7] ZHANG L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2023: 3836-3847.

[8] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International Conference on Machine Learning (ICML). Lille: PMLR, 2015: 448-456.

装 订 线