

同济大学
TONGJI UNIVERSITY

人工智能

-大模型及其应用

目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

大模型的概念

大模型通常指的是大规模的人工智能模型，是一种基于深度学习技术，具有海量参数、强大的学习能力和泛化能力，能够处理和生成多种类型数据的人工智能模型

通常说的大模型的“大”的特点体现在：**参数数量庞大、训练数据量大、计算资源需求高**

2020年，OpenAI公司推出了GPT-3，模型参数规模达到了1750亿，2023年3月发布的GPT-4的参数规模是GPT-3的10倍以上，达到1.8万亿，2021年11月阿里推出的M6 模型的参数量达10万亿

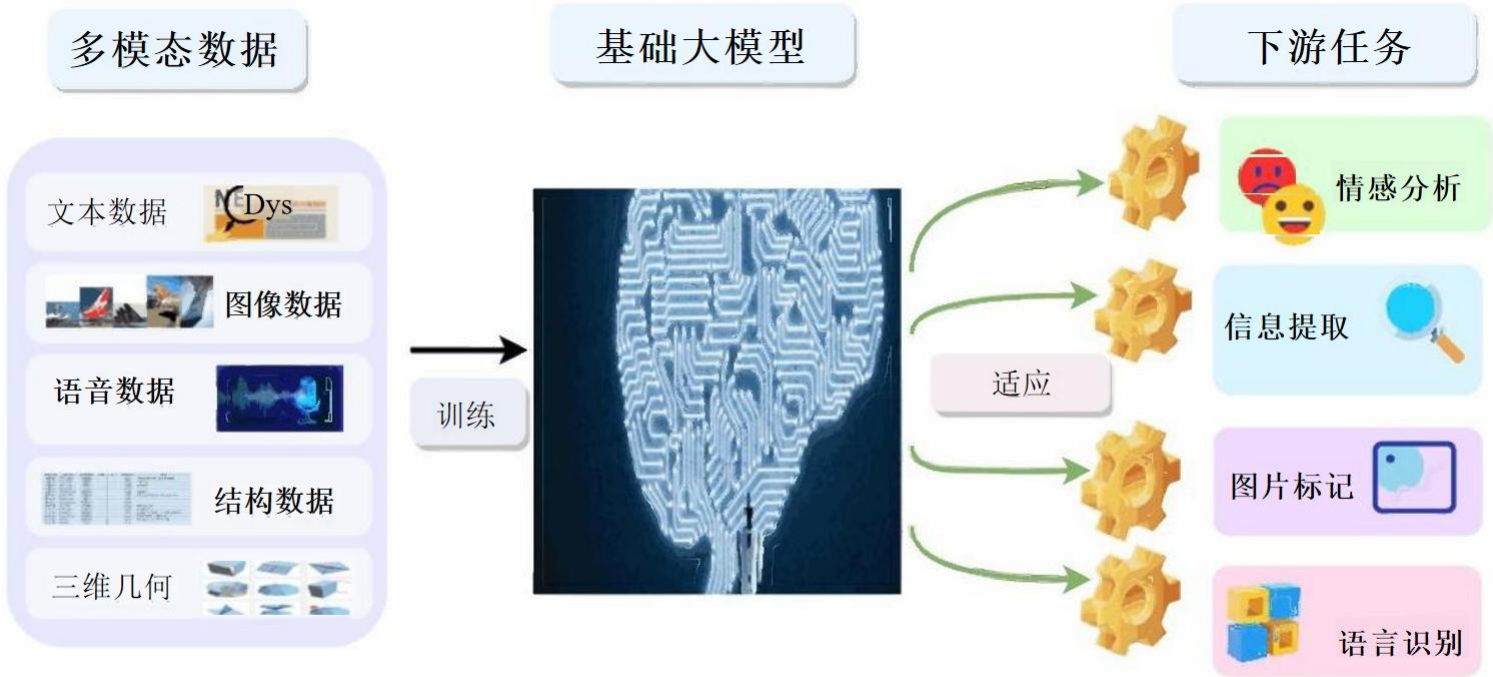





大模型的概念

大模型是通过“大数据+大算力+强算法”相结合来模拟人类思维和创造力的人工智能算法





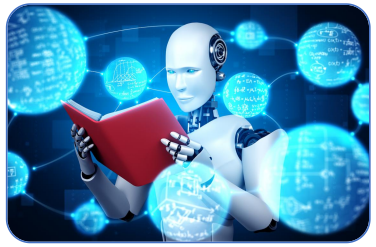
大模型是一种全新的AI基础范式

大模型的概念

大模型的设计和训练旨在提供更强大、更准确的模型性能，以应对更复杂、更庞大的数据集或任务。大模型通常能够学习到更细微的模式和规律，具有更强的泛化能力和表达能力

上下文理解能力

大模型具有更强的上下文理解能力，能够理解更复杂的语意和语境。这使得它们能够产生更准确、更连贯的回答



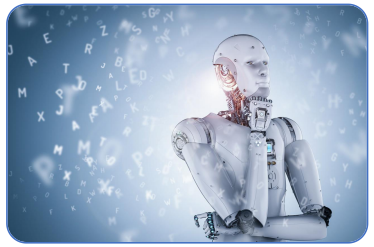
语言生成能力

大模型可以生成更自然、更流利的语言，减少了生成输出时呈现的错误或令人困惑的问题



学习能力强

大模型可以从大量的数据中学习，并利用学到的知识和模式来提供更精准的答案和预测。这使得它们在解决复杂问题和应对新的场景时表现更加出色



可迁移性高

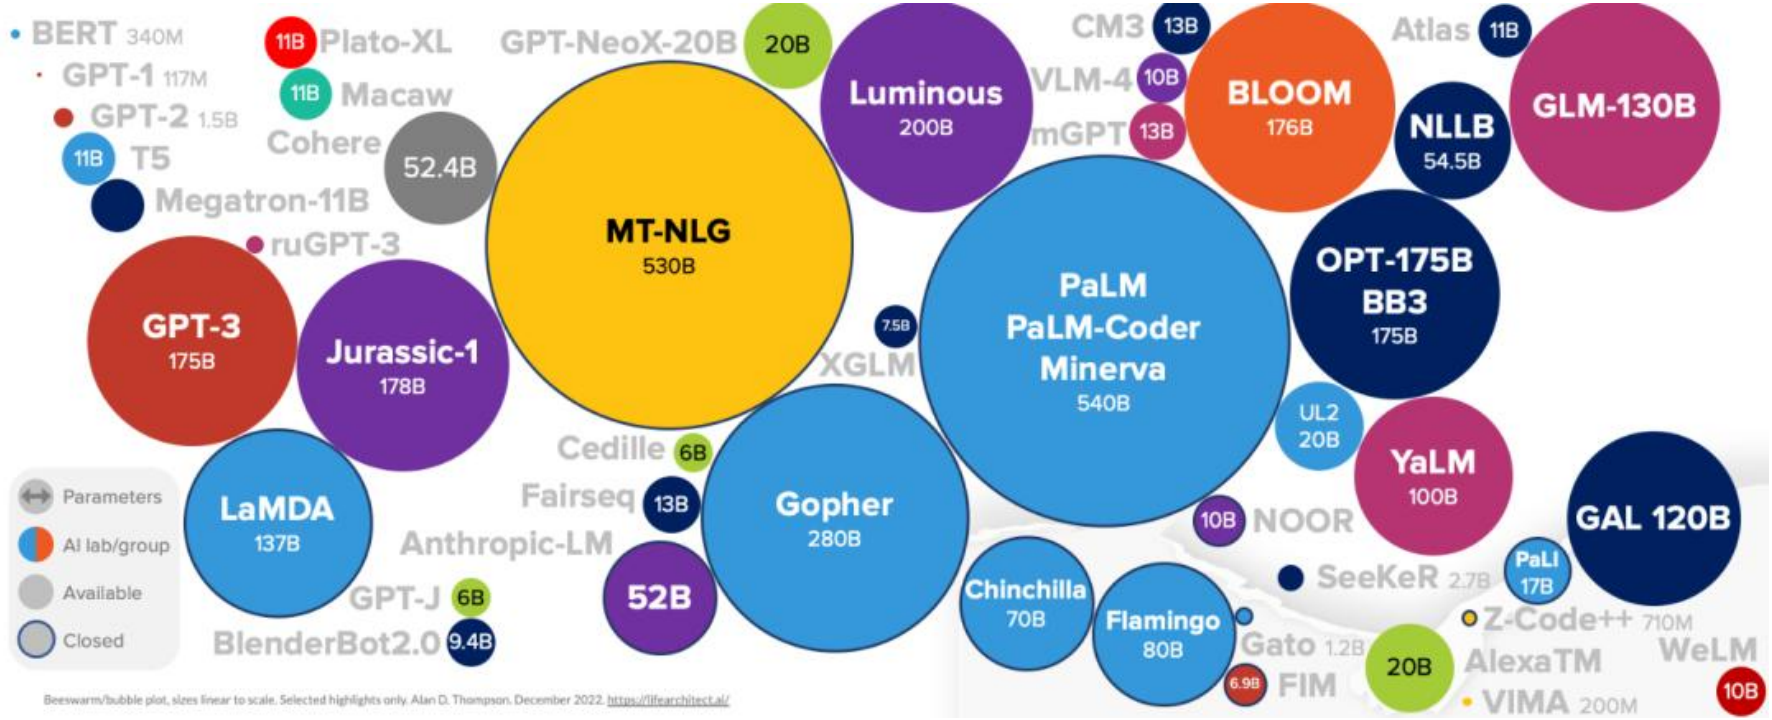
学习到的知识和能力可以在不同的任务和领域中迁移和应用。这意味着一次训练就可以将模型应用于多种任务，无需重新训练



大模型的特点

（1）巨大的规模

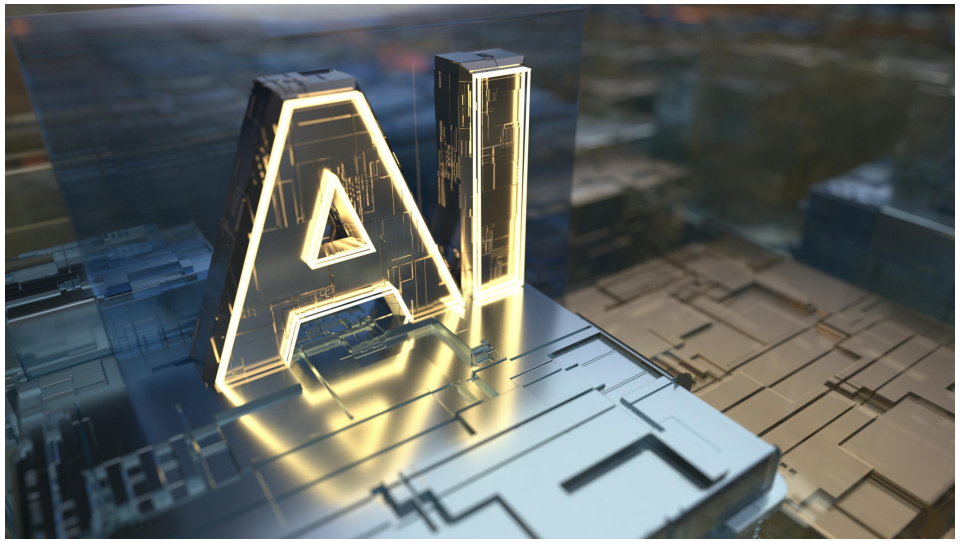
大模型通常包含数十亿个参数，模型大小可以达到数百GB甚至更大。这种巨大的规模不仅提供了强大的表达能力和学习能力，还使得大模型在处理复杂任务时具有更高的效率和准确性

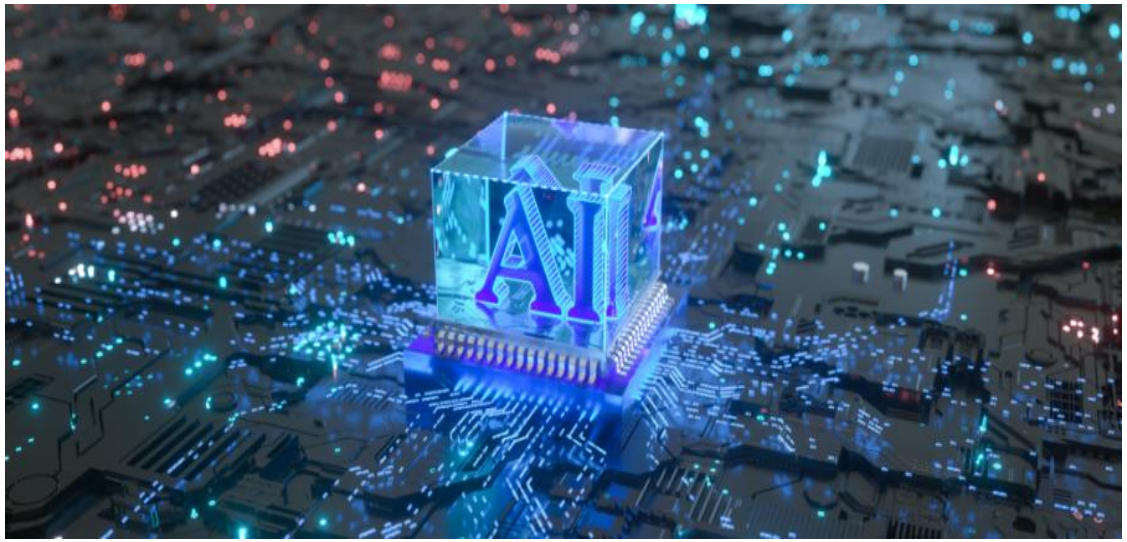


大模型的特点

（2）涌现能力

涌现能力是指模型在训练过程中突然展现出之前小模型所没有的、更深层次的复杂特性和能力。当模型的训练数据突破一定规模时，模型性能显著提升，表现出让人惊艳、意想不到的能力，展现出类似人类的思维和智能。**这种涌现能力是大模型最显著的特点之一，也是其超越传统模型的关键所在**





大模型的特点

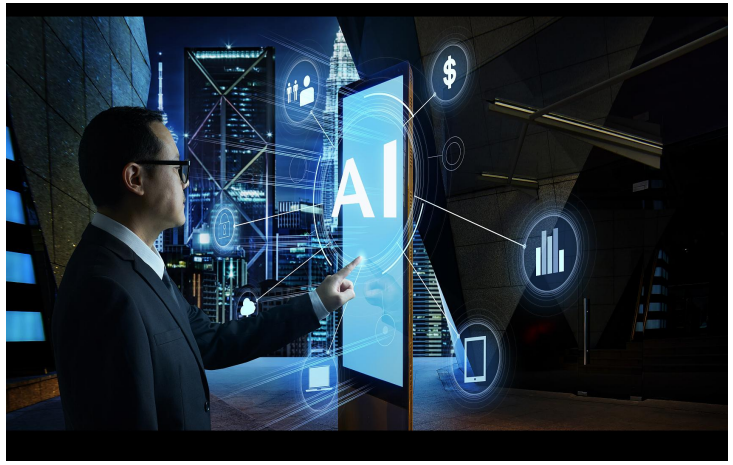
（3）更好的性能和泛化能力

大模型因其巨大的规模和复杂的结构，展现出更出色的性能和泛化能力。它们在各种任务上都能表现出色，超越了传统的小模型。**这主要归功于大模型的参数规模和学习能力**。大模型能够更好地理解和模拟现实世界中的复杂现象，从而在各种任务中表现出更高的准确性和效率。它们能够捕捉到数据中的微妙差异和复杂模式，使得在未见过的数据上也能表现优秀，即具有良好的泛化能力



（4）多任务学习

大模型的多任务学习特点使其能够同时处理多种不同的任务，并从中学习到更广泛和泛化的语言理解能力。通过多任务学习，大模型可以在不同的NLP（Natural Language Processing）任务中进行训练，例如机器翻译、文本摘要、问答系统等。**这种多任务学习的方式有助于大模型更好地理解和应用语言的规则和模式**



大模型的特点

（5）大数据训练

大模型需要大规模的数据来训练，通常在TB级别甚至PB级别。这是因为大模型拥有数亿甚至数十亿的参数，需要大量的数据来提供足够的信息供模型学习和优化。只有大规模的数据才能让大模型的参数规模发挥优势，提高模型的泛化能力和性能。同时，大数据训练也是保证大模型能够处理复杂任务的关键。通过使用大规模数据，大模型能够更好地理解数据中的复杂模式和关系，从而更好地模拟现实世界中的各种现象



（6）强大的计算资源

大模型需要强大的计算资源来训练和运行。由于模型规模庞大，参数数量众多，计算复杂度极高，因此需要高性能的硬件设备来支持。通常，训练大模型需要使用GPU（Graphics Processing Unit，图形处理器）或TPU（Tensor Processing Unit，张量处理器）等专用加速器来提高计算效率。这些加速器能够并行处理大量的参数和数据，使得大模型的训练和推断速度更快。除了硬件设备，大模型的训练还需要大量的时间。由于模型参数众多，训练过程中需要进行大量的迭代和优化，因此，训练周期可能长达数周甚至数月



大模型的特点

（7）迁移学习和预训练

通过在大规模数据上进行预训练，大模型能够学习到丰富的语言知识和模式，从而在各种任务上展现出卓越的性能。迁移学习和预训练有助于大模型更好地适应特定任务

在特定任务的数据上进行微调

在大规模数据上进行预训练后，大模型可以在特定任务的数据上进行微调，从而更好地适应目标任务的特性和要求。这种微调过程可以帮助大模型更好地理解和处理目标任务的特定问题，进一步提高模型的性能

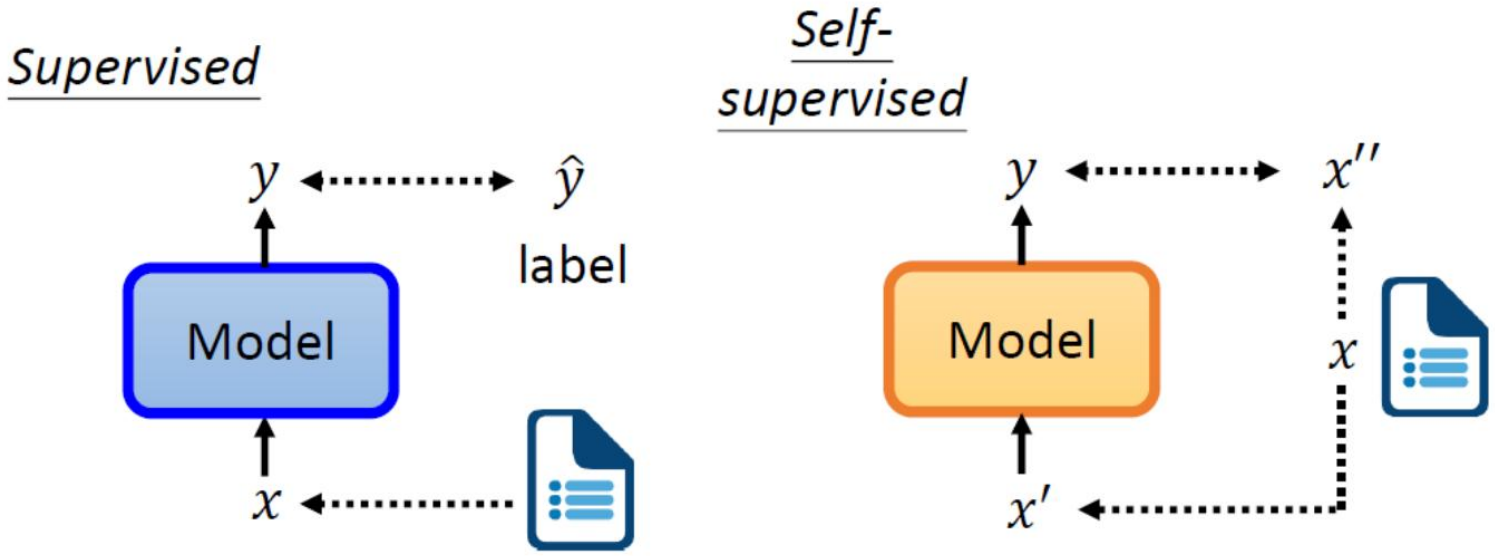
跨领域的应用能力

迁移学习和预训练也有助于大模型实现跨领域的应用。通过在多个领域的数据上进行预训练，大模型可以学习到不同领域的知识和模式，并在不同领域中进行应用。这种跨领域的应用能力，有助于大模型更好地服务于实际需求，推动人工智能技术的创新和发展

大模型的特点

（8）自监督学习

自监督学习利用大规模未标记数据进行训练，通过从数据中挖掘内在的规律和模式，使模型能够自动地理解和预测数据中的信息。在大规模的未标记数据中，大模型通过预测输入数据的标签或下一个时刻的状态来进行训练。这种训练方式使得大模型能够从大量的数据中自动地学习到语言的内在结构和模式，而不需要人工标注和干预

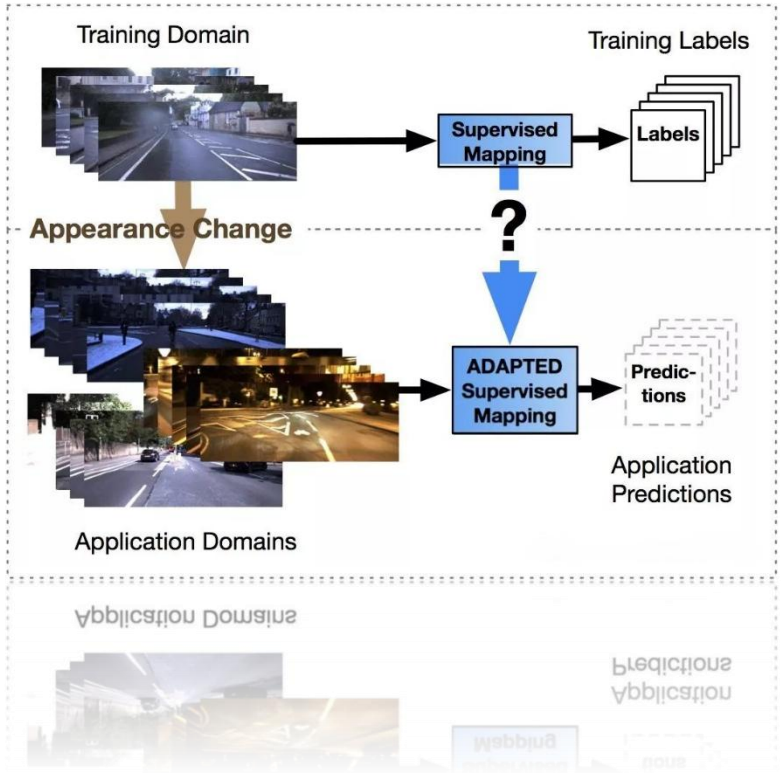


大模型的特点

（9）领域知识融合

大模型通过领域知识融合，能够将不同领域的数据和知识融合在一起，从而更好地模拟现实世界中的复杂现象

领域知识融合使得大模型能够从多个领域中学习到广泛的知识和模式，并将这些知识和模式整合到统一的框架中



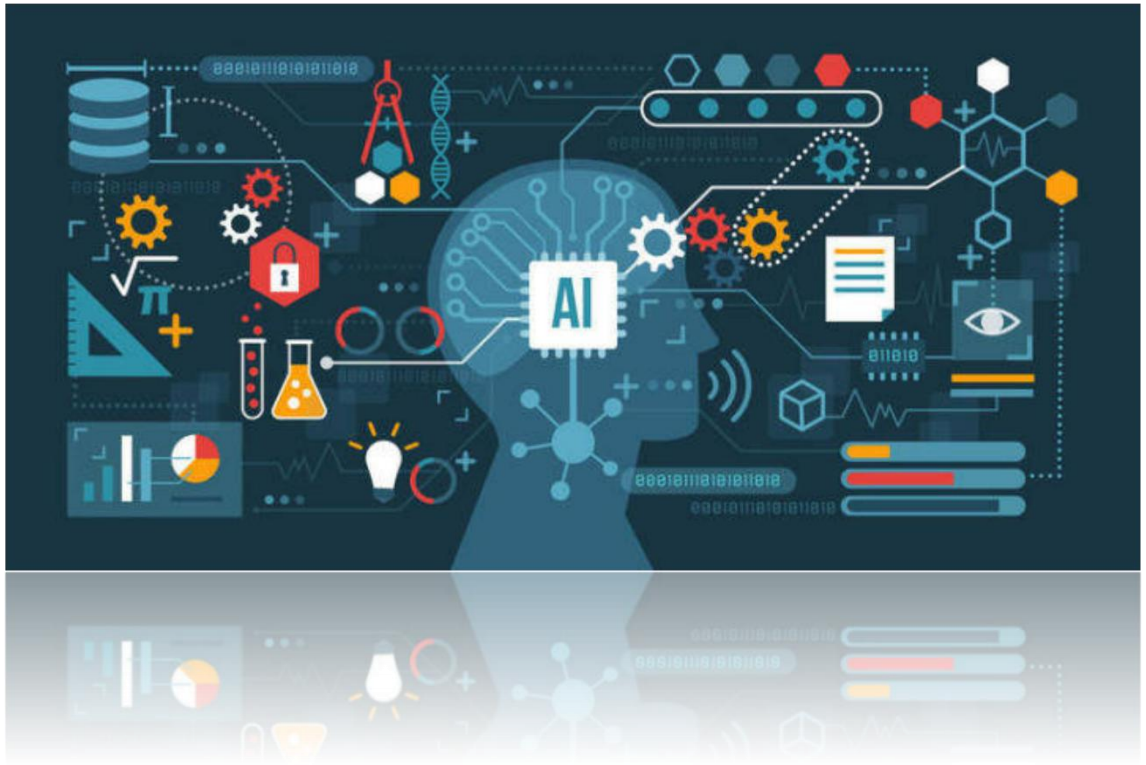


大模型的特点

（10）自动化和效率

大模型在应用中展现出高度的自动化和效率。由于大模型具有强大的表达能力和学习能力，它可以自动化许多复杂的任务，大大提高工作效率。大模型通过预训练和微调过程，能够自动地适应特定任务，而不需要过多的手工调整和干预。这使得大模型能够快速地应用于各种实际场景，并且自动地处理复杂的任务，如自动编程、自动翻译、自动摘要等



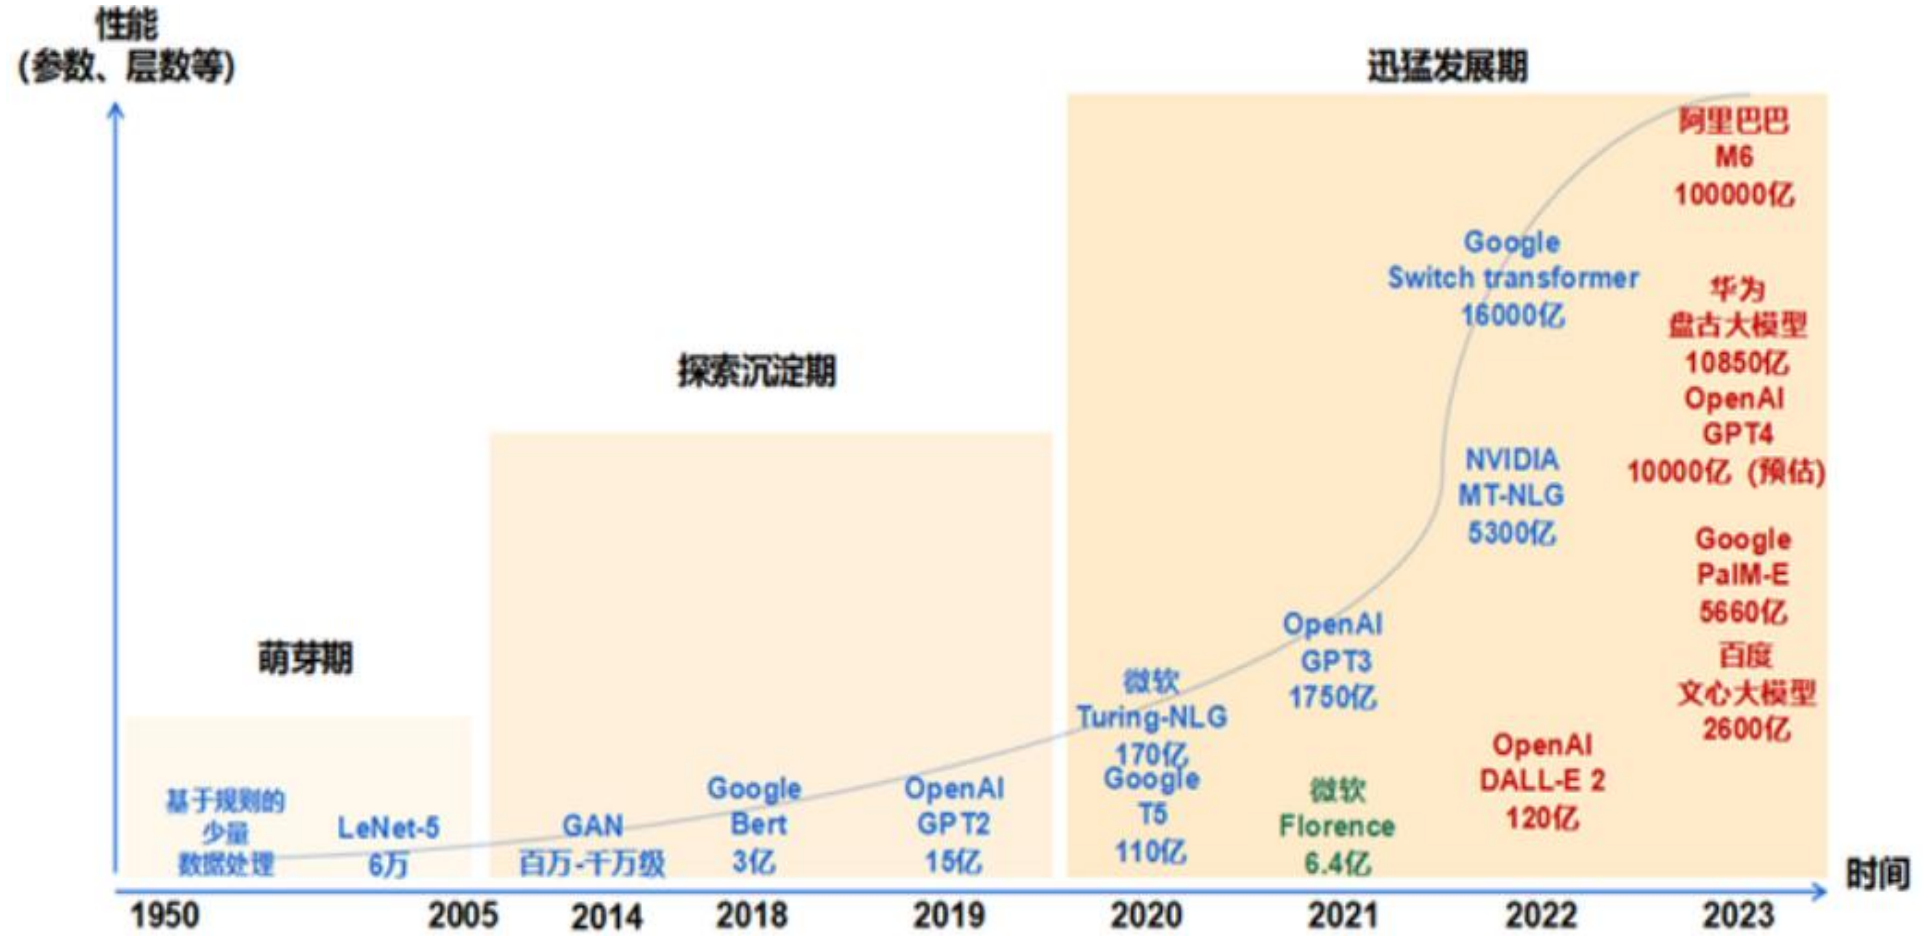


目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

大模型的发展历程

大模型发展历经三个阶段，分别是萌芽期、沉淀期和爆发期

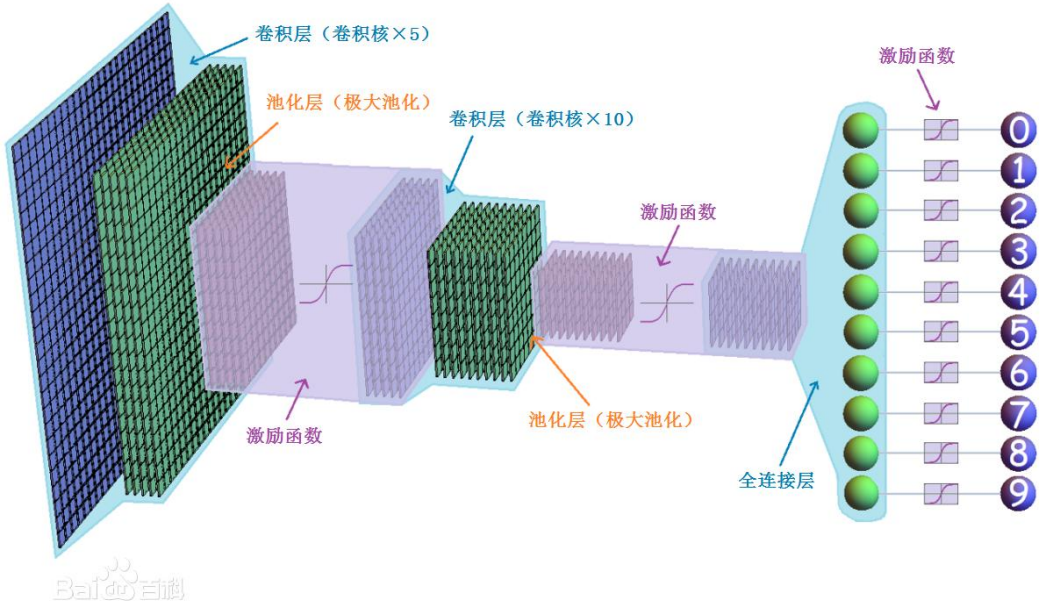


大模型的发展历程

■ 萌芽期（1950-2005）

这是一个**以CNN（Convolutional Neural Networks，卷积神经网络）为代表的传统神经网络模型阶段**

- 1956年，从计算机专家约翰·麦卡锡提出“人工智能”概念开始，AI发展由最开始基于小规模专家知识逐步发展为基于机器学习
- 1980年，卷积神经网络的雏形CNN诞生
- 1998年，现代卷积神经网络的基本结构LeNet-5诞生，机器学习方法由早期基于浅层机器学习的模型，变为了基于深度学习的模型，为自然语言生成、计算机视觉等领域的深入研究奠定了基础，对后续深度学习框架的迭代及大模型发展具有开创性的意义



大模型的发展历程

■ 沉淀期（2006-2019）

这是一个**以Transformer为代表的全新神经网络模型阶段**

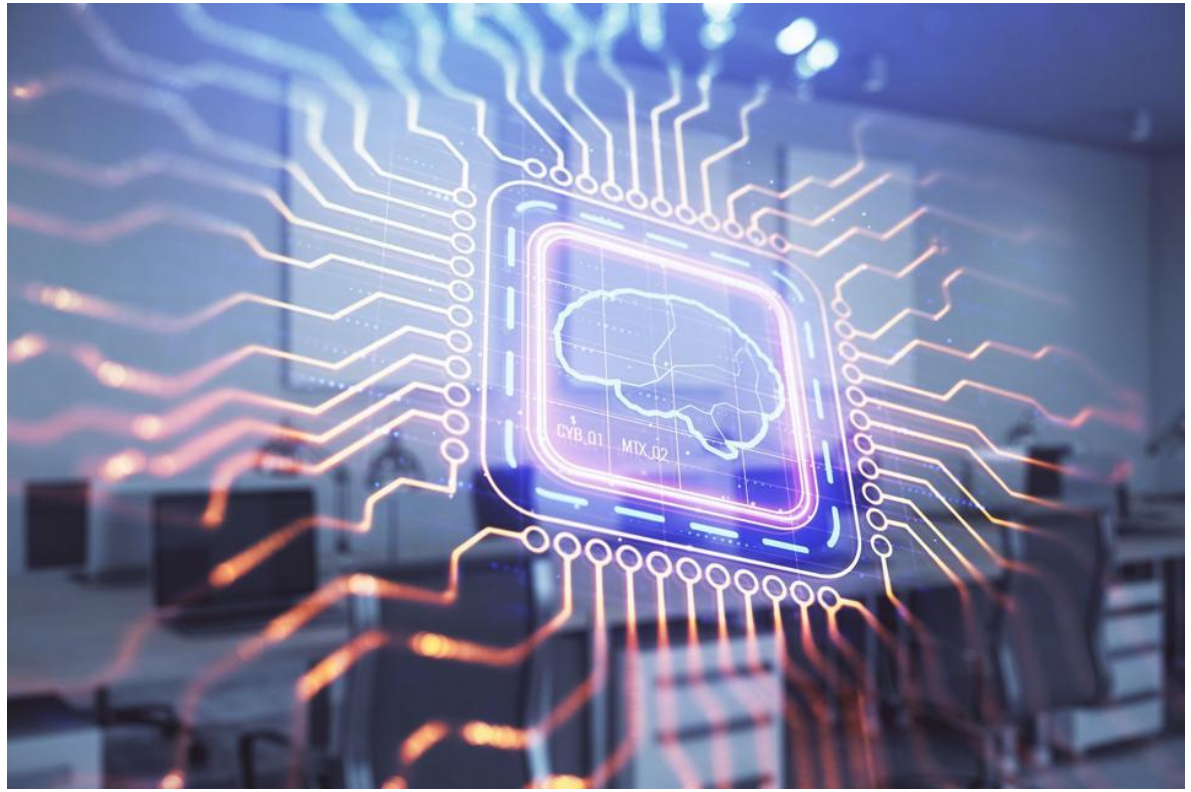
2013年，自然语言处理模型 Word2Vec诞生，首次提出将单词转换为向量的“词向量模型”，以便计算机更好地理解和处理文本数据。

2014年，被誉为21世纪最强大算法模型之一的GAN（Generative Adversarial Networks，对抗式生成网络）诞生，标志着深度学习进入了生成模型研究的新阶段

2017年，Google颠覆性地提出了基于自注意力机制的神经网络结构——Transformer架构，奠定了大模型预训练算法架构的基础

2018年，OpenAI基于Transformer架构发布了GPT-1大模型，意味着预训练大模型成为自然语言处理领域的主流，其中，GPT的英文全称是Generative Pre-Trained Transformer，是一种基于互联网的、可用数据来训练的、文本生成的深度学习模型

2019年，OpenAI发布了GPT-2



大模型的发展历程

■ 爆发期（2020-至今）

这是一个以GPT为代表的预训练大模型阶段

2020年6月，OpenAI公司推出了GPT-3，模型参数规模达到了1750亿，成为当时最大的语言模型，并且在零样本学习任务上实现了巨大性能提升。随后，更多策略如基于人类反馈的强化学习（RLHF，Reinforcement Learning from Human Feedback）、代码预训练、指令微调等开始出现，被用于进一步提高推理能力和任务泛化

2022年11月，搭载了GPT3.5的ChatGPT（Chat Generative Pre-trained Transformer）横空出世，凭借逼真的自然语言交互与多场景内容生成能力，迅速引爆互联网，在全球范围内引起轰动，使得大模型的概念迅速进入普通大众的视野。ChatGPT是人工智能技术驱动的自然语言处理工具，它能够通过理解和学习人类的语言来进行对话，还能根据聊天的上下文进行互动，真正像人类一样来聊天交流，甚至能完成撰写邮件、视频脚本、文案、翻译、代码，写论文等任务



大模型的发展历程

■ 爆发期（2020-至今）

OpenAI在2023年3月发布了GPT-4，它是一个多模态大模型（接受图像和文本输入，生成文本）。相比上一代的GPT-3，GPT-4可以更准确地解决难题，具有更广泛的常识和解决问题的能力。2023年12月，谷歌发布大模型Gemini，它可以同时识别文本、图像、音频、视频和代码五种类型信息，还可以理解并生成主流编程语言（如Python、Java、C++）的高质量代码，并拥有全面的安全性评估。2024年12月，DeepSeek迅速崛起，震撼全球，使得人工智能进入“普惠”时代



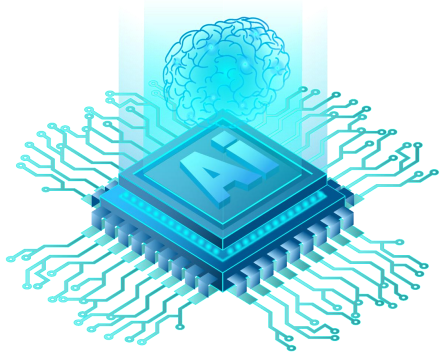


目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

大模型的关键技术

大模型是基于Transformer架构的，这种架构是一种专门用于自然语言处理的“编码-解码器”架构。在训练过程中，大模型将输入的单词以向量的形式传递给神经网络，然后通过网络的编码解码以及自注意力机制，建立起每个单词之间联系的权重。大模型的核心能力在于将输入的每句话中的每个单词与已经编码在模型中的单词进行相关性的计算，并把相关性又编码叠加在每个单词中。这样，大模型能够更好地理解和生成自然文本，同时还能够表现出一定的逻辑思维和推理能力



大模型

基于深度学习

利用



大量的数据和计算资源

训练



具有大量参数的
神经网络模型

不断地调整

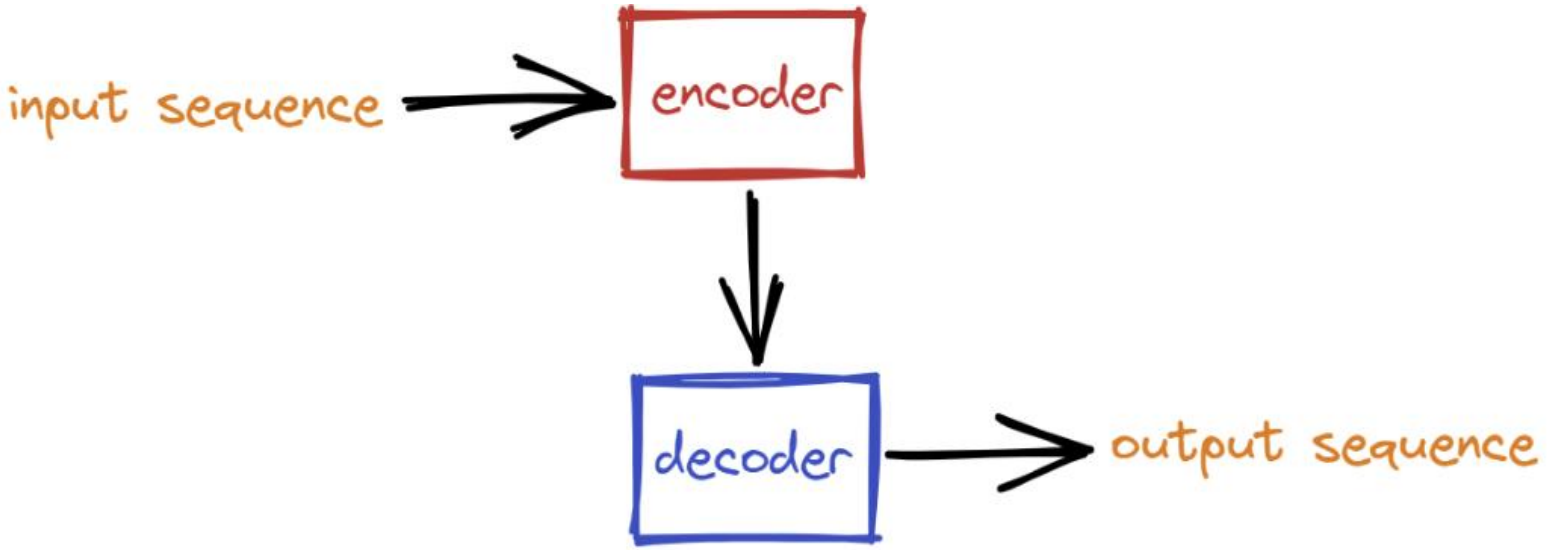
模型参数

模型能够在各种任务中取得最佳表现

大模型的关键技术

■ Transformer

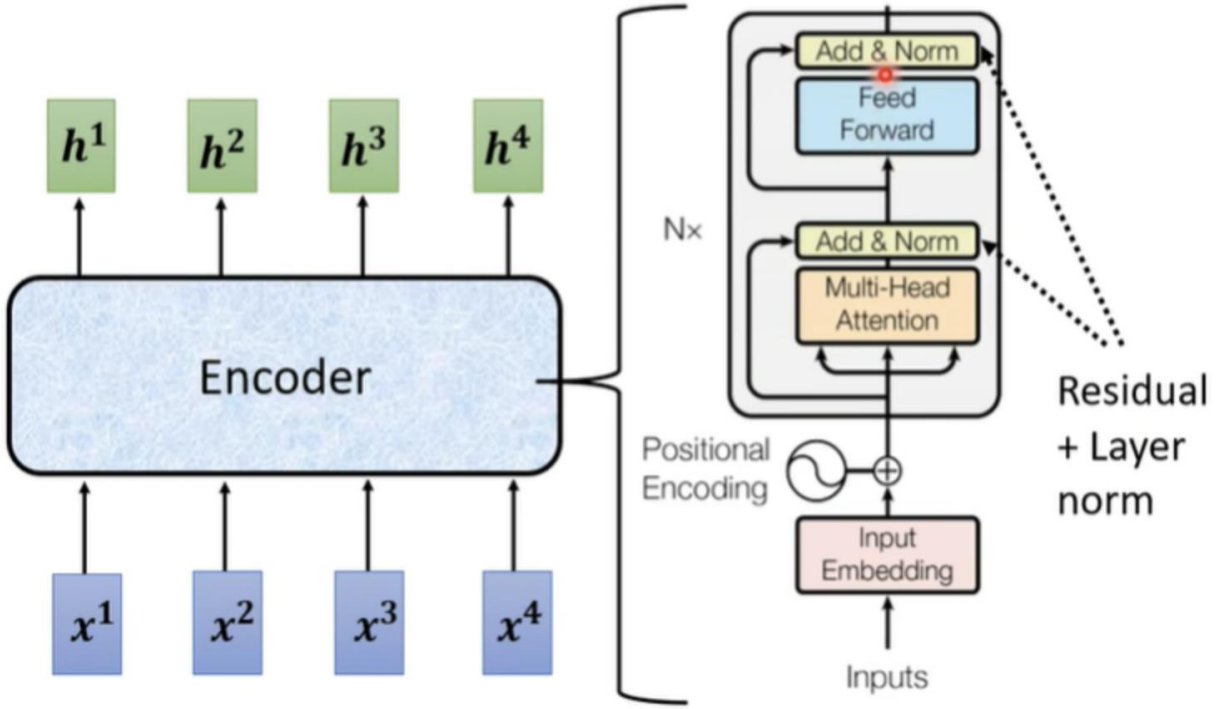
Transformer是“编码器—解码器”架构，由编码器(encoder)和解码器(decoder)组成，其都是多头自注意力模块的叠加。其中，input sequence分成两部分，分别为源(input)输入序列和目标(output)输出序列。前者输入编码器，后者输入解码器，两个序列均需进行embedding表示并加入位置信息。



大模型的关键技术

■ Transformer

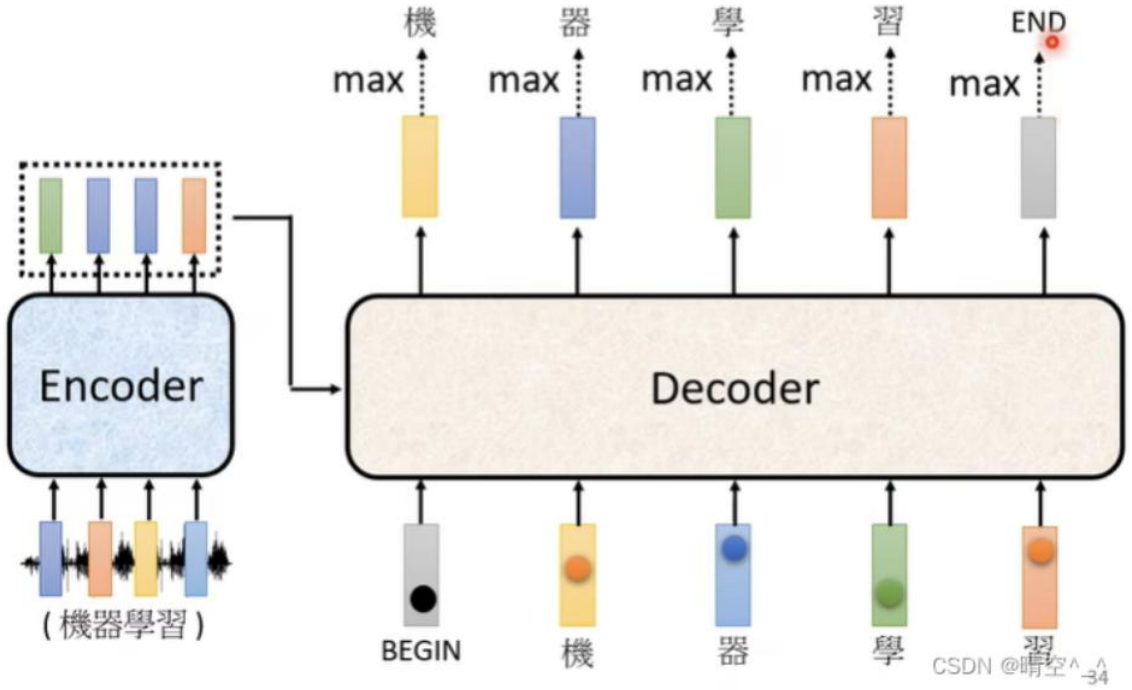
Transformer编码器由多个相同的层叠加而成，每个层都有两个子层(sublayer)，第一个是多头自注意力(multi-head self-attention)汇聚；第二个子层是基于位置的前馈神经网络。每个子层都采用了残差链接。



大模型的关键技术

■ Transformer

解码器接入编码器最后的输出向量。假设编码器学习的序列是“机器学习”。当解码器接收到[BEGIN]Token时会产生第一个字符“机”，之后由产生的第一个字符“机”产生第二个字符“器”，之后由前两个字符“机器”产生第三个字符“机器学”，之后由产生的前三个字符生成“习”，之后由产生的前四个字符产生[END]token，序列生成结束。



Transformer

Attention注意力机制在介绍什么是注意力机制之前先让大家看一张图片。当大家看到下面图片，会首先看到什么内容?当过载信息映入眼帘时，我们的大脑会把注意力放在主要的信息上，这就是大脑的注意力机制。



大模型的关键技术

■ Transformer

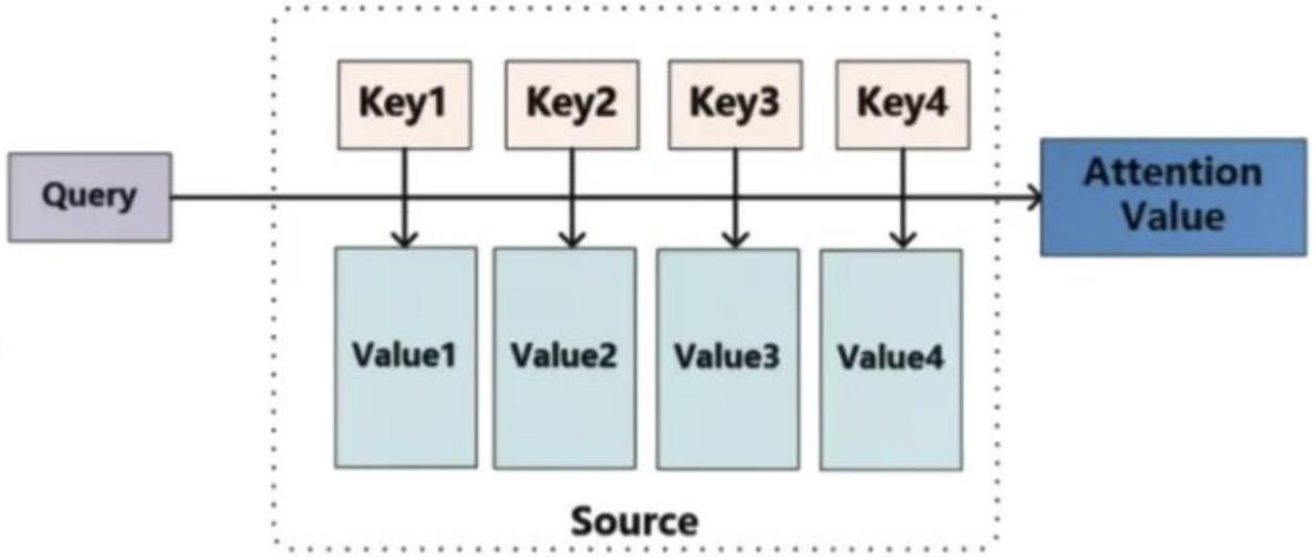
每个词的Attention计算

每个词的Q会跟整个序列中每一个K计算得分，然后基于得分再分配特征

Q: query，要去查询的

K: key，等着被查的

V: value，实际的特征信息



大模型的关键技术

■ Transformer自注意力例子

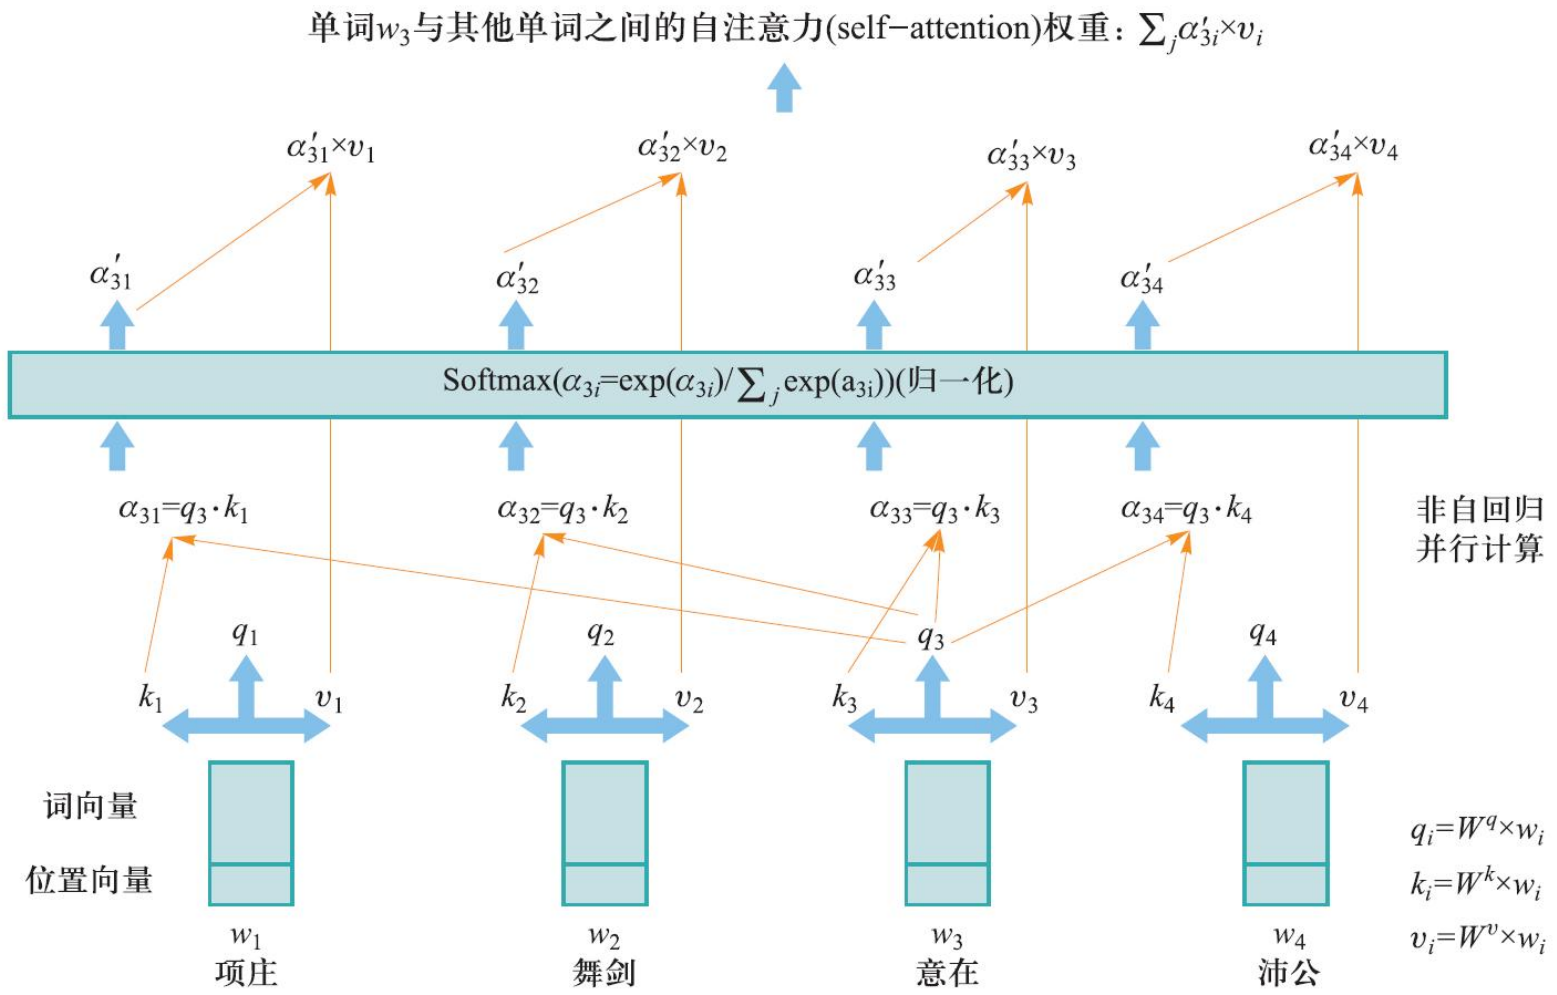
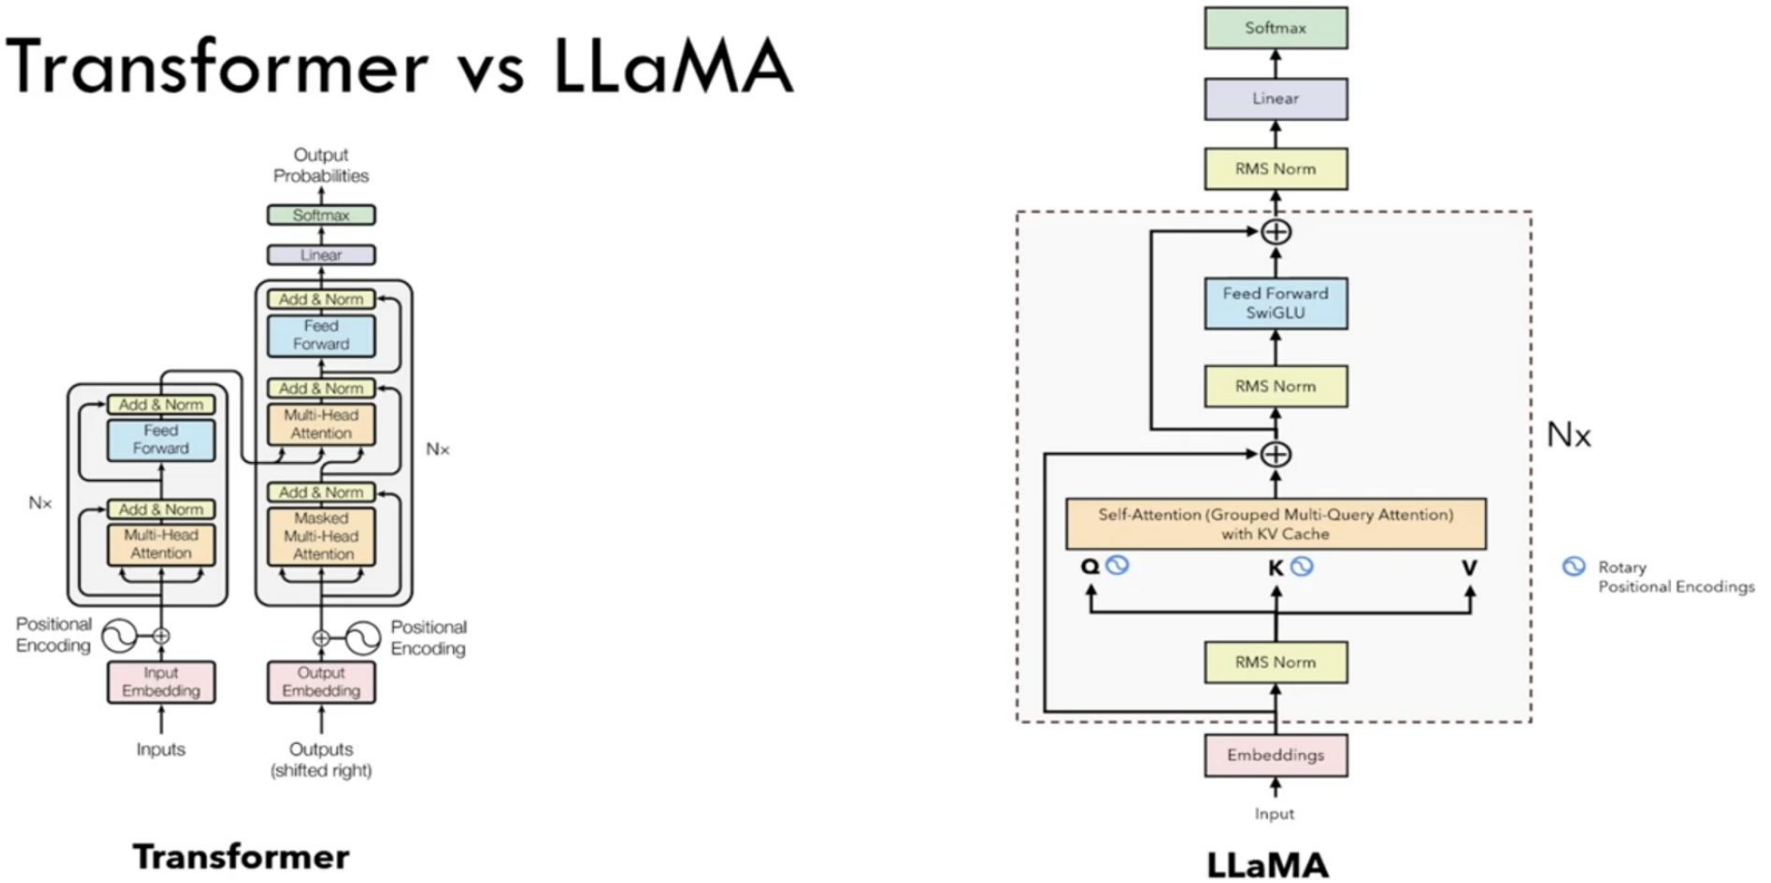


图 5.21　句子中每个单词与其他单词自注意力取值计算示意（以单词 w_3 为例）

大模型的关键技术

■ LLaMA

LLaMA（Large Language Model Meta AI）是由Meta开发的一种大规模语言模型，旨在提高自然语言处理任务的性能。LLaMA基于Transformer机构，并经过大规模数据训练，以便在多种语言任务中表现出色。LLaMA在Transformer结构的基础上，采用前置层归一化（Pre-normalization）和RMSNorm归一化函数（Normalizing Function）、SwiGLU激活函数，并使用了旋转位置嵌入（RoPE）



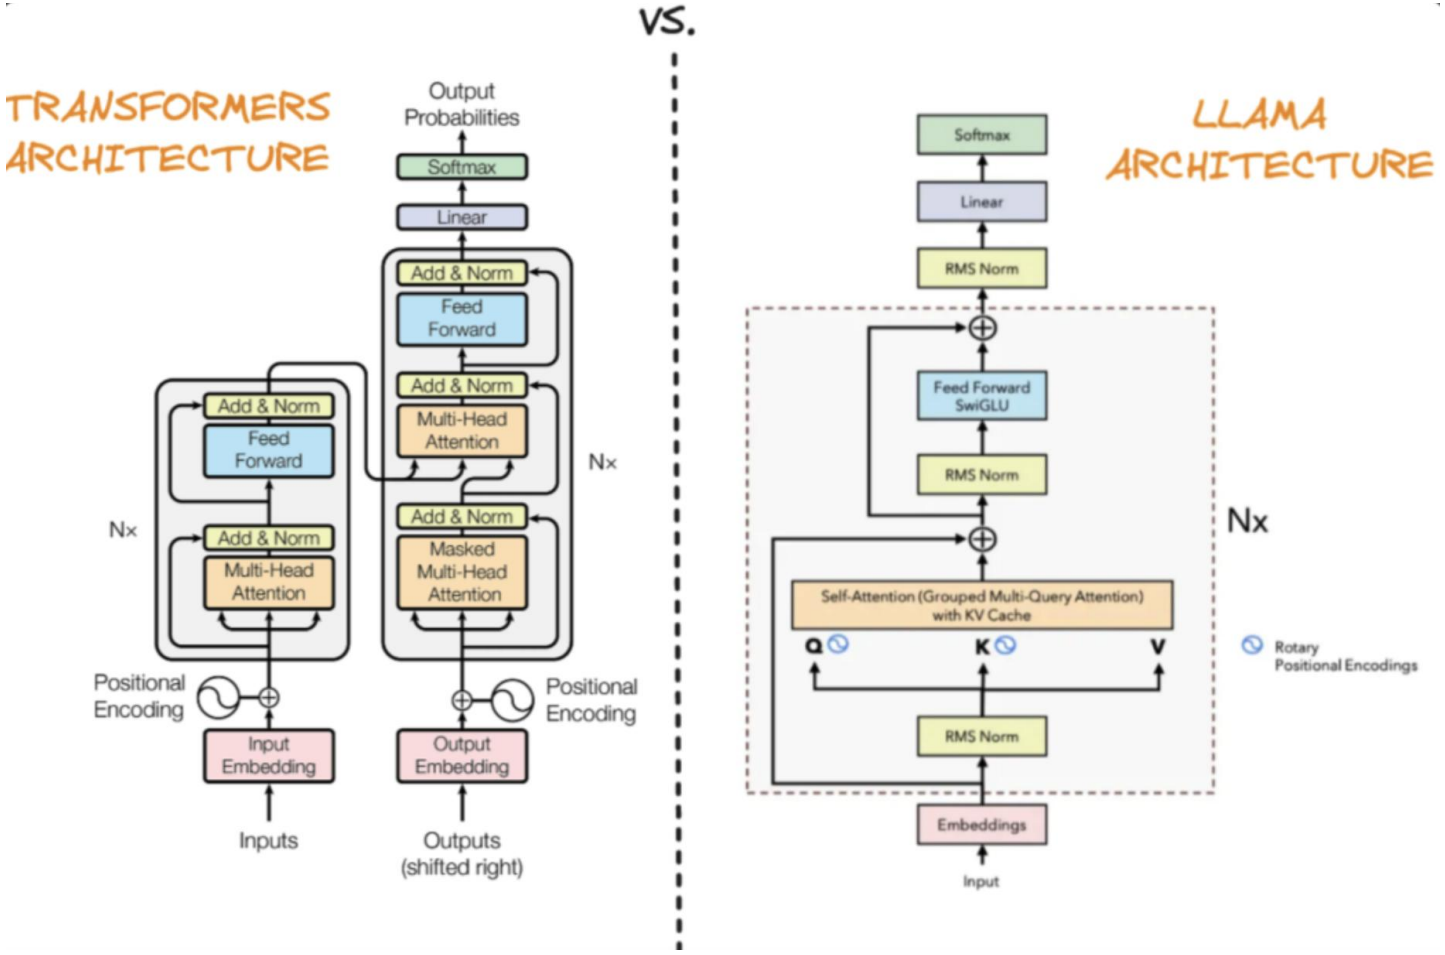
大模型的关键技术

■ LLaMA

- **前馈神经网络**：在自注意力机制之后，是一个前馈神经网络，它对每个位置的表示进行进一步的变换和处理，通常由两个线性层和一个激活函数组成，如 ReLU 或 GeLU 等。

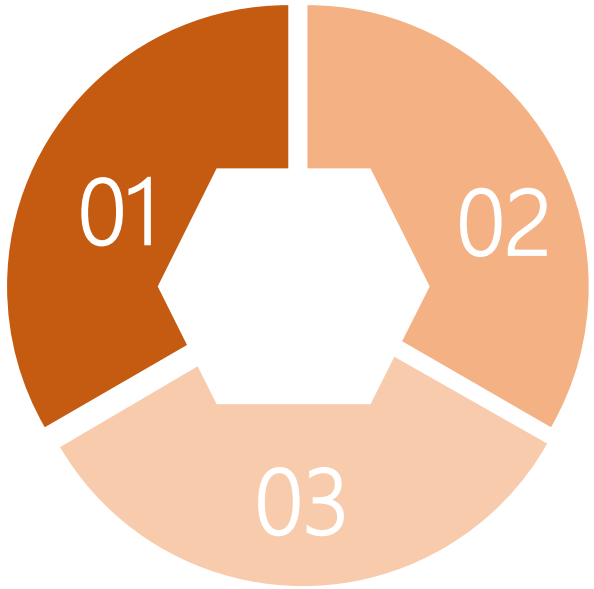
- **规范化和激活函数：**LLaMA 在输入每个子层之前使用 RMS Norm 进行归一化，以提高训练稳定性和性能。激活函数采用 Swiglu，它结合了 Swish 和 GLU 的优点，能够显著提高模型质量。

- **位置编码：**为了捕捉输入序列中单词的顺序信息，LLaMA 使用了旋转位置编码（Rotary Positional Embedding，RoPE），将绝对位置编码和相对位置编码相结合，通过在自注意力机制中对查询和键向量进行旋转操作，来表示位置信息。



大模型的关键技术

■ 训练数据处理



01 数据清洗

在训练大模型前，需要对数据进行清洗，剔除错误、重复或无关的信息确保数据质量。

02 数据增强

通过旋转、缩放、裁剪等技术手段增加训练数据的多样性，提高模型的泛化能力。

03 特征工程

选择和构造对预测任务最有帮助的特征，以提升模型的性能和训练效率

大模型的关键技术

■ 模型训练方法

梯度下降法

梯度下降法是优化算法的核心，通过迭代计算损失函数的梯度来更新模型参数，以最小化误差。

随机梯度下降法

随机梯度下降法(SGD)是梯度下降的一种变体，每次只用一个样本来更新参数，加快了训练速度。

批量归一化

批量归一化是将每层输出特征标准化处理为均值为0和方差1的过程，加速模型训练过程，并提高模型的泛化能力。

正则化技术

正则化技术如L1和L2惩罚项被添加到损失函数中，以防止模型过拟合，提高模型在新数据上的表现。

大模型的关键技术

■ 性能优化策略

参数调优

通过调整学习率、批大小等超参数优化模型性能，减少过拟合和欠拟合现象。

模型剪枝

移除冗余或不重要的参数和神经元 ，降低模型复杂度提高推理速度。

量化技术

将模型参数从浮点数转换为低精度的整数，减少模型大小，加速计算。

知识蒸馏

利用一个大型、性能优越的模型来训练一个更小的模型保留关键信息，提升效率。

大模型的关键技术

■ 性能优化策略-参数调优

关键参数：

- 学习率：控制参数更新步长，过大导致震荡，过小收敛慢。
- 批大小：影响内存占用和梯度稳定性（如小批量更鲁棒）。
- 正则化：L1/L2正则化防止过拟合，Dropout随机屏蔽神经元。

调参方法（人为设定的超参数）：

- 网格搜索：遍历预设参数组合，计算成本高。
- 随机搜索：高效探索参数空间，适合高维场景。
- 自动化工具：贝叶斯优化（如HyperOpt）、早停法（Early Stopping）。

参数类型	作用	典型取值/策略
学习率	控制参数更新步长	初始值1e-4~1e-3，配合衰减策略（如Warmup）
批大小（Batch Size）	影响梯度稳定性与内存占用	根据GPU显存调整（如1024~4096）
优化器	决定参数更新方式	AdamW（带权重衰减）、LAMB（大模型专用）
正则化系数	防止过拟合	L2正则化系数1e-5~1e-3
训练步数	控制训练时长与收敛性	动态早停（Early Stopping）

■ 性能优化策略-参数调优

调优策略

a) 学习率调度（预热到衰减）

•**Warmup**：训练初期逐步增大学习率，避免梯度爆炸（如BERT训练前10%步数逐步升温）。

•**衰减策略**：后期逐步降低学习率（线性衰减、余弦退火等），提升收敛稳定性。

b) 自动化调参工具

•**贝叶斯优化**：基于历史实验结果动态选择下一组超参数（如HyperOpt、Optuna）。

•**分布式搜索**：并行化多组实验（如Ray Tune、Weights & Biases）。

c) 迁移学习调优

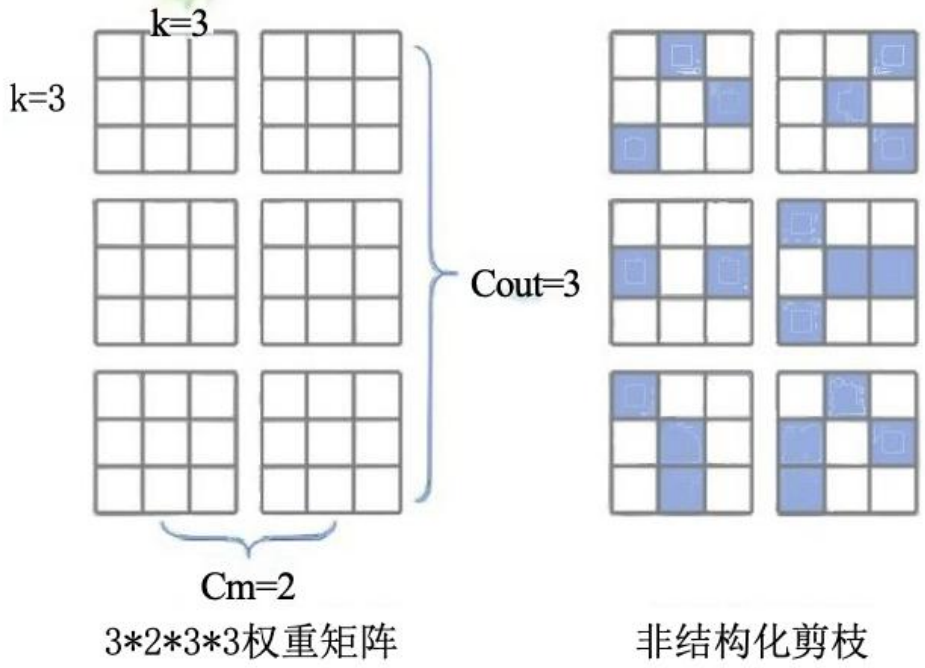
•**预训练模型微调**：复用预训练权重（如GPT-3），仅调整顶层或部分层参数，降低调优成本。

■ 性能优化策略-模型剪枝

模型剪枝的核心思想是从经过训练的深度学习模型中识别和删除不必要的连接、权重甚至整个神经元。删除这些冗余的组件能够显著减小模型的规模，同时能够提高模型的效率和泛化能力。

非结构化剪枝

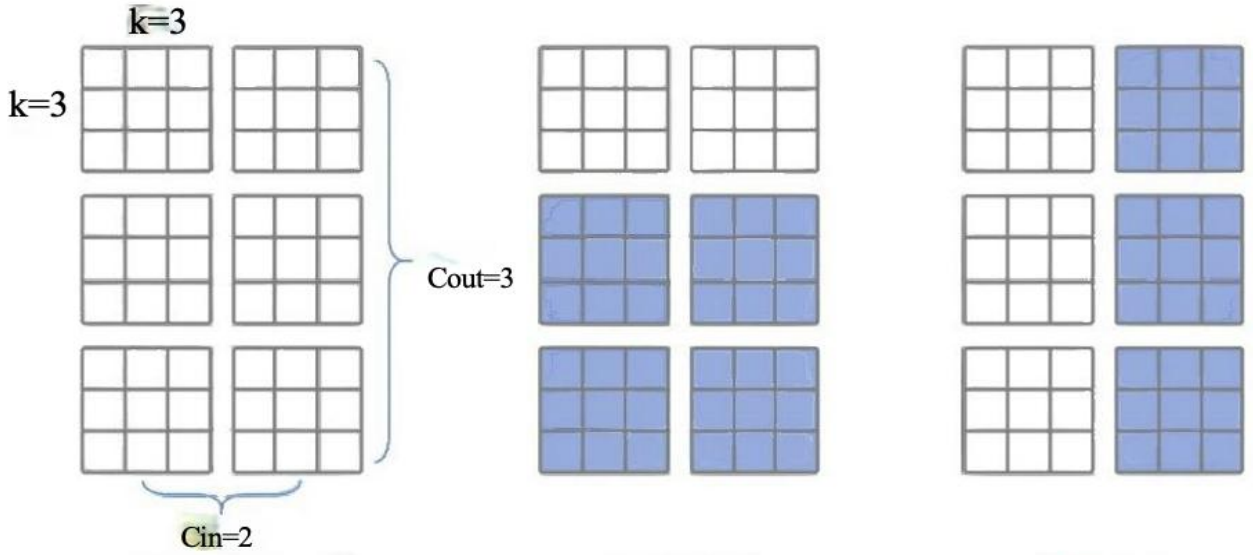
- 以模型的单个参数为单位进行剪枝操作
- 通过设定一个阈值或使用稀疏正则化等方法来判断参数的重要性，将权重或激活值较小的参数设置为零
- 优点：对模型的任意参数进行剪枝，不受模型的限制，并且理论上来说能够提供较高的压缩率
- 缺点：剪枝后的模型存在大量的零参数，引入了稀疏性，需要额外的处理与优化，严重依赖于计算库和硬件



■ 性能优化策略-模型剪枝

结构化剪枝

- 直接对权重矩阵进行剪枝，其在剪枝过程中保持了模型的整体结构
- 目前主流的结构化剪枝可分为滤波器/卷积核剪枝和通道剪枝
- 滤波器剪枝：减少卷积层权重矩阵的滤波器数量来实现模型剪枝
- 通道剪枝：改变滤波器的尺寸来减小模型的规模



大模型的关键技术

■ 性能优化策略-量化技术

模型量化可以看作是一种建立定点数与浮点数之间映射关系的过程

- 将数据的连续值转化为多个离散值，并以最小的代价保持模型原有的性能
- 根据是否对连续的数值范围进行均匀的区间划分，量化可分为均匀量化和非均匀量化两种

均匀量化：

将数值范围均匀地划分为相等的间隔，每个间隔映射到一个固定的离散值， 常见的子类别包括二值化和线性量化

-二值化：将模型的权重和激活值量化为只有两个值，通常为+1和1

-线性量化：将数值范围均匀地划分为等间距的离散值

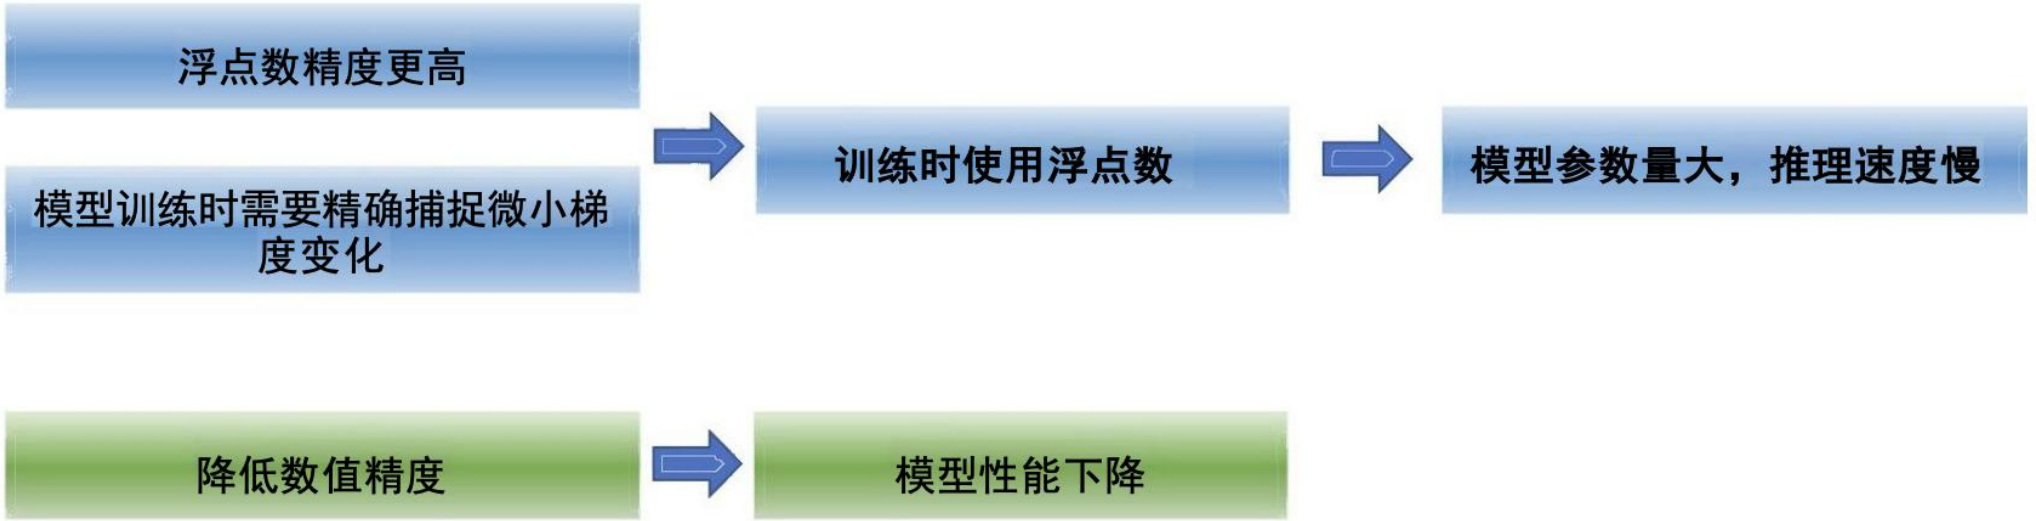
非均匀量化

允许不同区间的间隔大小不同，以更加适应模型参数的实际分布情况，包括对数量化、自适应量化等

-对数量化：使用对数函数来划分数值范围

大模型的关键技术

■ 性能优化策略-量化技术

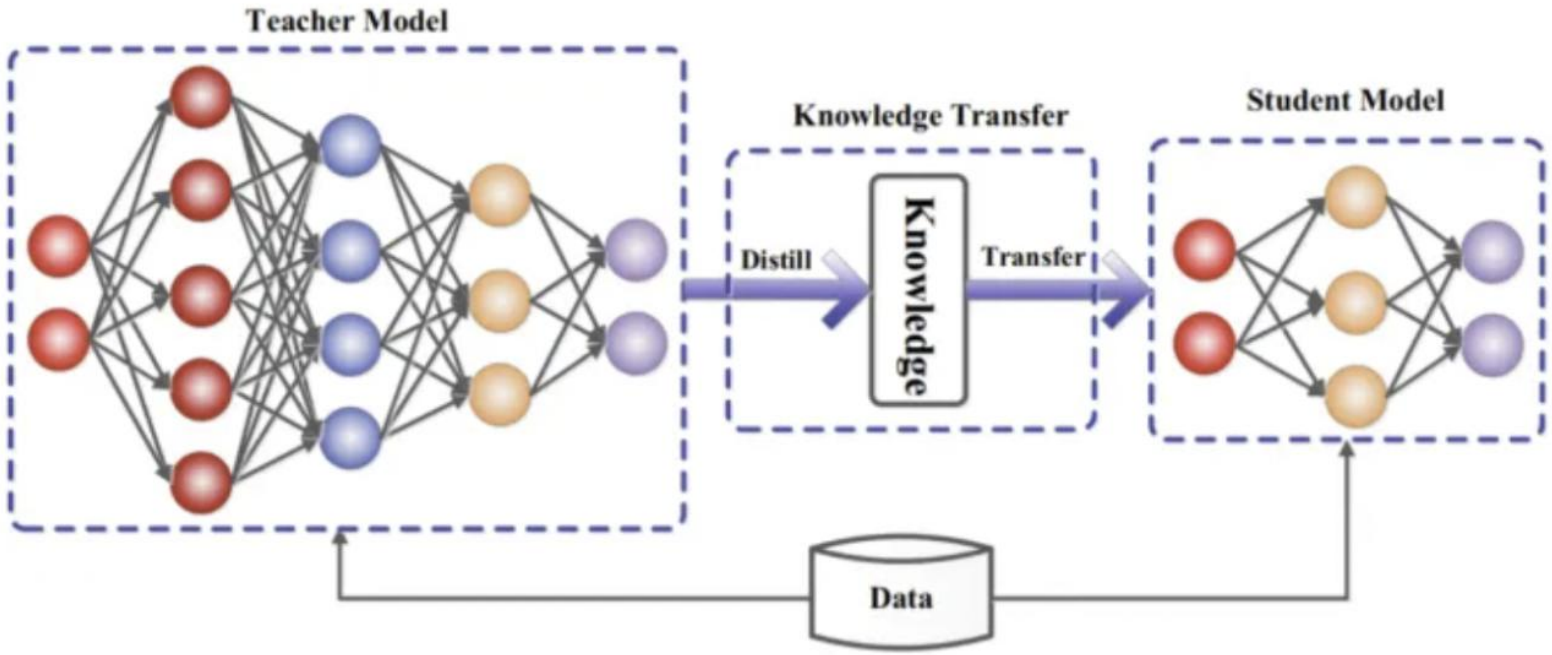


模型量化的核心：在显著减小模型规模的同时，最大限度维持模型的性能水平

■ 性能优化策略-知识蒸馏

知识蒸馏最初由Hinton等人提出，目的是解决大型模型在部署时的资源消耗问题。其基本思想是通过让一个较小的模型学习较大模型的预测分布来获得类似的表现。蒸馏过程包括两个主要模型：

- **教师模型（Teacher Model）：**通常是一个大规模的、经过充分训练的模型，拥有复杂的结构和较高的准确率。
- **学生模型（Student Model）：**一个结构相对简单、参数较少的小型模型，蒸馏过程就是让该模型模仿教师模型的输出。



大模型的关键技术

■ 性能优化策略-知识蒸馏

常见的蒸馏方法

（1）软目标蒸馏（Soft Target Distillation）

教师模型输出的是概率分布（而不是硬标签），学生模型需要模仿这种概率分布。

常用损失函数：KL散度（Kullback-Leibler Divergence）。

（2）特征蒸馏（Feature Distillation）

迁移教师模型在中间层的特征表示，而不仅仅是最终输出。

通过计算学生模型和教师模型在某一层或几层之间的特征相似性，引导学生学习更有效的特征表达。

（3）注意力蒸馏（Attention Distillation）

对于基于Transformer的模型，可以迁移注意力权重。

这种方法常用于自然语言处理任务（如文本分类、机器翻译等）。

（4）多教师蒸馏（Multi-Teacher Distillation）

使用多个教师模型进行知识迁移，增强学生模型的鲁棒性和泛化能力。

从教育孩子视角来讲大模型的推理训练

类比出发点：本质都是“习得复杂能力”的过程

- **大模型训练**：是通过大量数据+ 策略优化，训练出能泛化能力的AI。
- **孩子教育**：是通过反复练习+ 思维引导，让孩子形成稳定的知识结构与思维方式。

核心目标相同：不是记住答案，而是习得“解题能力”、“推理能力”、“迁移能力”。

相似点分析：这不是类比，是共通规律

维度	LLM微调训练	孩子教育	共通点
知识来源	高质量标注数据，包含输入、过程、输出	教材 + 作业 + 老师/家长讲解	都依赖外部示范+反馈机制来学习
目标	泛化能力、推理能力、生成准确性	掌握知识点，形成逻辑思维能力	都追求能力迁移和组合，不是死记硬背
训练方式	few-shot、CoT（思维链）、RLHF（人类反馈强化学习）、对抗训练	示例讲解、逐步引导、举一反三、错题讲解	都需要从样例中抽象出思路
数据策略	简单→困难、过程标注、提示优化	先基础题、再综合题，有时要“拆解思路”	由浅入深，注重思维过程
错误处理	Loss反向传播、对抗样本修正	讲错题、分析错因、重点再练	错误是学习最有效的切入点
干预方式	prompt injection（提示注入）/ 微调 / RL（强化学习）引导	提问、讲解、鼓励、自主练习	都要在合适时刻提供外部干预而非死盯结果
学习成效提升	加入高质量推理过程CoT（思维链）可大幅提升	难题配详细讲解能带来质变	思维路径的显性建模是能力跃迁的关键

从教育孩子视角来讲大模型的推理训练

不同点分析：人与AI的本质差异决定了策略的边界

维度	LLM微调训练	教育孩子	差异说明
先验能力	参数随机初始化，毫无常识	人类天生具备一定感知和社会认知能力	AI是“空白”的，孩子是“带背景”的
动机系统	没有动机，靠优化目标函数	有主观能动性、好奇心、逆反心理等	教育是心理过程，训练是最优化过程
泛化方式	模型结构决定泛化能力	孩子可通过抽象思维进行迁移	LLM 的“泛化”更多靠“统计与模式学习”
训练反馈	梯度更新、loss下降即可	孩子有情绪、压力、疲惫、思维瓶颈	LLM 永远不“走神”，孩子会
可塑性窗口	越早训练效果越稳定，但可重启训练	人类有关键学习期，错过很难补救	人脑塑性有限，模型可以无限训练
知识迭代方式	重训练 or 增量微调	循环复习 + 探索式学习	模型学到新知识可能“遗忘”旧知识（灾难性遗忘），人则容易保留多种路径

结论：教育孩子是心理与认知的协同建构，而训练大模型是工程化地拟合世界规律。策略类似，本质不同。

从教育孩子视角来讲大模型的推理训练

实践总结：从教育方法反向优化模型训练策略

其实，很多教育中被验证有效的方法，**正在变成最前沿的AI训练策略**，

教育方法	对应的大模型训练机制	应用价值
讲步骤比讲答案更有效	Chain of Thought	显性化推理过程，提升复杂任务能力
举一反三训练	Multi-task Learning	多任务微调提升泛化能力
错题本机制	Adversarial Training对抗训练 / hard negative sampling强负例采样	针对性补齐模型薄弱点
循序渐进训练	Curriculum Learning课程学习	先易后难提升稳定性与收敛速度
“拆题”训练	Intermediate Reasoning Decomposition	拆解复杂任务成子任务，逐步推理
小组讨论 / 对话教学	Self-Ask / Debate Prompting	模型通过自问自答或多轮生成提升推理能力

✨启示与建议：用“教育观”做更好的大模型训练设计

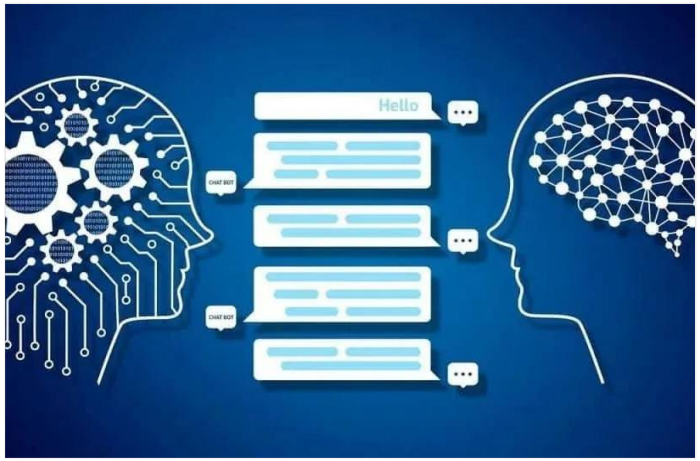
- **训练数据不只是多，要结构清晰、有思维过程，** 就像教材要配例题与过程详解。
- **难题才有教学价值，但必须配合思维引导，** 让模型“做难题 + 看步骤”，而不是“背答案”。
- **模型也需要“错题本机制”，** 构造 hard negative case，让模型不断突破盲点。
- **关注模型的“学习方式”而非“答案表现”，** loss 下降 ≠ 学到推理；有思路输出才是真能力。
- **对话式学习将是未来趋势，** 类似Socratic teaching（苏格拉底式提问）的方式，正逐步用于模型思维链建模。

结语：教育孩子的心态，可以让我们训练出更“聪明”的大模型

目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

大模型的分类



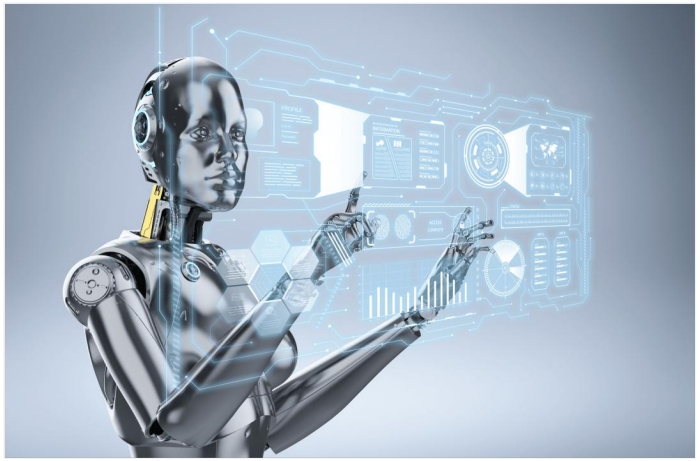
语言大模型

是指在自然语言处理（Natural Language Processing，NLP）领域中的一类大模型，通常用于处理文本数据和理解自然语言。这类大模型的主要特点是它们在大规模语料库上进行了训练，以学习自然语言的各种语法、语义和语境规则。代表性产品包括GPT系列（OpenAI）、Bard（Google）、DeepSeek、文心一言（百度）等



视觉大模型

是指在计算机视觉（Computer Vision，CV）领域中使用的大模型，通常用于图像处理和分析。这类模型通过在大规模图像数据上进行训练，可以实现各种视觉任务，如图像分类、目标检测、图像分割、姿态估计、人脸识别等。代表性产品包括VIT系列（Google）、文心UFO、华为盘古CV、INTERN（商汤）等



多模态大模型

是指能够处理多种不同类型数据的大模型，例如文本、图像、音频等多模态数据。这类模型结合了NLP和CV的能力，以实现对多模态信息的综合理解和分析，从而能够更全面地理解和处理复杂的数据。代表性产品包括DingoDB多模向量数据库（九章云极DataCanvas）、DALL-E(OpenAI)、悟空画画（华为）、midjourney等

大模型的分类

按照应用领域的不同，大模型主要可以分为L0、L1、L2三个层级

通用大模型L0

是指可以在多个领域和任务上通用的大模型。它们利用大算力、使用海量的开放数据与具有巨量参数的深度学习算法，在大规模无标注数据上进行训练，以寻找特征并发现规律，进而形成可“举一反三”的强大泛化能力，可在不进行微调或少量微调的情况下完成多场景任务，相当于AI完成了“通识教育”

行业大模型L1

是指那些针对特定行业或领域的大模型。它们通常使用行业相关的数据进行预训练或微调，以提高在该领域的性能和准确度，相当于AI成为“行业专家”

垂直大模型L2

是指那些针对特定任务或场景的大模型。它们通常使用任务相关的数据进行预训练或微调，以提高在该任务上的性能和效果

目录

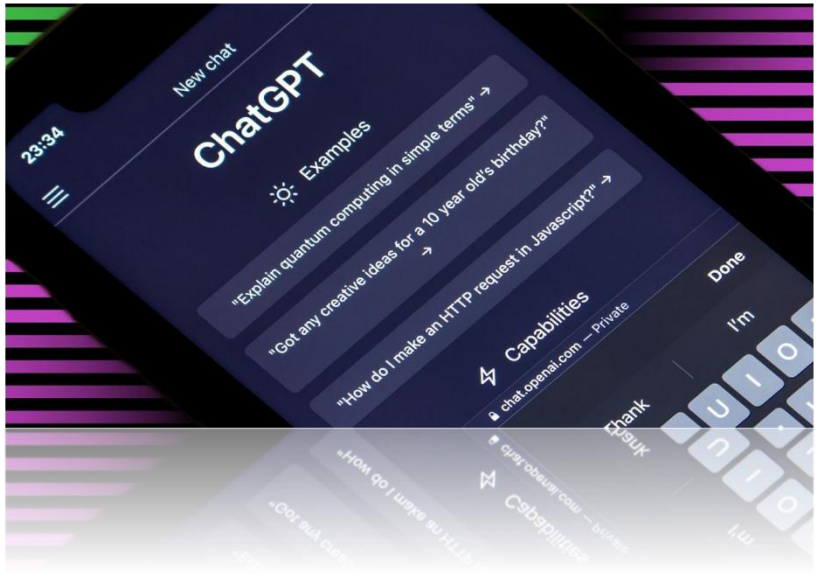
- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

国内外大模型产品

■ ChatGPT

ChatGPT是一种**由OpenAI训练的大语言模型**。它是基于Transformer架构，经过大量文本数据训练而成，能够生成自然、流畅的语言，并具备回答问题、生成文本、语言翻译等多种功能

ChatGPT的应用范围广泛，**可以用于客服、问答系统、对话生成、文本生成等领域**。它能够理解人类语言，并能够回答各种问题，提供相关的知识和信息。与其他聊天机器人相比，ChatGPT具备更强的语言理解和生成能力，能够更自然地与人类交流，并且能够更好地适应不同的领域和场景。ChatGPT的训练数据来自互联网上的大量文本，因此，它能够涵盖多种语言风格和文化背景







国内外大模型产品

■ Gemini

Gemini是谷歌发布的大模型，它能够**同时处理多种类型的数据和任务，覆盖文本、图像、音频、视频等多个领域**。Gemini采用了全新的架构，将多模态编码器和多模态解码器两个主要组件结合在一起，以提供最佳结果

Gemini包括三种不同规模的模型：Gemini Ultra、Gemini Pro和Gemini Nano，适用于不同任务和设备。2023年12月6日，Gemini的初始版本已在Bard中提供，开发人员版本可通过Google Cloud的API获得。Gemini可以应用于Bard和Pixel 8 Pro智能手机。Gemini的应用范围广泛，包括**问题回答、摘要生成、翻译、字幕生成、情感分析**等任务。然而，**由于其复杂性和黑箱性质，Gemini的可解释性仍然是一个挑战**







国内外大模型产品

■ Sora

2024年2月16日，OpenAI再次震撼全球科技界，发布了名为Sora的**文本生成视频大模型**，只需输入文本就能自动生成视频。这一技术的诞生，**不仅标志着人工智能在视频生成领域的重大突破，更引发了关于人工智能发展对人类未来影响的深刻思考**。随着Sora的发布，人工智能似乎正式踏入了通用人工智能（AGI：Artificial General Intelligence）的时代。**AGI是指能够像人类一样进行各种智能活动的机器智能，包括理解语言、识别图像、进行复杂推理等**。Sora大模型能够直接输出长达60秒的视频，并且视频中包含了高度细致的背景、复杂的多角度镜头，以及富有情感的多个角色。这种能力已经超越了简单的图像或文本生成，开始触及到视频这一更加复杂和动态的媒介。这**意味着人工智能不仅在处理静态信息上越来越强大，而且在动态内容的创造上也展现出了惊人的潜力**



国内外大模型产品

■ Sora

右图是Sora根据文本自动生成的视频画面，一位戴着墨镜、穿着皮衣的时尚女子走在雨后夜晚的东京市区街道上，抹了鲜艳唇彩的唇角微微翘起，即便带着墨镜也能看到她的微笑，地面的积水映出了她的身影和灯红酒绿的霓虹灯，热闹非凡的唐人街正在进行舞龙表演，熙熙攘攘的人群目光都聚焦在跃动的彩龙身上，整个环境的喜庆氛围仿佛令人身临其境

提示词译文：

一位时尚女性走在布满温暖霓虹灯和动画城市标牌的东京街道上。 她穿着黑色皮夹克、红色长裙和黑色靴子，拎着黑色钱包。 她戴着太阳镜，涂着红色口红。 她走路自信又随意。 街道潮湿且反光，在彩色灯光的照射下形成镜面效果。 许多行人走来走去。

Sora生成的视频：



国内外大模型产品

OpenAI o3

2024年12月20日，OpenAI发布推理模型o3，无论在软件工程、编写代码，还是竞赛数学、掌握人类博士级别的自然科学知识能力方面，o3都达到了很高的水平



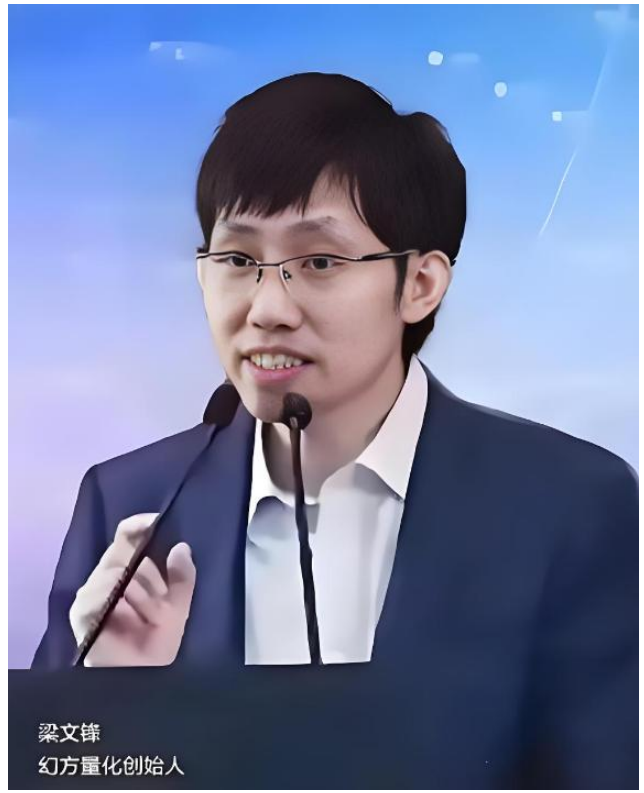


国内外大模型产品

■ DeepSeek（深度求索）

2024年12月26日，杭州一家名为“深度求索”（DeepSeek）的中国初创公司，发布了全新一代大模型DeepSeek-V3。在多个基准测试中，DeepSeek-V3的性能均超越了其他开源模型，甚至与顶尖的闭源大模型GPT-4o不相上下，尤其在数学推理上，DeepSeek-V3更是遥遥领先。DeepSeek-V3以多项开创性技术，大幅提升了模型的性能和训练效率。DeepSeek-V3在性能比肩GPT-4o的同时，研发却只花了558万美元，训练成本不到后者的二十分之一。因为表现太过优越，DeepSeek在硅谷被誉为“来自东方的神秘力量”。

2025年1月20日，DeepSeek-R1正式发布，拥有卓越的性能，在数学、代码和推理任务上可与OpenAI o1媲美。



DeepSeek创始人
梁文峰

国内外大模型产品

■ 通义千问

通义千问是阿里云推出的一个**超大规模的语言模型**，它具备**多轮对话、文案创作、逻辑推理、多模态理解、多语言支持**的能力。通义千问这个名字有“通义”和“千问”两层含义，“通义”表示这个模型能够理解各种语言的含义，“千问”则表示这个模型能够回答各种问题。通义千问基于深度学习技术，通过对大量文本数据进行训练，从而具备了强大的语言理解和生成能力。它能够理解自然语言，并能够生成自然语言文本

同时，通义千问还具备**多模态理解能力，能够处理图像、音频等多种类型的数据**。通义千问的应用范围非常广泛，可以**应用于智能客服、智能家居、移动应用等多个领域**。它可以与用户进行自然语言交互，帮助用户解决各种问题，提供相关的知识和信息。同时，通义千问还可以**与各种设备和应用进行集成**，为用户提供更加便捷的服务



国内外大模型产品

■ 字节跳动豆包

豆包是字节跳动基于云雀模型开发的 AI，能理解你的需求并生成高质量回应。它知识储备丰富，涵盖历史、科学、技术等众多领域，无论是日常问题咨询，还是深入学术探讨，都能提供准确全面的信息。同时，具备出色的文本创作能力，能撰写故事、诗歌、文案等各类体裁。并且擅长语言交互，交流自然流畅，就像身边的知心伙伴，耐心倾听并给予恰当反馈。



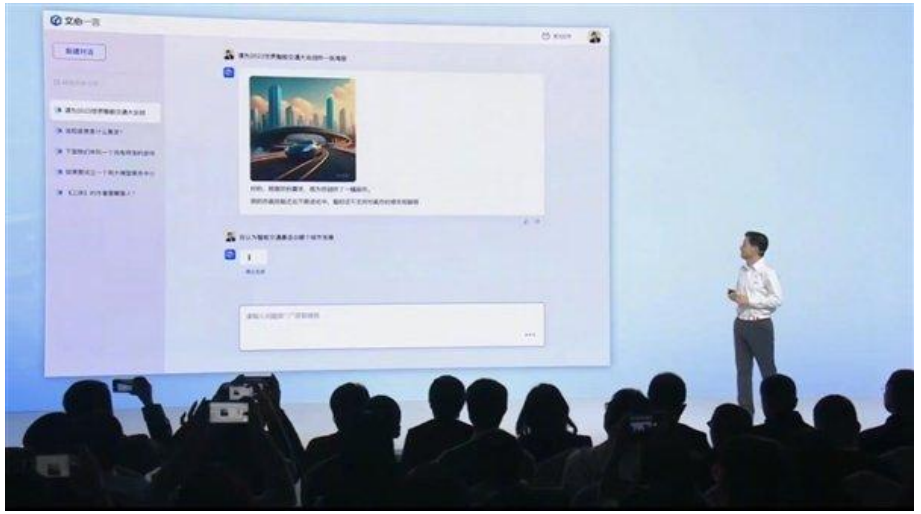
国内外大模型产品

■ 文心一言

文心一言是由百度研发的知识增强大模型，能够与人对话互动、回答问题、协助创作，高效便捷地帮助人们获取信息、知识和灵感

文心一言基于飞桨深度学习平台和文心知识增强大模型，持续从海量数据和大规模知识中融合学习，具备知识增强、检索增强和对话增强的技术特色。

文心一言**具有广泛的应用场景**，例如智能客服、智能家居、移动应用等领域。它可以与用户进行自然语言交互，帮助用户解决各种问题，提供相关的知识和信息





国内外大模型产品

2025年1月国内大模型排行榜

大模型	图标	指标排名
DeepSeek		能力测评第一
豆包		用户数量第一
Kimi		文本处理第一
即梦AI		作图能力第一
通义万相		视频生成第一
智谱清言		文档归纳第一

大模型能做些什么？

目录

- 大模型的概念和特点
- 大模型的发展历程
- 大模型的关键技术
- 大模型的分类
- 国内外大模型产品
- 大模型的应用

大模型的应用

大模型的应用领域非常广泛，涵盖了自然语言处理、计算机视觉、语音识别、推荐系统、医疗健康、金融风控、工业制造、生物信息学、自动驾驶、气候研究等多个领域

（1）自然语言处理

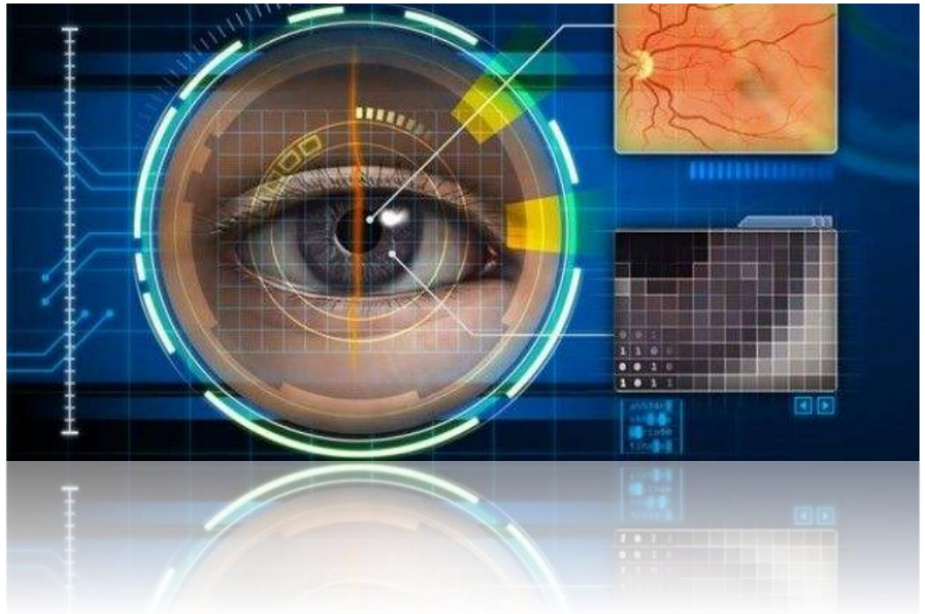
大模型在自然语言处理领域具有重要的应用，可以用于文本生成（如文章、小说、新闻等的创作）、翻译系统（能够实现高质量的跨语言翻译）、问答系统（能够回答用户提出的问题）、情感分析（用于判断文本中的情感倾向）、语言生成（如聊天机器人）等





（2）计算机视觉

大模型在计算机视觉领域也有广泛应用，可以用于图像分类（识别图像中的物体和场景）、目标检测（能够定位并识别图像中的特定物体）、图像生成（如风格迁移、图像超分辨率增强）、人脸识别（用于安全验证和身份识别）、医学影像分析（辅助医生诊断疾病）等



大模型的应用

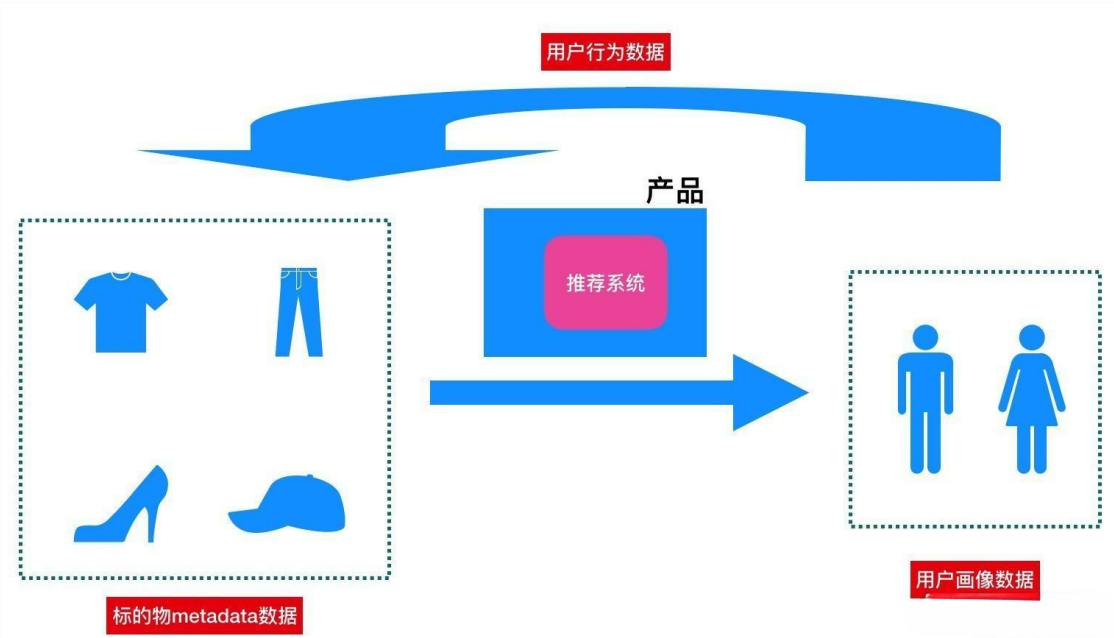
（3）语音识别

大模型在语音识别领域也有应用，如语音识别、语音合成等。通过学习大量的语音数据，大模型可以实现高质量的跨语言翻译和语音识别以及生成自然语音



（4）推荐系统

大模型可以用于个性化推荐、广告推荐等任务。通过分析用户的历史行为和兴趣偏好，大模型可以为用户提供个性化的推荐服务，提高用户满意度和转化率



大模型的应用



自动驾驶

大模型可以用于自动驾驶中的感知、决策等任务。通过学习大量的驾驶数据，大模型可以实现对车辆周围环境的感知和识别，以及进行决策和控制，提高自动驾驶的安全性和效率



医疗健康

大模型可以用于医疗影像诊断、疾病预测等任务。通过学习大量的医学影像数据，大模型可以辅助医生进行疾病诊断和治疗方案制定，提高医疗水平和效率



金融风控

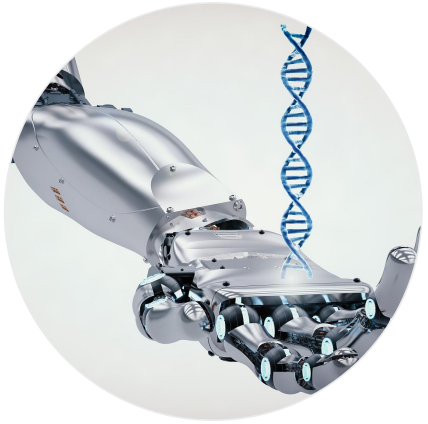
大模型可以用于信用评估、欺诈检测等任务。通过分析大量的金融数据，大模型可以评估用户的信用等级和风险水平，以及检测欺诈行为，提高金融系统的安全性和稳定性

大模型的应用



工业制造

大模型可以用于质量控制、故障诊断等任务。通过学习大量的工业制造数据，大模型可以辅助工程师进行产品质量控制和故障诊断，提高生产效率和产品质量



生物信息学

在生物信息学领域，大模型可以用于基因序列分析（识别基因中的功能元件和变异位点）、蛋白质结构预测（推测蛋白质的二级和三级结构）、药物研发（预测分子与靶点的相互作用）等



气候研究

在气候研究领域，大模型可以处理气象数据，进行天气预测和气候模拟。它们能够分析复杂的气象现象，提供准确的气象预报，帮助人们做出应对气候变化的决策

大模型的应用

■ 一道物理题的求解

Answer question I.1.a. Think step-by-step.

I. Principe de la détection de rayonnement avec un bolomètre

Comme illustré sur la figure 1 un bolomètre est constitué d'un absorbeur qui reçoit le rayonnement que l'on désire détecter. Sa température T, supposée uniforme, est mesurée à l'aide d'un thermomètre incorporé, constitué d'un matériau conducteur dont la résistance $R(T)$ varie avec la température T ; cette variation est caractérisée par le coefficient $\alpha = \frac{1}{R}\frac{dR}{dT}$. L'ensemble possède la capacité thermique C_{th}.

Un barreau, conducteur thermique, homogène, de longueur L, de section S et de conductivité thermique λ et sans échanges thermiques latéraux, relie le bolomètre à un thermostat de température T_b fixe.

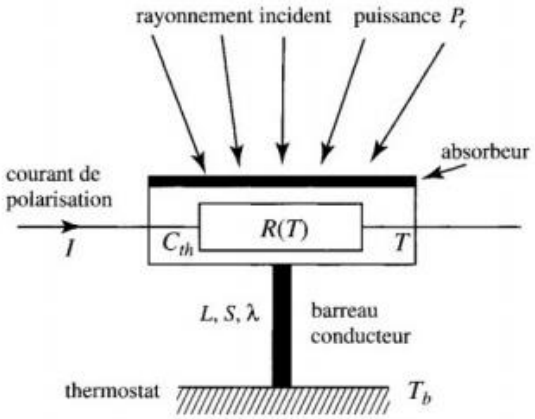


Figure 1 - Schéma d'un bolomètre

I.1. Dans cette première partie, on étudie le comportement du bolomètre en régime stationnaire, à la température de fonctionnement $T = T_0$.

I.1.a) Exprimer la température $T(x)$ en tout point du barreau conducteur repéré par son abscisse x ; on prendra $T(0) = T_0$ et $T(L) = T_b$.

To answer question I.1.a, we need to express the temperature $T(x)$ in every point of the conductive bar, which is characterized by the abscissa x. We are given that $T(0) = T0$ and $T(L) = Tb$.

For a stationary regime, the heat equation for the one-dimensional heat conduction in the bar is:
$d^2T/dx^2 = 0$

Integrating once, we get:
$dT/dx = C_1$

Integrating a second time:
$T(x) = C_1x + C_2$

To determine the constants C_1 and C_2, we use the boundary conditions:
$T(0) = T0$, which gives $C_2 = T0$
$T(L) = Tb$, which gives $C_1 = (Tb - T0)/L$

Finally, the expression for $T(x)$ is:
$T(x) = (Tb - T0) * (x/L) + T0$
This represents a linear temperature profile along the conductive bar, with a slope of $(Tb - T0)/L$.

大模型的应用

程序撰写

YI 我是一名高中学生，对斐波那契数列很感兴趣，能否请你帮我用python撰写一个求解斐波那契数列的程序，谢谢！

当然可以！斐波那契数列是一个经典的数列，其中每一项都是前两项的和。数列的开始通常是这样的：$0, 1, 1, 2, 3, 5, 8, 13, \ldots$

以下是一个简单的Python程序，可以用来生成斐波那契数列：

python Copy code

```python
def fibonacci(n):
    """
    返回前n个斐波那契数列的数
    """
    if n <= 0:
        return []
    elif n == 1:
        return [0]
    elif n == 2:
        return [0, 1]

    fib_sequence = [0, 1]
    for i in range(2, n):
        fib_sequence.append(fib_sequence[i-1] + fib_sequence[i-2])

    return fib_sequence
```

使用此函数，你可以得到斐波那契数列的前n个数字。例如，`fibonacci(10)`会返回斐波那契数列的前10个数字。

你想试试这个程序吗？

YI 非常感谢，那对于100以内的质数，有什么程序化的求解方法嘛

当然有。质数是一个只能被1和它自身整除的正整数。为了找到100以内的所有质数，我们可以使用一个叫做“埃拉托斯特尼筛选法”（Sieve of Eratosthenes）的经典算法。这种方法通过排除倍数来找出质数。

以下是使用埃拉托斯特尼筛选法查找100以内质数的Python程序：

python Copy code

```python
def sieve_of_eratosthenes(n):
    """
    返回小于等于n的所有质数
    """
    sieve = [True] * (n + 1)
    sieve[0], sieve[1] = False, False  # 0和1不是质数
    for i in range(2, int(n**0.5) + 1):
        if sieve[i]:
            for j in range(i*i, n+1, i):
                sieve[j] = False

    return [i for i, is_prime in enumerate(sieve) if is_prime]
```

使用此函数，`sieve_of_eratosthenes(100)`将返回100以内的所有质数。

我可以为你运行这个程序，看看结果如何吗？

大模型的应用

■ 图片理解与生成

GPT-4 visual input example, Extreme Ironing:

User: What is unusual about this image?



Source: https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg

GPT-4: The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.



Generate an image of a futuristic car driving through an old mountain road surrounded by nature

大模型的应用

■ 图文回答



My daughter says its name is Larry.

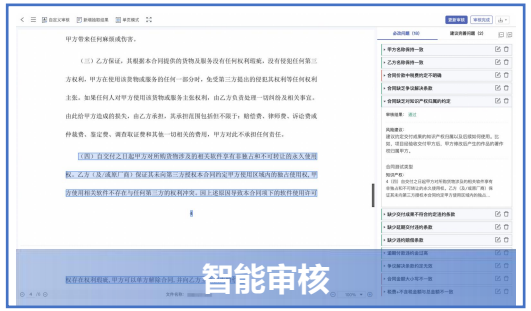
Can

大模型的应用

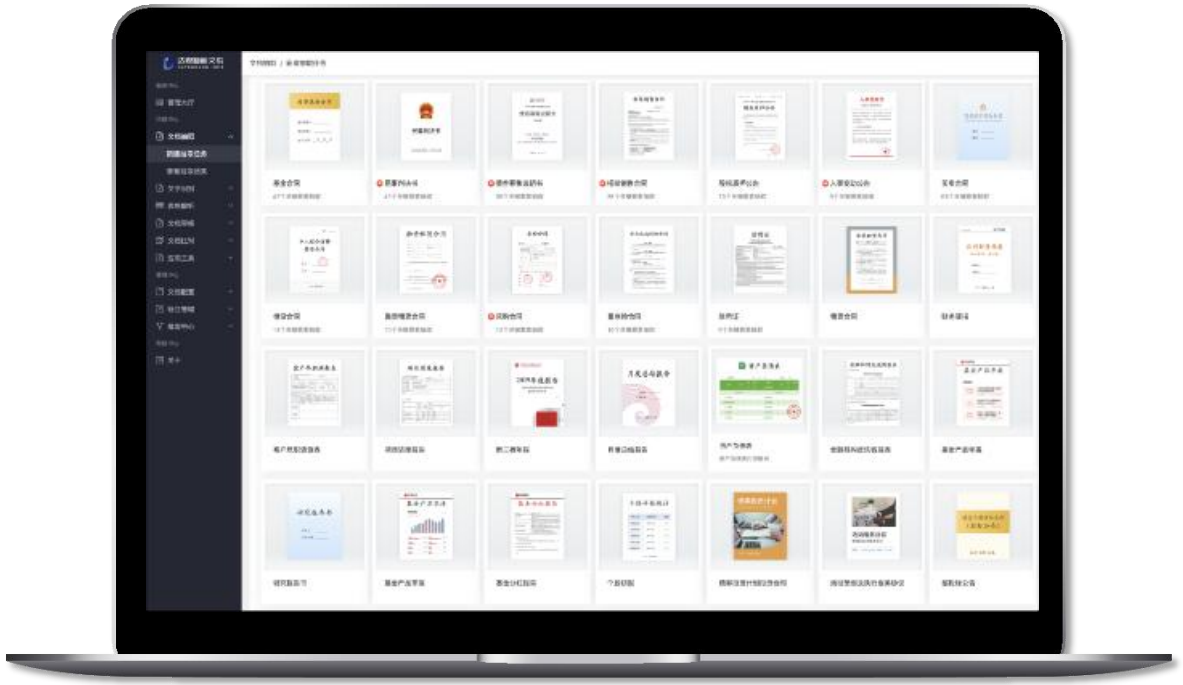
■ 一体化智能写作处理平台

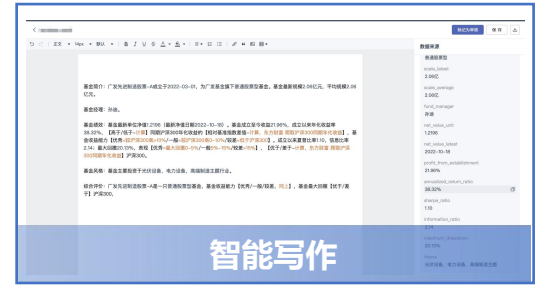
- 让计算机像人一样阅读、理解、生成各类文档、帮助金融行业完成自动化、智能化、定制化的文档处理工作

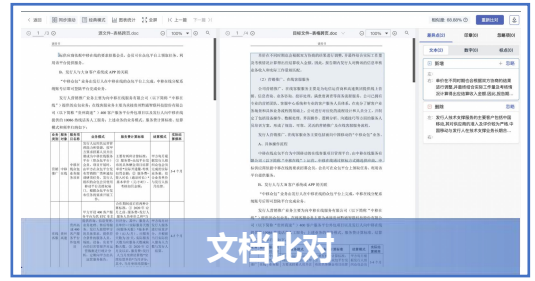










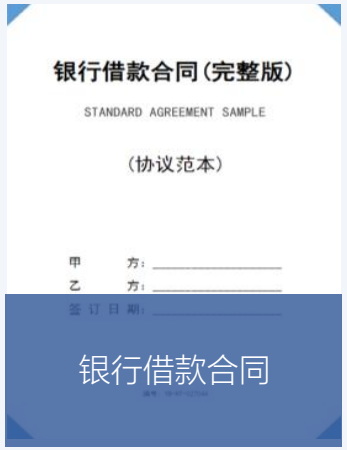




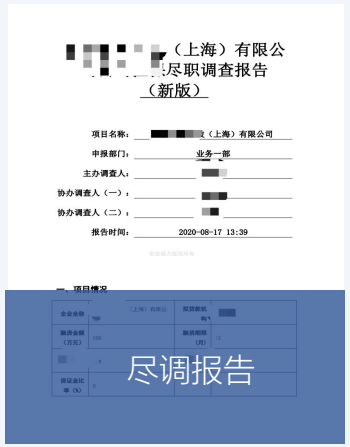
大模型的应用

■ 基于大模型的金融文本智能写作

银行常见写作场景



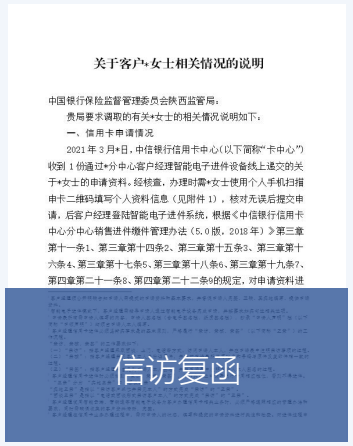
银行借款合同



尽调报告



审计报告

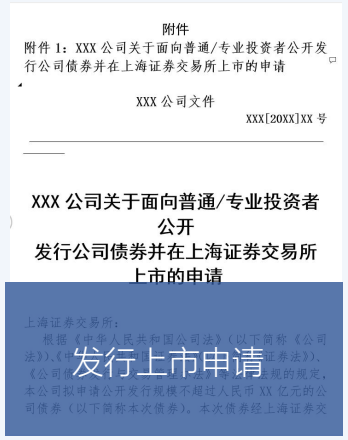


信访复函

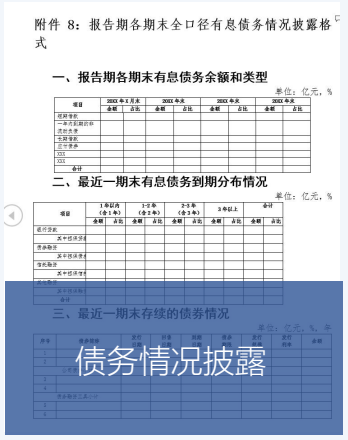


公文

非银常见写作场景



发行上市申请



债务情况披露



研究报告



产品合同

更多类型

资金用途核查

对外投资核查

发行公告

发行结果公告

债券年报

...

大模型的应用

基于大模型的知识问答系统

以GPT大模型为基座的问答系统会成为知识获取的新形态

以GPT大模型为基础的知识问答系统跨代的提升了传统问答系统中的用户意图理解和上下文情境理解，极大的提升了知识获取和加工的效率，支持读取文档、数据库、表格等多种格式的文档，并提供多场景下、多粒度、多轮次、多形态的知识问答交互方式。

多模态大模型问答系统，全面、快速、灵活的触达精准答案



支持知识问答和智能搜索结果联动展示

- 支持智能搜索和知识问答联动，同时显示全文搜索和知识问答结果，智能搜索结果作为问答系统的答案补充，全文搜索筛选条件也将影响大模型的问答范围



支持用户问题推理步骤拆解和答案精准溯源

- 多模态大模型理解用户查询，将问题分步骤拆解，显性展示意图理解和执行步骤，结果可解释
- 多模态大模型支持生成文本、表格、图表等格式答案且每个数据精准溯源”



支持单文档问答

- 多模态大模型可回答关于给定文档中某些信息的问题。在单文档问答中，会根据用户提供的问题，从一个给定的文档中找到最佳答案
- 适用于手册、制度类长文档场景

大模型的应用

■ 基于大模型的AIGC技术日益成熟

AIGC的全称为“Artificial Intelligence Generated Content”，中文翻译为“人工智能生成内容”。这是一种新的创作方式，利用人工智能技术来生成各种形式的内容，包括文字、音乐、图像、视频等

- AIGC是**人工智能进入全新发展时期的重要标志**，其核心技术包括生成对抗网络（GAN，Generative Adversarial Networks）、大型预训练模型、多模态技术等
- AIGC的核心思想是**利用人工智能算法生成具有一定创意和质量的内容**。通过训练模型和大量数据的学习，AIGC可以根据输入的条件或指导，生成与之相关的内容。例如，通过输入关键词、描述或样本，AIGC可以生成与之相匹配的文章、图像、音频等
- AIGC技术**不仅可以提高内容生产的效率和质量，还可以为创作者提供更多的灵感和支持**。在文学创作、艺术设计、游戏开发等领域，AIGC可以自动创作出高质量的文本、图像和音频等内容。同时，AIGC也可以应用于媒体、教育、娱乐、营销、科研等领域，为用户提供高质量、高效率、高个性化的内容服务



大模型的应用

常见的AIGC应用场景

电商

生成商品标题、描述、广告文案和广告图

办公

写周报日报，写方案，写运营活动，制作PPT，写读后感，写代码

游戏

生成场景原画，生成角色形象，生成世界观，生成数值，生成3D模型，生成NPC对话，音效生成

娱乐

头像生成，照片修复，图像生成，音乐生成

影视

生成分镜头脚本，生成剧本脚本，台词润色，生成推广宣传物料，音乐生成

大模型的应用

■ 常见的AIGC应用场景

动漫

原画绘制，动画生成，分镜生成，音乐生成

艺术

写诗，写小说，生成艺术创作品，草图生成，艺术风格转换，音乐创作

教育

批改试卷，试卷创建，搜题答题，课程设计，课程总结，虚拟讲师

设计

UI设计，美术设计，插画设计，建筑设计

媒体

软文撰写，大纲提炼，热点撰写

生活

制定学习计划，做旅游规划

大模型的应用

AIGC技术对行业发展的影响深远且广泛，主要体现在以下几个方面：

内容创作领域的革新

AIGC技术能够自动生成高质量的文本、图像、音频和视频等内容，极大地提高了内容创作的效率。在新闻、广告、自媒体等领域，AIGC已经实现了广泛应用，帮助创作者快速生成多样化、个性化的内容，满足市场需求。这种技术革新不仅降低了内容创作的成本，还激发了创作者的创新灵感，推动了内容产业的繁荣发展。

生产力提升与成本降低

AIGC技术在多个行业中展现了其提升生产力和降低成本的潜力。例如，在游戏开发领域，AIGC技术可以用于场景构建、角色互动等，减少人工制作的工作量，提高开发效率。在制造业中，AIGC技术可以辅助设计、优化生产流程，降低生产成本。这些应用使得企业能够更快地响应市场变化，提升竞争力。

用户体验的升级

AIGC技术通过提供个性化、定制化的内容和服务，显著提升了用户体验。在智能客服、在线教育等领域，AIGC技术可以根据用户的需求和偏好提供精准的服务，满足用户的个性化需求。这种以用户为中心的服务模式不仅增强了用户的满意度和忠诚度，还为企业带来了更多的商业机会。

推动行业创新与转型

AIGC技术的快速发展为传统行业带来了转型升级的契机。通过与AIGC技术的深度融合，传统行业可以探索新的商业模式和服务模式，实现创新发展。例如，在零售业中，AIGC技术可以用于智能推荐、虚拟试衣等场景，提升购物体验并促进销售增长。在金融领域，AIGC技术可以应用于投资策略优化、风险管理等方面，提高金融机构的决策效率和准确性。

大模型的应用

图片类AIGC是一种基于人工智能技术生成图片的方法，它利用深度学习、生成对抗网络（GAN）等先进算法，通过学习和模仿大量图像数据，能够自动创作出高度真实和艺术化的图片。AIGC在图像生成、修复、风格转换、艺术创作等领域展现出强大能力，**为数字艺术、设计、游戏、电影等多个行业带来创新解决方案。其优势包括高效性、多样性和自动化**，能够快速生成大量高质量的图像内容，满足各种复杂需求。





大模型的应用

图片类AIGC的应用场景非常广泛，主要包括图像生成、图像修复、图像增强和图像识别等方面：

图像生成

AIGC能够生成高度逼真的图像，如人脸、动物、建筑物等。例如，OpenAI发布的DALL-E可以根据文本提示词创作出全新的、原创的图像，展示了AI在图像创作方面的强大能力。

图像修复

AIGC还可以修复损坏的图像，如去除噪声、填充缺失的部分等。这项技术对于保护和恢复古老的艺术作品、修复损坏的照片等具有重要意义。

图像增强

通过对图像进行增强处理，AIGC可以增加图像的饱满感和增强细节，使图像质量得到提升。这在提升照片的视觉效果、改善图像的清晰度和细节方面非常有用。

图像识别

AIGC在图像识别方面也有广泛应用，可以识别图像中的对象、场景和特征，如人脸识别、车牌识别等。这项技术对于安防监控、智能搜索、自动驾驶等领域的发展至关重要。

大模型的应用

语音类AIGC是一种利用人工智能技术（特别是语音识别、自然语言处理和语音合成技术），自动生成和处理语音内容的技术。它能够**模拟人类语音，实现语音到文本的转换、文本到语音的合成，以及语音情感分析等**功能，广泛应用于智能语音助手、智能客服、语音翻译等多个领域。



大模型的应用

语音类AIGC的应用场景非常丰富，涵盖了多个领域，从日常生活到专业应用，都展现出了其独特的价值和潜力，以下是一些主要的语音类AIGC应用场景：



大模型的应用

视频类AIGC是指利用人工智能技术，特别是深度学习、机器学习等算法，自动创建或处理视频内容的技术。**它能根据给定的文本、图像或其他数据，自动生成符合描述的视频内容，涵盖文生视频、图生视频、视频风格化、人物动态化等多个方向**。这一技术在创意设计、影视制作等领域潜力巨大，极大地提升了视频内容的生产效率和质量





大模型的应用

视频类AIGC在多个领域拥有广泛的应用场景，以下是一些主要的应用方向：



大模型的应用

总结

大模型是人工智能领域的重要研究方向，其强大的语言理解和生成能力使得它在自然语言处理、机器翻译、智能客服等领域有着广泛的应用。大模型的训练需要大量的数据和计算资源，同时也需要先进的技术和算法支持。随着技术的不断发展，大模型的应用场景也在不断扩展，未来将会更加广泛地应用于各个领域。

